HUB NoC 模块需求

> Owner: WangYizhao | 2026-10-24 | NPU Architecture V1.5

0 读这份文档之前

- 读者是有 NPU 设计经验、第一次接触本项目的工程师。读完 §1 到 §3 应能说出 hub 怎样把中央 L2 的数据送进四个核、怎样把四个核的结果收回 L2、跨核只需要的那几件事（位图并集、列表写入、判决广播、标量合并、位点 barrier）在哪里做；§4 是条款，§5 是设计目标。
- 10-24 起本篇的 D-40 与上行链路按传输协议篇（`SPEC_TRANSFER_PROTOCOL_V1.5.md` 的协议 B，56 号；V1.4 时为整体集成篇第 6.8 节）描述：flit 带侧带头（下行 12 bit、上行 14 bit，类别字段取代 1 bit 类型位）、不带地址；VC0 / VC1 信用按（核, VC, 道），VC2 / VC3 按（核, VC）共享池；信用经链路束内侧带脉冲返还；写完成 / 读完成计数器移到 L2 侧，HUB-SYNC 只保留 barrier 计数。改动处标〔按 56 号 §x〕。
- 本篇把 V1.2 的 D-40 下行（HUB-DN）、上行汇合与单写口（HUB-UP）、跨核位图 OR 与列表环写入（HUB-ATT）、标量合并与计数（HUB-SYNC）合为一篇，hub 内部不再细拆。核间部分和归约的 R-hub 另成 HUB RHUB 篇；L2 的物理组织、区域划分与计数单位在 L2 SRAM 篇。
- 互连的正式表述是"以中央 L2 为中心的两级集中式互连"。
- 条款以 4.x.y 小节组织，末尾〔原 REQ-xx-nn〕只作与 V1.2 的对照，〔新，R46-02〕表示按裁定新增，〔按 R50-5 改〕表示 V1.4 按 50 号 D50-5（训练权重不经 hub）改写。配置、事件与计数器只按含义描述，实名与编码等 ISA 确认后补入。数字口径：1 GHz（1 拍 = 1 ns）、DDR 19.2 B/拍，模型写作 Qwen3-4B / MiniCPM5-1B。
- 10-26 起全篇按 AW 写法（$Y = XW$，W 为 $K \times M$），行 / 列以右操作数为准（归约下标为行、输出下标为列），旧稿行 / 列义相反，对应表见 `SYMBOLS_AND_TERMS_V1.5.md` §3。

1 HUB NoC 是做什么的

1.1 它在片上的位置

四个计算核（CC0–CC3）之间没有直连，全部片上搬运都经 hub。hub 以中央 L2 为中心分两级：第一级在中心，含 4 个 L2 象限读引擎、上行汇合、写 L2 的单写口、HUB-ATT、HUB-SYNC 与挂在中心的 R-hub；第二级是 4 个道发端，每道把本道 flit 按目的掩码送到 4 个核口。下行只有 D-40 一条：128 B/拍 = 4 道 × 32 B，道 n_{q} 硬连 L2 象限 n_{q}；上行为每核一条 32 B/拍链路。上下行各 4 个虚通道（VC），端到端信用流控，中间级不设 VC 缓冲。LIC 是 hub 的控制客户，经 hub 控制口下发 hub 位点描述符、收 GO 与合并结果；MAE 经 hub 注入计数事件；NI 的写客户与返回车道直接在 L2 bank 上仲裁，不经 hub。

1.2 整体任务

一句话：在口宽固定的前提下，把 L2 内容按信用多播或单播给四核，把四核上行汇合写回 L2，并在中心完成"只搬位图、列表与标量"的跨核功能。分四类：

1. 下行（HUB-DN）：激活紧凑记录的按段交错重放、数据类单播 / 多播、响应回送、控制与表装载，四 VC 共用 4 道，数据 VC 有保底份额。
2. 上行与单写口（HUB-UP）：收四核 × 32 B/拍上行，按 VC 分流到单写口、HUB-ATT、HUB-SYNC 与 R-hub；写 L2 只有一个 32 B/拍写口。
3. 跨核位图与列表（HUB-ATT）：attention 录取位图与区块位图按 kv 头取 OR（区块并集同时写区块列表环并广播给参与核 CTL），训练多核 lo 读集取 OR，各核上行的列表记录按环号写列表环，K 切分判决结果转发广播。
4. 标量与控制原语（HUB-SYNC）：标量合并、带序号的位点 barrier 计数、barrier 超时检测并上报 LIC。写完成 / 读完成计数器（WCNT / RCNT）移到 L2 侧（L2 SRAM 篇），调用级计数窗与看门狗归 LIC〔按 56 号 §6.2；按 57 号 B-14 / B-20〕。

1.3 它不做什么

不在 NoC 之外另拉点对点链路（信用返还线是链路自身的流控侧带，不算另拉链路，用户 10-24）；不加宽 D-40、不改道数与 flit 宽、不为超口降档或放慢阵列；不为部分和读回开独立 L2 读口；不做任何阈值判决、TOPK 选择或采样（在产生评分的核内）；不承载逐行判决评分与 LM Head logits；不发 DDR 请求（MAE）；不解析 hub 位点描述符以外的描述符；不做部分和归约运算（HUB RHUB）；不跨核借 L1；不跨调用保存树结构（片上建树的树记录组驻留在 LM Head 属主核与 L2 调用输入区，不在 hub）；不持有写完成 / 读完成计数器（在 L2 侧）、不做调用级看门狗（在 LIC）；不解析载荷格式——hub 单写口、D-40 与上行链路本身只搬运 8 B 字，只有 HUB-DN 段片切分、HUB-ATT 与 R-hub 是格式感知端点〔按 56 号 §2.4〕。

1.4 贯穿全文的几个概念

- flit 与道：一个 flit 32 B，下行带 12 bit 侧带头（目的掩码 4、VC 2、类别 3、末标记 1、有效字数 nw8 2），上行带 14 bit 侧带头（VC 2、类别 3、末标记 1、nw8 2、归约属主号 2、区域号 4）；不带地址；掩码 1111 为四核多播，单个 1 为单播。一拍 4 道各发一个 flit。〔按 56 号 §5.1〕
- 四个 VC：下行 VC0 重放（类别 0 段片重放、1 灌入）、VC1 数据（类别 0 K / V、1 残差 / 特征行、2 AB 直写、3 PS 读回、4 Draft 分布）、VC2 响应（类别 0 R-hub 归约值、1 HUB-SYNC 回送的标量，原 1 bit 类型位是类别字段的一个取值）、VC3 控制（类别 0 消息，载荷首字节为消息类型）；上行 VC0 窄口（类别 0 录取位图、1 区块位图、2 lo 读集位图、3 K 切分判决、4 标量）、VC1 数据（类别 0 区域写、1 环写）、VC2 部分和、VC3 控制。控制 VC 源端严格优先。〔按 56 号 §5.1〕
- 信用：VC0 / VC1 按（核, VC, 道）计（绑定 L2 象限道，一道停收不挡其他道）；VC2 / VC3 按（核, VC）计一个共享池，hub 对共享池 VC 每核每拍至多发 1 flit；初始信用等于落地深度；信用经链路束内的侧带单拍脉冲返还。〔按 56 号 §5.3 / §5.4〕
- 有效性语义：链路层只说"本拍前 nw8 个 8 B 字有效"，不设逐字节有效位；元素语义由命令层绑定的载荷格式描述（SFD）与段头自定界；写使能由接收方按 nw8 生成到 bank 字粒度。〔按 56 号 §0.2〕
- 约束口宽：一个位点的 D-40 需求上限，q/k/v、o 为 128 B/拍，down 再扣数据 VC 保底份额。阈值套在编译期保证需求不超约束口宽，硬件不降档。
- 位点与 barrier：一层里一次矩阵乘为一个位点；位点边界由"位点完成汇总 → GO 广播"同步，位点控制命令在 GO 后 1 拍生效。
- 列表环：L2 固定区里的环形列表，共 9 个（录取并集、lo 读集、TOPK 列补算、接受路径、键号、重算、掩码镜像、区块列表、S 列表；接受路径列表环计入，与 L2 SRAM 篇 §4.3.1 一致；S 列表环为

LOSS 归并的 dH 支撑集 S 列表，MAE_ENG 只按列表 gather〔按 57 号 B-26〕），写者是各核或 HUB-ATT，写入一律经单写口，读者是 MAE 的引擎；上行侧带头的 4 bit 区域号在环写时为环号。〔按 54 号附录 B-CH-06 改〕

- 区块位图：区块搜索选出的 KV 区块集合，一位代表一个区块（参考 128 key）。

1.5 六种调用里 HUB NoC 各做什么

- Prefill：q/k/v 与 o 的激活多播重放（约 120 / 100 B/拍）、gate/up K 切分的 K 片分发与判决广播、down 部分和溢出写与读回、attention 的录取位图 OR 与区块位图 OR、层入口标量合并、每层 5 个位点 barrier。
- Decode：Verify 的单节点退化，CC0 单播重放。
- Proposal：CC0 单核重放；训练开启时 $\mathrm{d}\tilde{g}$ / $\mathrm{d}\tilde{u}$ 环单播与 Draft 梯度范数平方合并（合并值送 OPT 执行核，按用户 10-22 裁定改，CHANGELOG_V1.4 §2）；训练权重不经 hub，由 NI 经 SDN 多播直送训练核〔按 R50-5 改〕。
- Verify：调用开始时节点档表、祖先掩码块、父槽表、Batch 行表、Draft 分布与随机数（M55 向量路径）的分发，片上建树时只分发祖先掩码块与父槽表到 attention 参与核、节点档表到帮手核；CC0 单核重放与部分和读回；帮手核的 Q / K / V 单播；2–3 核 attention 的位图 OR；LM Head 属主核的列表、结果记录与树记录组写入；调用内改写档表的同步。生成循环每轮重复以上步骤，不经 M1〔按用户 10-24 裁定改，57 号 R57-01 / R57-02〕。
- Target 独立训练：OPT 写回与训练状态回写经单写口、梯度范数合并；权重由 NI 直读、经 SDN 多播到前向重算核与训练核，不经 hub〔按 R50-5 改〕。

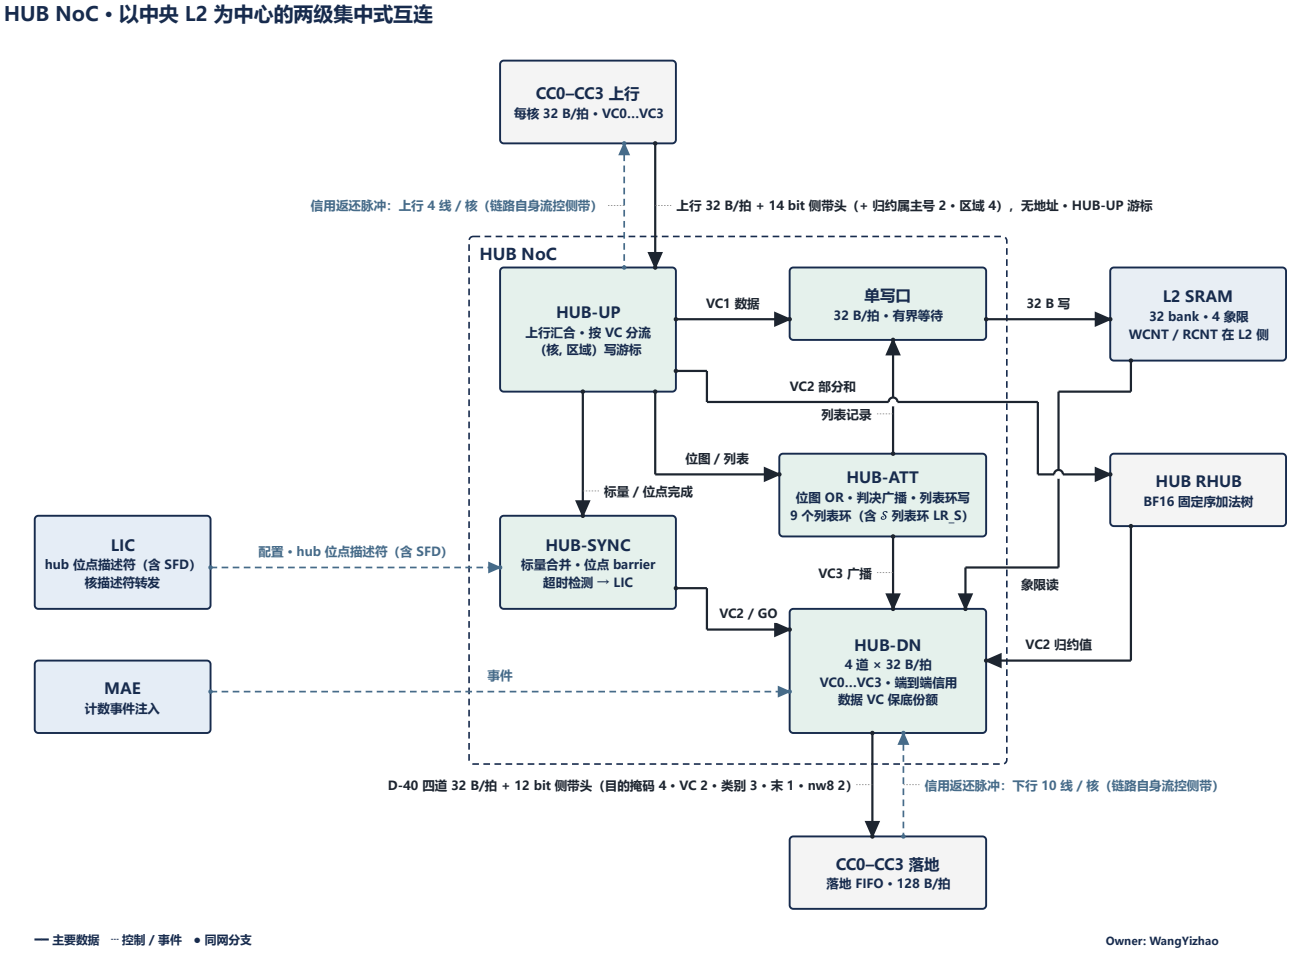
2 子单元分工

- HUB-DN（下行）：每道 1 个 L2 象限读引擎与 $N_{\mathrm{grp}}/4$ 个 token 游标，按段交错重放（段片切分按 hub 位点描述符里该流 SFD 的元素位宽 w 算段长，56 号 §2.4），按 32 槽加权窗口给数据 VC 保底份额，控制 VC 严格优先，VC0 / VC1 按（核, VC, 道）计信用、VC2 / VC3 按（核, VC）共享池每核每拍至多 1 flit；为每个在途读单位记"未返还目的数"，末标记 flit 全部目的返还即读完成、报 L2 侧 RCNT。输入来自 L2、R-hub、HUB-ATT、HUB-SYNC、LIC 与 MAE 事件。〔按 56 号 §5.3 / §5.5 / §6.2〕
- HUB-UP（上行汇合与单写口）：每核 4 VC 独立源队列与 hub 入口信用；数据类经单写口落 L2，写 L2 的地址由 HUB-UP 按 hub 位点描述符给的（核, 区域）基址、长度与回绕生成游标（上行 flit 不带地址，同一区域写序等于到达序，每核约 16 个 21 bit 游标【一阶推导】）；VC2 部分和分流到 R-hub；VC0 位图与判决结果、VC1 中区域号为环号的列表与结果记录分流到 HUB-ATT；VC0 标量与 VC3 控制分流到 HUB-SYNC。单写口 32 B/拍、有界等待、无固定优先。〔按 56 号 §5.2〕
- HUB-ATT（位图、列表与广播）：按（层, kv 头, 64-key tile）收齐参与核录取位图后按位 OR；按（层, kv 头, 查询波次）收齐区块位图后 OR，区块并集写区块列表环、同时按参与核掩码经 VC3 广播；训练多核时按（位点, 列块）OR lo 读集；把各核上行的列表记录与结果记录按环号送单写口，维护各环写指针与满标志（写完成计数在 L2 侧）；把 R-hub 归约属主核的 K 切分判决结果按参与核掩码送 VC3。
- HUB-SYNC（标量与控制）：标量合并、位点 barrier 计数与 barrier 超时检测上报；经 hub 控制口与 LIC 交换 hub 位点描述符与 GO。写完成 / 读完成计数器移到 L2 侧（L2 SRAM 篇），调用级计数窗与看门狗归 LIC。〔按 56 号 §6.2；按 57 号 B-14 / B-20〕

共享资源：4 道与其信用、单写口、控制口、信用返还侧带（下行每核 10 根、上行 hub → 每核 4 根，四核 56 根）。两级集中式的好处是跨核功能都在中心一处完成、核间无直连；代价是单写口与 D-40 口宽成为全局约束，由编译期的阈值套与分区表保证不超。

3 与周围怎么连、怎么配合

3.1 连接



图中左列是上行与控制输入：四核上行（每核 32 B/拍、4 VC，14 bit 侧带头）、LIC（hub 位点描述符含各流 SFD、核描述符转发、barrier 配置）、MAE 事件注入；虚线框内是四个子单元（HUB-SYNC 只剩标量合并与 barrier）；右列是 L2（WCNT / RCNT 在 L2 侧区域表旁）、R-hub 与四核落地口；信用返还侧带与数据线同束画出〔图按 56 号重画，57 号〕。逐条接口如下：

- D-40 → 四核落地 FIFO（协议 B）：128 B/拍 = 4 道 × 32 B；端到端信用，初始信用 = 落地深度；flit 32 B + 12 bit 侧带头（目的掩码 4 + VC 2 + 类别 3 + 末标记 1 + nw8 2），不带地址，落点地址由核侧落地口按核位点描述符的区域基址加本地游标生成；信用经下行每核 10 根返还线（VC0、VC1 各 4 道，VC2、VC3 各 1）以单拍脉冲返还，往返预算 22 拍 = 前飞 ≤ 10 + 弹出 1 + 返还 ≤ 10 + 1。〔按 56 号 §5.1 / §5.2 / §5.4〕
- 训练核的权重不经 D-40：它与前向核共享同一次 DDR 读，由 NI 权重形态级处理后经 SDN 多播直送训练核 WB 的重排窗口（MAE_NI_INT 篇），hub 不为训练权重设发送表、份额或信用〔按 R50-5 改〕。

- D-40 VC1 数据 → 核落地：按类别字段分路——残差 / 特征行（类别 1）→ 后处理单元；Q、x 因子、$\mathrm{d}\tilde{g}$ / $\mathrm{d}\tilde{u}$（类别 2 AB 直写）→ AB；down PS 读回（类别 3）→ L1 PS 区（56 号 a18）；K / V（类别 0）→ NI 写缓冲 → WB；Draft 分布（类别 4）→ 采样状态区；32 B/拍/道，受数据 VC 份额约束；单播或多播，本核新 K / V 同样单播回自己。〔按 56 号 §5.1、57 号 B-42〕
- 表与调用记录装载 → 各核：阈值套（每套约 4.3 KB）进各核 SEL 阈值表与出口侧 keep 阈值（NLU 所需 $\ln \tau_{\mathrm{O3}}$ 由 LIC 随位点控制命令装入 NLU 标量寄存器，不经阈值装载通路；装载目标与 CTL 的阈值消费者表一致〔按 57 号 B-33〕）；节点档表（128 节点时 33 B）进各参与核 CTL 的待生效份（CTL 持当前 / 待生效两份，不直接进档 MUX〔按 57 号 B-17〕）；祖先掩码按 32 × 32 bit 的块（每块 128 B，128 节点 16 块）进参与核；父槽表（128 × 7 bit = 112 B）进属主核采样状态区；Batch 行表（每行 16 B，按组）进参与核；Draft 分布（单序列 0.8 KB，批 B 时为 B 倍）与随机数向量（M55 向量路径）进 LM Head 属主核〔按用户 10-22 去定容改；按用户 10-24 裁定改，57 号 R57-01 / R57-03〕；Draft 分布走 VC1，随机数、父槽表、TAG 表、祖先掩码块、节点档表与 Batch 行表走 VC3，阈值套走 VC3 或 hub 配置口。片上建树时父槽表、节点档表与 Draft 分布已在 LM Head 属主核，hub 只分发祖先掩码块与父槽表给 attention 参与核、同步节点档表给帮手核。
- 四核上行 → HUB-UP（协议 B）：32 B/拍/核，4 VC 各自独立源队列与 hub 入口信用；14 bit 侧带头（VC 2 + 类别 3 + 末标记 1 + nw8 2 + 归约属主号 2 + 区域号 4），不带地址；上行 hub → 每核 4 根返还线（每 VC 1 根，VC2 的信用即 R-hub 入口 FIFO ≥ 16）；每核入口深度建议 VC0 4、VC1 12、VC3 2（VC2 用 R-hub FIFO），合计每核 18 flit = 576 B，按 22 拍往返预算。〔按 56 号 §5.1 / §5.4〕
- HUB-UP → L2：单写口 1 个，四核合计 32 B/拍；写地址由 HUB-UP 按（核, 区域）游标生成，环写沿用 HUB-ATT 的环写指针；写完成由 L2 写仲裁计入 L2 侧 WCNT（该单位最后一个 32 B 行落 bank 即计 1）。〔按 56 号 §5.2 / §6.2〕
- L2 象限读引擎 → 道：象限 n_{q} → 道 n_{q}，32 B/拍/道；读完成由 HUB-DN 的"末标记 flit 全部目的返还"配对后报 L2 侧 RCNT。
- HUB-UP → R-hub：上行 VC2 部分和，侧带头带 2 bit 归约属主号；每核入口 FIFO ≥ 16 条，FIFO 满经 VC2 信用反压到核出口队列（细节在 HUB RHUB 篇）。
- R-hub → D-40 VC2 → 归约属主核落地：MXFP6 g32 归约值 25 B + 16 bit 组序号；下行 VC2 侧带头类别 0 标为部分和（类别 1 为 HUB-SYNC 标量）；VC2 为（核, VC）共享池、每核每拍至多 1 flit，核侧 VC2 落地 FIFO 单写入；在飞表归 LAND，消费者 NLU（56 号 a20）。〔按 56 号 §5.1 / §5.3；按 57 号 B-43〕
- HUB-ATT 入口与出口：入为各核上行 VC0 的最终录取位图（每 64-key tile 64 bit，Verify 已含祖先掩码）、区块位图、lo 读集位图与 K 切分判决结果（每列 2 bit）；出为经单写口写固定区的列表记录，以及经 VC3 的判决广播与区块并集广播。列表记录头的条数按"计数 − 1"编码，有效条数 ≤ 65535。
- LIC 控制口：hub 位点描述符入（含各流的 SFD：格式码、元素位宽 w、组大小、尺度放置、平面数、长度来源与计数，HUB-DN 段片切分与 R-hub 据此工作〔按 56 号 §2.1 / §10〕）、GO、合并结果与 barrier 超时上报出；核描述符经 VC3 转发；阈值配置读描述符给套号、基址与消费者掩码。
- barrier：各核 CCU 上行位点完成事件（带位点号与 n_{flit}），下行 GO；超看门狗门限时 HUB-SYNC 检测并上报 LIC（致命类错误由 LIC 收束，B-20）。
- 计数：hub 的性能计数（D-40 等待汇总、R-hub 入口满、信用停顿）按位点锁存，经 LIC 汇总到 CIF；调用级计数窗与看门狗在 LIC，不在 hub〔按 57 号 B-20〕。
- 计数门限口：MAE、HUB-DN 与 LIC 经 hub 中心内部的门限比较接口读 L2 侧的 WCNT / RCNT（hub 中心与 L2 同处一地，不算新链路），读者等写完成计数 $\geq n_{\mathrm{th}}$，写者按读完成计数水位。〔按

56 号 §6.2〕

- 标量合并 / 回送：核后处理单元 / NLU → 上行 VC0 → HUB-SYNC → D-40 VC2（flit 头标为标量）→ 核 VC2 落地口的标量抽头；批闭合梯度范数平方走同一通路，合并后只单播该模型首个 OPT 执行核（由 hub 侧 SD 给出），交该核 NLU 算裁剪系数，不再送 LIC 或 CIF；FP32。〔按用户 10-22 裁定改，CHANGELOG_V1.4 §2〕
- MAE 事件注入：MAE → HUB-DN → VC3 → CCU（模板完成计数达门限等）；WB 槽释放事件经 hub 直达 MAE，不经 LIC。
- 训练核份释放事件：训练核 CCU 的重排窗口份释放事件（1 flit）经上行控制 VC 由 hub 直达 NI 的 SDN，作该核的资源信用（份；SDN 两层信用的第二层，56 号 §5.6），与 WB 槽释放事件同一通路；hub 不为训练权重设发送表、份额或信用（与 CCU_CTL 篇 §4.6.1 对应）。〔按 54 号 C54-05 改〕
- LM Head 属主核列表与结果写入：逻辑接口，不新增物理口；LM Head 属主核的 TOPK 列补算列表、接受列表、lo 读集、结果记录、片上建树的树记录组与 LOSS 归并的 S 列表经本核上行 VC1（类别 1 环写，区域号 = 环号）→ HUB-ATT → 单写口 → 固定区〔按 57 号 B-26；按用户 10-24 裁定改，57 号 R57-01〕。

3.2 谁来配置、什么时候生效

hub 位点描述符由 LIC 按（阶段, 层, 位点）下发，在 hub 内直达，随 GO 生效，内容按含义为：目的掩码与 D-40 发送表、部分和读回表、数据 VC 保底份额 w_D（4 bit）、R-hub 归约配置（使能、参与核、归约属主核）、位图 OR 与列表环配置（参与核掩码、kv 头 → 核映射、OR 粒度、Batch 段号）、判决广播映射、barrier 模式、HUB-UP 各（核, 区域）的写游标基址 / 长度 / 回绕，以及本位点各条下行流的 SFD（HUB-DN 按其中的元素位宽 w 切段片；R-hub 用其组大小与尺度放置）〔按 56 号 §2.1 / §5.2〕。核描述符经 VC3 单播进各核 CCU 的控制命令寄存。阈值套在调用开始由 LIC 选套、HUB-DN 读固定区装入；调用输入的分发在调用输入区写完成计数到齐后由 LIC 下发。

3.3 典型场景里的配合次序

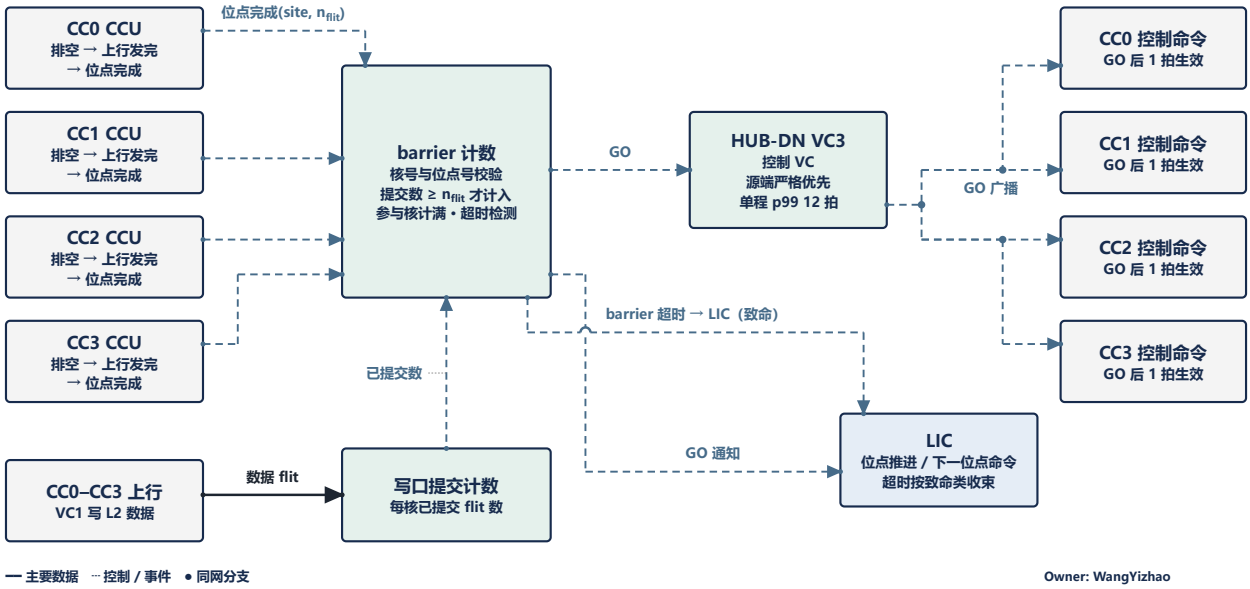
(a) Prefill q/k/v 的激活重放。chunk 池的写完成计数到门限后，四道读引擎按组内位置读出本道 token 的紧凑记录，按段交错、目的掩码 1111 多播；各核落地 FIFO 按信用收；需求约 120 B/拍，留约 8 pp 稀疏率余量；最后一个目的核返还信用后计读完成，下一组可覆写。

(b) attention 录取并集。各核 SEL 判出本核最终录取位图，经上行 VC0 进 HUB-ATT；按（层, kv 头, tile）等齐参与核后按位 OR，写一条录取并集记录经单写口进列表环、写完成计数加一；IGE 据此取 K lo / V，多播给各核；每个 query 的 P×V 仍只用本行录取位。时延须被下一 tile 的粗算盖住。

(c) K 切分判决广播。R-hub 把归约值回送归约属主核；归约属主核 SEL 判出每列 2 bit 结果，经上行 VC0 进 HUB-ATT，按参与核掩码经 VC3 多播给同组其他核的列片 Router；F 判决链 60–75 拍。

(d) 位点 barrier。

HUB NoC • 位点 barrier：位点完成汇总 → GO 广播



各核停止发射、出口队列排空、上行发完后发位点完成事件（带位点号与本核本位点经单写口的数据 flit 数 n_{flit}）；HUB-SYNC 只在该核已提交写口的 flit 数 $\geq n_{\text{flit}}$ 时计入；参与核计满后经 VC3 广播 GO 并通知 LIC；各核的位点控制命令在 GO 后 1 拍生效。总时延约 $2 \times (12 + 11) = 46$ 拍。区域交接同时按读完成 / 写完成计数进行，不等 barrier。

(e) 区块搜索（Prefill，新）。各核 SEL 对区块打分并选出本核区块位图（强制集已在核内置位），经上行 VC0 进 HUB-ATT；按（层, kv 头, 查询波次）OR 成区块并集后同时做两件事：写区块列表环（MAE 按列表只读选中区块的 K 高平面），并经 D-40 VC3 按参与核掩码广播给各参与核 CTL（展开 tile 序列）；之后照常走 (b)。

4 需求条款

4.1 拓扑、VC 与信用

4.1.1 两级集中式拓扑

拓扑为以中央 L2 为中心的两级集中式互连；D-40 是全部下行；上行复用核 → 中心链路；R-hub 与 HUB-ATT 挂 hub 中心，LIC 作 hub 控制客户；hub 上不挂集中判决单元与集中采样单元；NoC 之外不另拉链路，核间无直连。〔原 REQ-L2H-09′〕

4.1.2 四 VC 与控制优先

上下行各 4 VC，用途按 §1.4；控制 VC 源端严格优先，落地 ≥ 2 flit（VC3 按（核, VC）共享池计，2 flit 合法，建议 4）；控制单程 p99 ≤ 12 拍。〔原 REQ-L2H-10；按 56 号 §5.3〕

4.1.3 端到端信用：两种粒度

VC0 重放与 VC1 数据绑定 L2 象限道（象限 n_{q} → 道 n_{q}），信用按（核, VC, 道）计，一道停收不挡其他道；VC2 与 VC3 的发送方（R-hub、HUB-ATT、HUB-SYNC、LIC）挂 hub 中心、flit 本不绑定道，信用改按（核, VC）计一个共享池，hub 对共享池 VC 每核每拍至多发 1 flit，核侧这两个 VC 各只需一个单写入的落地 FIFO、不需 4 入 1 出合流。发端初始信用 = 落地深度（由 L1 集成篇定，建议值）：重放 VC $\geq 4\times$ RTT，RTT 22 拍时 88 flit 按道 4 份；数据 VC 每道 6、每核 24 flit（原约 20，数据 VC 保底 $w_D = 8$ 槽时差约 9%）；VC2 每核 ≥ 8 flit；VC3 每核 ≥ 2 flit、建议 4。按（核, VC, 道）计时控制 VC 每核至少要 4 flit、与"≥ 2 flit"不能同时成立，改共享池后消除。信用由接收方每弹出一个 flit 在下一拍以链路束内的侧带单拍脉冲返还（下行每核 10 根、上行 hub → 每核 4 根，四核 56 根），不用带内返还（避免上下行信用的跨方向环依赖）；返还线与数据线同级寄存，到达发送方的下一拍才可用。往返预算【建议值，阶段二仿真复核】：D-40 $t_{\mathrm{rt}} = t_f + 1 + t_r + 1 = 22$（前飞 $t_f \leq 10$、返还 $t_r \leq 10$）；上行与 SDN 同按 22 拍；任何一段实测超出时按 $C_{\mathrm{cr}} \geq \lceil t_{\mathrm{rt}} \cdot r \rceil$ 同比加深落地深度，不改协议。〔原 REQ-L2H-11；按 56 号 §5.3 / §5.4；D51-04 / D51-05 / D51-08 落定〕

4.1.4 上行 VC 隔离

上行 4 VC 各有独立源队列与 hub 入口信用；写口拥塞不得反压窄口与控制 VC。每核入口深度建议 VC0 4、VC1 12、VC3 2（VC2 用 R-hub 入口 FIFO），合计每核 18 flit = 576 B、四核约 2.3 KB，在现行入口缓冲约 4 KB 之内；VC1 在此深度下每核可达约 17.5 B/拍【推导】。〔原 REQ-L2H-12；按 56 号 §5.4〕

4.1.5 挂 hub 单元选最短道，共享池 VC 每核每拍至多 1 flit

R-hub、HUB-ATT、HUB-SYNC 与 LIC 的下行 flit 选当拍排队最短的道；VC2 / VC3 信用按（核, VC）共享池计，hub 对同一核的 VC2、VC3 每拍各至多发 1 flit，"选最短道"因此不再与信用绑定冲突；VC2 / VC3 的带宽需求每核只有 3.5–5.8 B/拍与数 B/拍，每拍 1 flit = 32 B/拍远够。〔原 REQ-L2H-13′；按 56 号 §5.3〕

4.1.6 flit 侧带头、类别字段与落地深度

flit 不带地址，核侧与 hub 要靠同一份侧带头定义分路。要求：

- 下行每道每拍 12 bit：目的掩码 4（1111 为四核多播）、VC 2、类别 3、末标记 1、nw8 2（1–4 个 8 B 字）。类别按 VC 解释：VC0 0 段片重放（→ 段片解析器）、1 灌入（→ AB 写口，含 K 切分 K 片）；VC1 0 K / V（→ NI 写缓冲）、1 残差 / 特征行（→ 后处理单元）、2 AB 直写（Q、x 因子、$\mathrm{d}\tilde{g}$ / $\mathrm{d}\tilde{u}$ 环）、3 PS 读回（→ L1 PS 区）、4 Draft 分布（→ 采样状态区）；VC2 0 部分和（R-hub 归约值 → AB 停放区 + 在飞表）、1 标量（HUB-SYNC → 标量抽头）；VC3 0 消息（类型在载荷首字节）。
- 上行每核每拍 14 bit：VC 2、类别 3（VC0 0 录取位图、1 区块位图、2 lo 读集位图、3 K 切分判决、4 标量；VC1 0 区域写（经单写口）、1 环写（经 HUB-ATT）；VC2 0 部分和；VC3 0 消息）、末标记 1、nw8 2、归约属主号 2（VC2，K 切分部分和的属主由 CCU_CTL 给出）、区域号 4（VC1：区域写时索引 HUB-UP 游标表，环写时为环号）。
- 源核号与道号由物理链路隐含，不占字段；类别字段取代原下行 VC2 的 1 bit 类型位，旧位是类别字段的一个取值，语义不变。

- 地址的生成：下行落点地址由核侧落地口按核位点描述符的区域基址加本地游标生成（AB 写口每 token 一个写游标，token 序号取自记录头；K / V 转接按位点给的区与游标）；上行写 L2 的地址由 HUB-UP 按 hub 位点描述符给的（核, 区域）基址、长度与回绕生成游标，同一区域写序等于到达序，环写沿用 HUB-ATT 的环写指针；游标代价每核约 16 个 21 bit 计数器【一阶推导】。SDN 例外：它带 NI 给出的落地地址（MAE_NI_INT 篇）。
- L1 落地口的 VC2 深度 ≥ 8 flit，作为 VC2 共享池的初始信用（与重放 VC ≥ 88、数据 VC 24、控制 VC ≥ 2 flit 并列，由 L1 集成篇定，建议值）。
- 多播信用：一个 flit 的目的掩码含 n_{dst} 个核时，发送方只在 n_{dst} 个计数全部 ≥ 1 时才发，各减 1；读完成等于该单位末标记 flit 在全部目的都已弹出、信用都已返还，HUB-DN 为每个在途读单位记"未返还目的数"；正确性前提是各目的落地深度相同。

〔新，按对齐审查 §1.D（flit 头）与第 66 行；按 56 号 §5.1 / §5.2 / §5.5 改写〕

4.1.7 链路层有效性与协议断言

链路层只认 32 B 拍与 8 B 字：每拍的字段是 vld、last（末标记）、nw8（本拍有效字数，非末拍恒为满），不设逐字节有效位；元素语义由命令层绑定的载荷格式描述（SFD）与段头自定界，只有格式感知端点（HUB-DN 段片切分、HUB-ATT、R-hub、核侧 LAND 与 NI 写缓冲等）解析它，hub 单写口、D-40 与上行链路本身、L2 存储只搬运字。一个单位不在拍中间结束后再接另一单位的字，下一单位从下一拍的字 0 开始；段片流例外（整条流是一个单位，段片按字节背靠背，保持道实收 ≥ 31 B/拍）。协议不重传；以下为断言级检查、各一个比较器、报致命类错误事件（LIC 收束）：信用计数下溢或超初值；落地 FIFO 写入时已满；末标记 flit 的多播返还不配对；共享池 VC 同核同拍收到 2 flit；位点号不匹配的位点完成；barrier 超看门狗。流量性停顿（信用为 0、SDN 停发、R-hub 入口满、$w = 8$ 超口降速）照现行按位点计数，不报错。〔新，按 56 号 §0.2 / §3.2 / §5.8；错误分级按用户 10-24 裁定，57 号 R57-05〕

4.2 D-40 下行

4.2.1 口宽固定与只传紧凑记录

D-40 口宽固定 128 B/拍 = 4 道 × 32 B，flit 32 B 带 12 bit 侧带头（§4.1.6）。激活在 D-40 上只传紧凑记录（每段 E8M0 1 B + keep 位图 4 B + F 标志 $\lceil k_s/8 \rceil$ B + 值区；值区元素位宽 w 按位点为 6 bit（MXFP6，默认）或 8 bit（MXFP8 E4M3，兼容性预留，整体集成篇第 5.3.9 条），w 随 hub 位点描述符里该流的 SFD 给出，HUB-DN 按 w 算段长切段片〔按 56 号 §2.4、57 号 B-07〕），不传 BF16 激活。位宽取 8 时只有值区 +33%（段头与 F 标志不变），Qwen Prefill q/k/v 约 120 → 143 B/拍超口、MiniCPM 约 100 → 121 B/拍不超口【推导，56 号 §7】，口宽仍固定 128 B/拍，超口的链路按信用自然停顿并计数，不加口、不加专用缓冲，由算法侧按代价部署〔按 57 号 B-08〕。〔原 REQ-L2H-14、原 REQ-L2H-15〕〔按用户 10-24 裁定改，55 号 D55-03〕

4.2.2 超口时不降档

需求超过约束口宽时 D-40 吞吐成为瓶颈、阵列等数据；硬件不加口宽、不降档、不主动放慢阵列。违例计数 = 各核段片解析器因重放落地 FIFO 为空而等待的拍数（扣除位点首灌，由核侧计），hub 按位点汇总；"计数 ÷ 位点拍数"越阈值才报阈值不可行事件；需求低于口宽时的重放信用停顿是正常流控，不作判据。〔原 REQ-L2H-16〕

4.2.3 N 切分的子记录重放

I 模式 N 切分时每核独立写一条子记录，本 token 在 L2 共 4 条。重放先发 4 个 8 B 子头，再按自然段号轮转发段片（段长 $5+\lceil k_s/8\rceil+\lceil w\,k_s/8\rceil$ B 按 SFD 的 w 现算，最长段片 $w=6$ 时 33 B、$w=8$ 时 41 B）；接收端 tokmax 取最大、长度求和，AB 内仍按 token 连续；4 条的结束标志全到才放行，空段照发，自定界与信用合同不变；整条段片流是一个传输单位，段片在流内按字节背靠背排列，末 flit 以 nw8 给出有效字数。每 token 4 个子游标，每道管理本道 $N_{\mathrm{grp}}/4$ 个 token 的 4 条子记录；每游标 32 B 残字，全芯片残字 RF 约 4 KB；每 flit 平均 bank 读约 1 次，道实收 ≥ 31 B/拍。〔原 REQ-L2H-17、原 REQ-L2H-18；按 56 号 §2.4 / §3.2〕

4.2.4 同流灌入与 K 片分发

gate/up 下一组灌入截取 gate-hi 重放的同一股流，不另起数据 VC 流；K 切分的本 K 片经重放 VC 灌入（1×4 单播、2×2 同片多播）。〔原 REQ-L2H-19〕

4.2.5 数据 VC 保底份额

每道一个 32 槽加权窗口，数据 VC 保底 w_D 槽（$0\leq w_D\leq 8$），其余槽重放优先，某 VC 无流时其槽让出；控制 VC 始终最优先。w_D 按位点由 hub 位点描述符给出、随位点控制命令生效，取

$$w_D=\left\lceil\frac{\text{读回需求（B/拍）}}{4}\right\rceil,\qquad \mathrm{cap}_{\mathrm{down}}=128-4\,w_D,$$

Qwen $\mathrm{cap}_{\mathrm{down}}$ 为 120 到 108 B/拍、MiniCPM 为 124 到 112 B/拍。下行 VC2（R-hub 归约值回送与 HUB-SYNC 标量回送）在 32 槽窗口里不单设槽，按数据 VC 的保底份额 w_D 走、与数据 VC 共用；K 切分位点的 w_D 取值须计入 R-hub 回送的需求。〔原 REQ-L2H-20；按 54 号附录 B-CH-09 改〕

4.2.6 部分和读回

down 部分和溢出的读回经 D-40 数据 VC 单播：hub 按读回表按序发流、受落地信用流控，核不发请求；发前须写完成计数达门限；同一部分和 tile 只有一份活拷贝；读回份额从 down 约束口宽中扣除，不开独立 L2 读口。〔原 REQ-L2H-21〕

4.2.7 训练权重不经 hub

训练权重不再经 hub 分发，见 MAE_NI_INT 篇权重形态级。原 hub 训练权重取段通路（J′ 取段）取消〔按 54 号 C54-26 改〕；按 K 组分核、热 / 非热 K 组分队列与所载平面（只读 hi、按读取列表读 lo、稠密全码）的规则随之移到 MAE_ENG 篇的请求顺序与 MAE_NI_INT 篇的 SDN 多播与权重形态级。〔原 REQ-L2H-22、原 REQ-L2H-51，按 R50-5 撤销〕

4.2.8 表与调用记录装载

LIC 在调用开始从阈值套库取本调用选用的一套，经 VC3 或 hub 配置口装进各核 SEL 阈值表与出口侧 keep 阈值（NLU 的 $\ln\tau_{\mathrm{O3}}$ 由 LIC 随位点控制命令装入，不经本条通路，B-33），每核片上只存一套。Verify 调用把调用输入区的节点档表送各参与核 CTL 的待生效份（B-17）、祖先掩码按 32 × 32 bit 块送参与核、父槽表送属主核采样状态区，均走 VC3；节点数超过 32 时按组分发（R57-03）；片上建树时这些表由 LM

Head 属主核 SMP 产出并经上行写 L2 调用输入区，hub 只分发给 attention 参与核与帮手核（R57-01）；Batch 调用把行表按组送参与 attention 的核与线性位点核（VC3）；拒绝采样取 M55 向量时把 Draft 分布与随机数向量单播属主核采样状态区：Draft 分布走 VC1（类别 4，避免长时间占用控制 VC），随机数与父槽表、TAG 表、祖先掩码块、节点档表一样走 VC3（承载量小、要严格优先；按对齐审查第 7 行）；热度份额、x 因子、Q / K / V 走数据 VC。装载完成计数到齐前，第一个用阈值或档表的位点不得放行。〔原 REQ-L2H-23'，按 R46-09 / B-01 改；按用户 10-24 裁定改，57 号 R57-01 / R57-03；按 57 号 B-17 / B-33〕

4.2.9 调用内改写档表的同步

旁路判别器可在调用内改写节点档表（只在 0 / 1 / 2 之间）。LM Head 属主核改写本核档表后，若 attention 也按档分级，新档表经 LM Head 属主核上行 VC3 进 hub、由 D-40 VC3 按参与核掩码多播到 attention 帮手核，在下一个位点边界与 LM Head 属主核同时生效；同步完成计数到齐前该位点不放行。〔新，R46-01；上行 VC 按对齐审查第 22 行〕

4.2.10 位点内无栅栏

一个位点内若每组都等四核对齐，快核会空等慢核。位点内 barrier 模式为"无"时不设栅栏，四核按"一组余量"滑动，重放按全部参与核的池空闲标志发起。D-40 上不再有训练权重流，所以原"训练权重取段与 Prefill gate/up 重放不同时占 D-40"的互斥规则与相应的错误事件一并撤销；训练窗口里 D-40 的份额只在重放 VC、数据 VC（含 $\mathrm{d}\tilde{g}$ / $\mathrm{d}\tilde{u}$ 环单播）与控制 VC 之间按 §4.2.5 分配。〔原 REQ-L2H-24；原 REQ-L2H-49 按 R50-5 撤销〕

4.3 上行与单写口

4.3.1 单写口与两条分离

hub → L2 只有 1 个写口，四核合计 32 B/拍；NI 写分叉、PIN 写与 MAE 拷贝不经它。R-hub 入口 FIFO 与写 L2 路径分离，部分和不排在写口队列里。停放类状态不经写口进 L2；down 部分和溢出写属部分和自身的读改写流，允许。〔原 REQ-L2H-25、原 REQ-L2H-27、原 REQ-L2H-28〕

4.3.2 写口有界等待

写口仲裁有界等待、无固定优先：$r_{\mathrm{load}} = 9$ B/拍/核加压时各核平均写等待不劣于轮转基线（四核平均 103 到 105 拍），核间差小于固定优先。〔原 REQ-L2H-26〕

4.3.3 上行载荷格式

输出记录 = 归约完成的部分和在后处理单元一次舍入成 MXFP6（o / down 的量化点在残差加之后）、经出口侧打包成紧凑记录；k / v 投影按量化合同量化后上行；未完成归约的部分和以 BF16；反传归约完成、在算子之间流动的 dX、dP、dH 等以 MXFP6（后处理单元或 QNT 已量化），dK / dV 跨 chunk 累加与跨块梯度累加面以 BF16〔按用户 10-23 裁定改，原"反传 dX 等以 BF16"〕。attention 的 O / m_{run} / l 与分数驻留状态停本核 L1；需要跨核合并的 lse 标量经 HUB-SYNC。〔原 REQ-L2H-29〕

4.3.4 窄口不载评分

上行 VC0 窄口不承载逐列判决评分（如 gate 评分每 token 每位点 9728×2 B）与 LM Head 粗 logits；只承载录取 / 区块 / lo 读集位图、每列 2 bit 的 K 切分判决结果与标量。评分在产生它的核内比较并原地消费。〔原 REQ-L2H-59〕

4.3.5 列表环与结果区的写者

列表环与结果区的写者是各核，写入由 HUB-ATT 统一执行：录取并集与区块列表由 HUB-ATT 在 OR 之后写；TOPK 列补算列表、接受列表、属主核结果区、片上建树的树记录组与 Verify 单核的 lo 读集由 LM Head 属主核经本核上行 VC1 送入；键号与重算列表由产生它的核送入；LOSS 归并的 dH 支撑集 S 列表由链首训练核送入 S 列表环（MAE_ENG 只按列表 gather，B-26）；训练行掩码镜像由各核送本核行。上行 flit 以侧带头的类别 1（环写）与 4 bit 区域号（环号）标识，HUB-ATT 按环号维护写指针与满标志，全部经同一单写口，写完成由 L2 侧 WCNT 计；类别 0（区域写）的结果区与其他区域由 HUB-UP 按（核, 区域）游标生成地址；写口总份额与 V1.0 相同。嵌入取数列表随调用输入经 M1 → NI-L2C 落调用输入区，不经单写口，IGE 从 L2 读（与 L2 SRAM 篇 §4.3.3 一致）。〔原 REQ-L2H-60；按 54 号 C54-11 改；按 56 号 §5.1 / §5.2；按 57 号 B-26；按用户 10-24 裁定改，57 号 R57-01〕

4.3.6 环满停写与按计数放行

列表环满或写口忙时写者停写，不丢记录，计入"列表环满"异常计数；写者覆写某单位前等该单位读完成；读者只按写完成门限放行，事件不作数据就绪信号。〔原 REQ-L2H-61〕

4.4 HUB-ATT

4.4.1 录取位图 OR

对每个（层, kv 头, 64-key tile），全部参与核的最终录取位图到齐后按位 OR，写一条录取并集记录（64 bit 位图，对应读 K lo 64 B/key 与 V 129 B /（key, kv 头））；参与核集合按参与核掩码与 kv 头 → 核映射（Prefill 4 核按 query 分核；Verify Qwen 2 核、MiniCPM 3 核）。〔原 REQ-L2H-62〕

4.4.2 OR 只依赖输入位图

OR 类输出（录取并集、区块并集、多核 lo 读集）只依赖输入位图，与到达次序、核号和核内判别方式无关：录取模式为阈值、TOPK、阈值加封顶或全录取时输入格式相同，HUB-ATT 只合并最终位图，并集后不再封顶；每（行, q 头）录取数上限由核内保证；sink、局部窗口、对角块等强制集在核内已置位，HUB-ATT 不另加。〔原 REQ-L2H-63，按 R46-02 补〕

4.4.3 并集写入的时延

从最后一个参与核位图到达到录取并集写完成计数递增的时延须被下一 tile 粗算盖住；键号列表与录取并集共用单写口与固定区时仍须满足；MAE 发 K lo / V 读不等录取并集。〔原 REQ-L2H-64〕

4.4.4 lo 读集

Verify 时 LM Head 与线性位点在 LM Head 属主核单核执行，lo 读集（q/k/v、o 为 F 行并集，gate/up 为 F 列并集，down 为 F_D 行并集（按 down 的输入通道），只含 TAG ≠ 3 节点）由 LM Head 属主核本地形成后经上行写 lo 读集列表环，不经 OR；训练读 lo 有效且多核产出 F 结果时，各核本核 lo 读集位图经上行 VC0 进 HUB-ATT 按（位点, 列块）OR 后写入。两种情况下每（位点, 列块）的记录都须在 MAE 对该列块发 lo 读请求之前写入并计数。〔原 REQ-L2H-65〕

4.4.5 K 切分判决广播

K 切分归约后的 gate 与 F / C / Z 判决由归约属主核产生，每列 2 bit 结果经归约属主核上行 VC0 进 HUB-ATT，按参与核掩码经下行 VC3 多播给同组其他核，不进 L2；字节约 0.5 B/拍/核；F 链首核 q99 预算 60–75 拍。上行取 VC0 与录取位图同列为窄口负载，并据此核过 F 链时延（按对齐审查第 21 行确认）。〔原 REQ-L2H-66〕

4.4.6 合并缓冲定容

HUB-ATT 的合并缓冲按（在飞 tile 数 × 本层 kv 头数）定容，每项 64 bit 位图 + 参与核到齐位；区块位图按（在飞波次 × kv 头）另计，每项至多 512 bit；hub 内按组计的结构按 32 定容（每核一次驻留的 token 组），按本调用的组数与 N_{tree}（≤ 128）工作，不设 $B \times N_{\text{tree}}$ 上限〔按用户 10-24 裁定改，57 号 R57-03〕；TAG = 3 节点的录取行在核内已置零，HUB-ATT 不按 TAG 过滤。〔原 REQ-L2H-67，按 R46-02 补〕

4.4.7 hub 内无 logits 通路

hub 内不设候选、粗 logits 与精确 logits 的直达通路：LM Head 的 TOPK 项在 LM Head 属主核流式选出，精确 logits 在本核回填，只有 TOPK 列补算列表与结果记录经单写口进列表环与属主核结果区。〔原 REQ-L2H-68′〕

4.4.8 TOPK 列补算列表

TOPK 列补算列表每个位置 / 树节点一条记录，载荷为该节点 TOPK 项的词号（3 B/项，LM Head 属主核按升序排好，条数 = 有效项数 $\le K_{\text{top}}$），序号 = 槽号或位置号；记录不跨节点合并或去重；环长度由分区表按本调用的节点数与 K_{top} 给出（L2 SRAM 篇），按计数循环写入，环满停写反压；不补算 lo 的调用不写。〔原 REQ-L2H-73，按用户 10-22 去定容改〕

4.4.9 训练行掩码镜像

训练行掩码镜像（S1–S5）由各核写本核行：S1–S3 来自本核出口侧 keep / F 位图，S4 / S5 来自本核 gate / FCZ / F_D 结果；每个掩码行块（默认 8 行）一条记录，经本核上行 VC1 → 单写口 → 固定区镜像环 → MAE → DDR；镜像的写完成并入特征完成的放行条件；稠密训练时不写；环满按"列表环满"反压。〔原 REQ-L2H-69〕

4.4.10 区块位图 OR，粒度可配

区块搜索（方向一两段式框架）要求 KV 区块集合在 GQA 组内取并集，再只读选中区块的 K 高平面。HUB-ATT 按（层, kv 头, 查询波次）收齐参与核的区块位图后按位 OR 成区块并集，同时做两件事：写一条区块列表记录进区块列表环并计数（MAE 读）；经 D-40 VC3 按参与核掩码广播区块并集（各核 CTL 收，据此展开 tile 序列），两路出自同一条并集记录，使 CTL 的 tile 序与 MAE 的读序同源（按对齐审查第 19 行）。位图一位代表一个区块，区块大小按位点可配（$64 \cdot 2^{e_{\mathrm{blk}}}$ key，$e_{\mathrm{blk}} = 0 \ldots 3$，参考 128 key），记录长度 $\lceil L_{\mathrm{ctx}}/\text{区块} \rceil$ bit，32K 上下文、64-key 粒度时至多 512 bit；与录取位图 OR 共用同一 OR 数据通路，只是位宽与记录头不同。Prefill 必须支持，Verify / Decode 可选。〔新，R46-02〕

4.4.11 Batch 的前缀 tile 与私有 tile

Batch 下每行可见 KV = 共享前缀段 + 本行私有段。HUB-ATT 的合并键加入段号：前缀段的 tile 对全部行、全部参与核取并集（同 Verify），一次读入、多播给各行；私有段的 tile 只合并持有该行的核的位图，不同行同一 tile 号的私有 tile 不合并；每条记录带段号，期望到齐数按该段的参与核掩码派生。〔新，B-02〕

4.5 HUB-SYNC 与控制原语

4.5.1 标量合并

HUB-SYNC 收上行 VC0 标量，按 token / 轮标签与参与核掩码配对，收齐后按类合并：$\sum x^2$ / $\sum |x\gamma|$ 求和经 VC2 回出口侧；F5 amax 取最大只回出口侧；lse (m_{run}, l) 按在线 softmax 状态规则合并回 NLU；批闭合梯度范数只收反向核，按各组参与核掩码派生期望数，分 Draft / Target 合并后经 D-40 VC2 标量抽头送该模型首个 OPT 执行核的 NLU（按用户 10-22 裁定改，CHANGELOG_V1.4 §2）；FP32 标量格式不变；第 0 层两标量离线存嵌入表，不经 hub；标量齐备条件独立于 N 切分四条子记录的写完成；配对表 ≤ 1 KB。〔原 REQ-L2H-38〕

4.5.2 写完成计数（计数器在 L2 侧）

每个活跃区域一个单调写完成计数；N 切分 token 须 4 个子记录都到齐才记一次；"写完成" = 该单位最后一个 32 B 行落 bank；读者按描述符门限等写完成计数 $\geq n_{\mathrm{th}}$。覆盖直写序、部分和溢出读回、列表环、属主核结果区、调用输入区、特征拷贝、OPT 写回、$\mathrm{d}\tilde{g}$ / $\mathrm{d}\tilde{u}$ 环与训练状态回写。计数器的存放与比较在 L2 侧区域表旁（L2 SRAM 篇），增量来自 L2 写仲裁，覆盖 hub 单写口、NI-L2C、NI-FORK、PIN 全部写者；hub 只经中心内部的门限比较接口读它。各区域的计数单位见 L2 SRAM 篇。〔原 REQ-L2H-30′；按 56 号 §6.2、57 号 B-14〕

4.5.3 读完成计数（计数器在 L2 侧）

单调读完成计数；"读完成" = 该单位带末读标记的最后一次读出的全部 flit 信用已由全部目的核返还（HUB-DN 配对"末标记 flit 全部目的返还"后报 L2 侧计数器；返回车道读出以 NI-L2C 收齐为准）；写者按读完成水位写；逐 token 释放即池的读完成计数加一，CCU 不另发释放信号。〔原 REQ-L2H-31；按 56 号 §6.2〕

4.5.4 带序号的位点 barrier

经上行控制 VC 收位点完成事件（位点号, n_{flit}）；n_{flit} 只计本核本位点直接经单写口写 L2 的 VC1 数据 flit，经 HUB-ATT 的列表记录与 R-hub 的部分和不计，列表写出完成另由 WCNT 门控〔按 54 号 C54-09 改〕；

仅当该核已提交写口的同口径 flit 数 $\geq n_{\text{flit}}$ 时计入；参与核计满后经下行控制 VC 广播 GO 并通知 LIC；位点控制命令在 GO 后 1 拍生效；位点号不匹配的位点完成事件发错误事件。〔原 REQ-L2H-32′〕

4.5.5 barrier 与区域交接分管

barrier 管配置与计算的控制命令切换，区域交接按计数逐区进行：新写者只按读完成计数（可早于 GO），GO 不等区域最后使用，新读者只按写完成计数；不以 barrier 代替读完成计数。〔原 REQ-L2H-33〕

4.5.6 barrier 超时

HUB-SYNC 只做 barrier 超时检测：超过门限时向 LIC 上报，由 LIC 按致命类收束、发错误事件并拉中断；调用级计数窗与看门狗归 LIC，hub 不持看门狗。〔原 REQ-L2H-34；按 57 号 B-20、R57-05〕

4.5.7 训练核份释放事件直达 NI

训练窗口里 SDN 要知道训练核何时能收下一个分块，而 hub 不为训练权重设发送表、份额或信用。训练核 CCU 的重排窗口份释放事件（1 flit）经上行控制 VC 进 hub，由 hub 直达 MAE 内 NI 的 SDN，作该核的资源信用（份；SDN 两层信用的第二层，56 号 §5.6）；与 WB 槽释放事件同一通路、同属控制 VC 严格优先，不经 LIC，不计入 barrier 与区域计数（CCU_CTL 篇 §4.6.1、`MAE_NI_INT` 篇）。〔新，按 54 号 C54-05 改〕

4.5.8 事件消息与第二层资源信用

位点完成、WB 槽释放、份释放、属主核完成、系数就绪、gather 计数、GO 都是 VC3 上的单 flit 消息（载荷首字节为类型，属主核完成至多 3 flit），不拉专线。链路信用（第一层）由返还线承载；资源信用（第二层：槽、份、区域的读完成 / 写完成）由这些消息与 L2 侧计数器承载；两层不可互相代替。〔新，按 56 号 §5.7〕

4.6 NoC 规则一览

4.6.1 N1…N14

为便于与整体集成篇对照，本篇条款对应的 NoC 规则如下：N1 重放 VC 落地 $\geq 4\times$ RTT、VC0 / VC1 信用按（核, VC, 道）计、VC2 / VC3 按（核, VC）共享池、侧带返还线（§4.1.3）；N2′ 控制 VC 严格优先，判决广播、核描述符与 GO 走下行控制 VC（§4.1.2）；N14 三层协议与格式感知的有效性语义（§4.1.7）；N3 下一组灌入截取 gate-hi 重放同一股流（§4.2.4）；N4 随训练权重改经 SDN 撤销，编号不复用（§4.2.10，按 R50-5 改）；N5 位点内一组余量滑动（§4.2.10）；N6 输出驻留停放留本核 L1（§4.3.1）；N7 R-hub 规则（HUB RHUB 篇）；N8 Qwen 取 K4 时 $W_{\text{win}} \geq 48$，由配置保证、违反表现为超口计数（数据流篇）；N9 层内切 k 的 barrier 走控制 VC，约 46 拍（§4.5.4）；N10 数据 VC 保底份额（§4.2.5）；N11 跨核位图 OR（§4.4.1、§4.4.10、§4.4.11）；N12 列表环写入（§4.3.5）；N13 K 切分判决广播（§4.4.5）；训练核份释放事件直达 NI 见 §4.5.7（不对应编号规则）。训练权重不经 hub（§4.2.7），不对应任何 NoC 规则。〔汇总，无新增要求；按 R50-5 改〕

5 设计目标

带【待标定】的是设计目标，带【一阶推导】的是结构计数或闭式估算。

5.1 精度

HUB-DN、HUB-UP 与 HUB-ATT 只搬运与按位 OR，要求逐位透明。HUB-SYNC 的标量合并按 FP32 语义：$\sum x^2$、$\sum |x\gamma|$ 与梯度范数的合并相对误差 $\le 2^{-20}$，lse 合并 $\mathrm{lse} = m'_{\mathrm{run}} + \ln\left(\sum_c l_c e^{m_{\mathrm{run},c} - m'_{\mathrm{run}}}\right)$ 的相对误差 $\le 2^{-12}$（与 NLU 的 lse 目标一致）【待标定】。为满足批不变验收，合并按核号固定次序进行、与到达次序无关（按对齐审查 §2 第 13 条接受）【待标定】。标定方法：在严格软仿硬链上把合并换成拟实现的 FP32 树，对 Qwen3-4B / MiniCPM5-1B 先测 KL 再测 top-1。

5.2 面积与门数

一阶结构计数（不含 L2 宏、R-hub 与核侧落地 FIFO）：【一阶推导】

- HUB-DN：4 道读引擎、每道 $N_{\mathrm{grp}}/4$ 个游标与段交错状态（段长按 w 现算）、32 槽加权窗口、4 × 4 道到核口仲裁、信用计数（VC0 / VC1 4 核 × 2 VC × 4 道 + VC2 / VC3 4 核 × 2 共享池）、每在途读单位的"未返还目的数"：约 60 到 90 k 门，残字 RF 约 4 KB。〔按 56 号 §5.3 / §5.5〕
- HUB-UP：4 核 × 4 VC 入口队列与信用、VC 分流、单写口仲裁、每核约 16 个 21 bit 写游标：约 32 到 48 k 门，入口缓冲约 4 KB（建议每核 18 flit = 576 B）。〔按 56 号 §5.2 / §5.4〕
- HUB-ATT：64 到 512 bit 宽 OR 与到齐位、合并缓冲约 1.5 KB、9 个列表环写指针与满标志、判决广播映射：约 20 到 30 k 门。
- HUB-SYNC：FP32 加法 / 比较 2 到 3 个、在线 softmax 合并用 exp 1 个、配对表 1 KB、barrier 计数器与超时检测：约 20 到 30 k 门（写完成 / 读完成计数器移到 L2 侧，调用级看门狗归 LIC，各减约 10 k 门）。〔按 56 号 §6.2；按 57 号 B-14 / B-20〕
- 协议断言比较器 6 类、信用返还侧带 56 根的寄存：约 2 到 4 k 门。〔按 56 号 §5.8〕
- 合计约 135 到 200 k 门加约 10 KB RF（建议值）；对宏观 RF 账"核级与 NoC 流控约 41 KB、SI-8 残字 4 KB"的总账归后续内存分配设计。〔按用户 10-23 裁定改，通则二〕

5.3 并行度与带宽

- D-40 128 B/拍 = 4 flit/拍，有效 125–127 B/拍（道间不均）；N10 每道 32 槽、每槽合 4 B/拍。
- 需求闭式（编译期用）：需求 $\approx \dfrac{64\,(a_{\mathrm{v}} \cdot \mathrm{keep} + h_{\mathrm{seg}})}{\kappa\,\chi_{\mathrm{I}}}$，其中 $\kappa = (\mathrm{keep} + F)/2$（20 号裁定 §1）、$\chi_{\mathrm{I}}$ 为 I 模式结构倍率；$a_{\mathrm{v}} = 0.875$、$h_{\mathrm{seg}} = 0.156$、$\chi_{\mathrm{I}} = 1.094$；边界稀疏率 Qwen 73.8%、MiniCPM 80.1%（与统一 $\chi_{\mathrm{I}} = 1.094$ 配对；V1.2 宏观 §6.2 的 75.4% 是 Qwen 在 $\chi_{\mathrm{I}} = 1.0$ 口径下的数，不用于 MiniCPM，按对齐审查 §3 第 1 条确认）；工作点 65.5% / 48.7%，需求约 120 / 100 B/拍。
- 负载（Qwen / MiniCPM，B/拍）：Prefill I 模式重放约 120 / 100，down 部分和读回 +6.6…19.7 / +1.4…15.6；gate/up K 切分 Qwen 1×4 W48 84.7–96，MiniCPM 四核 N 切分同流灌入 49–55；Verify 单核重放 + 读回 16.3–37.5，余约 90；训练权重不占 D-40，较 V1.3 释放 Draft 组窗口 0.05–0.20 的 D-40 份额【一阶推导】〔按 R50-5 改〕。
- 上行（每核）：VC2 部分和 Qwen 8.1（峰 9.4，逐任务 ≤ 16.7）；MiniCPM 现行切分下为 0（gate/up 走 N 切分、不经 R-hub），11.7（峰 13.2）为 V1.2 记账、口径待核，不作现行负载（按

对齐审查 §3 第 15 条）；I 模式位点 ≤ 3.3；录取位图 ≤ 2.7；判决广播约 0.5；区块位图远小于录取位图【一阶推导】。
- 单写口利用率：Qwen down 0.36–0.45、o 0.11–0.13、K4 W48 0.05。

5.4 时钟数

- 控制单程 p99 ≤ 12 拍（= 前飞 + 源端仲裁与排队）；barrier 约 $2 \times (12 + 11) = 46$ 拍，GO 后 1 拍位点控制命令生效。
- 往返分段【建议值，阶段二仿真复核】：D-40 $t_{\mathrm{rt}} = 22$ = 前飞 ≤ 10 + 弹出 1 + 返还 ≤ 10 + 1；上行与 SDN 按 22 拍预算；实测超出时按 $C_{\mathrm{cr}} \geq \lceil t_{\mathrm{rt}} \cdot r \rceil$ 加深落地深度。〔按 56 号 §5.4〕
- 写口等待 p99 15 拍。
- 重放落地 64 / 80 / 88 / 96 / 128 flit 时 D-40 可达 93 / 116 / 128 / 128 / 128 B/拍（RTT 22 拍）。
- 阈值套 4.3 KB 经 VC3 装载：VC3 落地 2 flit 时约 1,500 拍，建议 4 flit 时约 750 拍【推导】。〔按 56 号 §5.3〕
- F 判决链 q99 60–63 拍，预算 60–75 拍（含 R-hub 回送、归约属主核比较与 VC3 广播）。
- 录取并集写完成时延 $\leq$ 下一 tile 粗算拍数；区块并集写完成时延 ≤ 64 拍【待标定】。
- 调用开始分发：节点档表 + 祖先掩码 + Batch 行表经 VC3 < 30 拍，Draft 分布 2.4 KB 经 VC1 < 100 拍【一阶推导】，均在首个用档表的位点之前。

6 与其他模块的合同

- L2 SRAM：对方提供 bank、区域表、计数单位、bank 着色与写完成 / 读完成计数器（存放与比较在 L2 侧，增量来自 L2 写仲裁与本篇 HUB-DN 的返还配对 / NI-L2C 收齐）；本篇拥有单写口、象限读引擎与 HUB-UP 写游标，经中心内部门限比较接口读计数器〔按 56 号 §6.2、57 号 B-14〕。
- HUB RHUB：本篇把上行 VC2 分流到其入口 FIFO 并转发其归约值到 VC2（侧带头类别 0，共享池信用、每核每拍至多 1 flit）；归约本身与反压在对方。
- L1 集成篇：落地 FIFO 深度（重放 88、数据 24、VC2 ≥ 8、VC3 ≥ 2 建议 4 flit）与强制水位（$H_{\mathrm{wm}} = C_{\mathrm{cr}} - r \cdot L_{\mathrm{esc}}$，$L_{\mathrm{esc}}$ 为升级生效时延约 3 拍）、段片解析（按 SFD 的 w）、超口等待计数、落地路由按类别字段分路（含 PS 读回第三路）、标量抽头、信用返还脉冲的发出与在飞表（消费者 NLU）归对方；本篇负责发送序、份额、信用发端、多播"未返还目的数"与按位点汇总。训练核权重落地来自 NI 写缓冲（SDN），与 D-40 落地口无关〔按 R50-5 改；按 56 号 §4.5 / §6.3；按 57 号 B-04 / B-42 / B-43〕。
- MAE_NI_INT 篇：训练权重的权重形态级、SDN 多播与两层信用（链路信用（8 B 字）+ 资源信用（份））、停发都在对方；SDN 的拍带 NI 给出的落地地址，是协议 B 唯一带地址的例外；本篇不为训练权重提供 D-40 通路〔按 R50-5 改；按 56 号 §5.2 / §5.6〕。
- LIC（续）：hub 位点描述符里的 SFD 由 LIC 按编译期表直拷；barrier 超时由本篇上报、LIC 收束；调用级计数窗与看门狗在 LIC〔按 56 号 §2.1；按 57 号 B-20〕。
- VNU_EPI 篇：出口侧打包（后处理量化点）与 S1–S3 位图在对方产生。
- VNU_SEL 篇：录取 / 区块 / lo 读集位图与每列 2 bit 判决在对方产生；阈值表与档 MUX 在核内。VNU_SMP 篇：LM Head 属主核的 TOPK 列补算列表、接受列表与结果记录在对方产生，Draft 分布（VC1）与随机数（VC3）由本篇送到对方的采样状态区（位于 LM Head 属主核 AB 地址范围内，见 L1 集成篇）。

- CCU_CTL 篇：产生位点完成事件与核事件（含训练核的重排窗口份释放事件，经本篇直达 NI 的 SDN），消费判决广播与区块并集广播，执行 Batch 行的 tile 序列，给出上行 VC2 flit 头的归约属主号；本篇提供 barrier、GO 与 VC3 下发。〔按 54 号附录 B-CH-26、C54-05 改〕
- CCU_GRP 篇：执行 I 模式分组与组内并集，产生 lo 读集与掩码镜像记录（本核单独写时经上行 VC1，多核训练的 lo 读集位图经上行 VC0 进 HUB-ATT 做 OR）。〔按 54 号附录 B-CH-26、C54-10 改〕
- MAE_ENG 篇：读列表环（含区块列表）、执行 KCE / WKE / IGE、注入计数事件；本篇提供门限与事件通路。
- LIC：生成与下发 hub 位点描述符（含梯度范数部分和的期望数与合并值的目的核）、配置 barrier、选阈值套并装载、按调用输入区计数下发分发；本篇上报 GO，并转发 OPT 执行核经上行控制 VC 发出的系数就绪事件；梯度范数平方不再上报 LIC（按用户 10-22 裁定改，CHANGELOG_V1.4 §2）。
- CIF：计数窗经 LIC 汇总。
- 数据流篇：各调用里每个位点的目的掩码、份额与负载，N8 的配置保证，OPT 写回、$\mathrm{d}\tilde{g}$ / $\mathrm{d}\tilde{u}$ 环与训练状态回写在两种训练模式下的次序〔按 R50-5 改〕。

7 未定项

区块位图的记录格式与 OR 粒度编码随区块搜索实现定（在飞波次数随位点描述，区块列表环长度由分区表给出）【待审查】；三个往返时延（D-40、上行、SDN）的实测与落地深度回填【待仿真，56 号 §5.4】；上行 chunk 池按 token 定位所需的偏移索引对齐【待审查，56 号 §5.2】；S 列表环的记录格式与长度（LOSS 归并，B-26）【待审查】；Batch 合并键中段号的位宽与私有段参与核掩码的派生方式【待审查】；调用内改写档表同步的时延预算【待审查】；区块并集经 VC3 广播到 CTL 的时延【待标定】；MiniCPM 上行 VC2 11.7 B/拍的 V1.2 记账来源，仿真阶段核实【待审查】；§5.2 一阶门数与 RF 对宏观 RF 账的总账归后续内存分配设计（通则二）；训练窗口释放的 D-40 份额（Draft 组窗口 0.05–0.20）是否改作重放余量或读回份额，由数据流篇按位点重排后定【待核】；训练核份释放事件经 hub 的时延对 n_w 取值的影响留 54 号 J-3【待仿真】。〔按用户 10-23 裁定改，通则二；按 54 号 C54-05 改〕