HUB RHUB 模块需求

> Owner: WangYizhao | 2026-10-22 | NPU Architecture V1.5

0 读这份文档之前

- 读者是有 NPU 设计经验、第一次接触本项目的工程师。读完 §1 到 §3 应能说出 R-hub 为什么存在、它把什么加成什么、怎样在没有标签的情况下把四个核的部分和对齐、结果怎样回到归约属主核；§4 是条款，§5 是设计目标。
- R-hub 是挂在 hub 中心的一个归约单元，只服务"核间 K 切分"这一种并行方式。上行分流、VC 与信用、回送选道在 HUB NoC 篇；部分和从哪个出口队列、按什么次序放出在 MXU_ARR 篇；归约值落到归约属主核后被哪条序列消费在 VNU 组各篇与数据流篇。
- 条款以 4.x.y 小节组织，末尾〔原 REQ-xx-nn〕只作与 V1.2 的对照。配置、事件与计数器只按含义描述，实名与编码等 ISA 确认后补入。数字口径：1 GHz（1 拍 = 1 ns），模型写作 Qwen3-4B / MiniCPM5-1B。
- 10-26 起全篇按 AW 写法（$Y = XW$，W 为 $K \times M$），行 / 列以右操作数为准（归约下标为行、输出下标为列），旧稿行 / 列义相反，对应表见 `SYMBOLS_AND_TERMS_V1.5.md` §3。

1 HUB RHUB 是做什么的

1.1 它在片上的位置

当一个线性位点的归约维（K 维）被切成四段、四个核各算一段时，每个核只得到同一输出的四分之一部分和，必须跨核相加。四个核之间没有直连，所以加法放在 hub 中心：各核 MXU 的 F1b 累加器出口队列（E6）把部分和以 BF16 经本核上行 VC2 直接送出（不经后处理单元），进 R-hub 的每核入口 FIFO；R-hub 头对齐、按固定次序相加、量化成 MXFP6 g32，经 D-40 VC2 回送这一组输出的归约属主核；归约属主核的 L1 落地口把它写进 AB 停放区，再由本核向量单元继续处理。R-hub 全芯片一个，没有 DDR 口，不写 L2，不发描述符，配置只来自 hub 位点描述符。

1.2 整体任务

一句话：对四个核同一位置的 BF16 部分和做无状态、固定次序、逐位可复现的归约，并在出口一次量化成激活格式。拆成三件事：

1. 入口对齐：四路部分和不带标签，靠"各核按同一 pid 序放行"保证四路 FIFO 的同一位置就是同一输出，头对齐即配对。
2. 固定序加法：每 lane 一个 4 输入加法节点，$(y^{(0)} + y^{(1)}) + (y^{(2)} + y^{(3)})$，每级 BF16 RNE，无跨拍累加状态。
3. 出口量化与回送：按 32 元素组求 amax 得共享尺度，量化成 MXFP6 g32，带组序号回送归约属主核。

1.3 它不做什么

不做 L2 读改写累加，不做 key 匹配或按地址查找；不保存跨拍累加状态；不做残差加与 attention 的 O 累加（这两处加法在后处理单元、按 BF16，用户 10-24 已裁定保留后处理单元自有 lane，57 号 R57-04）；不做任何判决（gate / F / C / Z 判决在归约属主核）；不选回送道（由 HUB NoC 选最空道）；不服务 N 切分（MiniCPM 的 gate/up 走 N 切分，不经 R-hub）。

1.4 贯穿全文的几个概念

- K 切分：一个输出的归约维被分给多个核，每核得部分和；现行只用于 Qwen Prefill gate/up，形态 1×4、窗口 W48、组 G32（N 组 1 个、K 片 4 个）。
- pid 序：一个位点内各输出组的编号次序。四个核在各自出口队列内把部分和重排成同一 pid 序后才放行。
- 部分和与归约值：未完成 K 归约的部分和（psum 1）一律 BF16；R-hub 的输出是完成归约的值（psum 2），在出口量化成 MXFP6。
- 组与条目：上行一条条目是 16 个 BF16 元素（256 bit）；同一 token 相邻两条条目组成一个 32 元素组，与 MXFP6 g32 的尺度组对齐。参考设计为 16 lane，一拍处理一条 16 元素条目，前一条结果暂存 32 B，第二条到齐后一起量化。〔按 54 号 C54-13 改〕
- R-hub 归约属主核：一组输出归约后送去的核；按 token 交错指定。

1.5 各类调用里 R-hub 各做什么

- Prefill：Qwen 的 gate/up 位点（gate-hi 与 up-hi 的部分和）启用；MiniCPM 取 N 切分，不启用；其他位点不启用。
- Decode、Proposal、Verify：线性位点为单核或按 N 切分，不启用。
- Target 独立训练：不启用。
- down / o 的 K 切分为预留扩展，默认不启用。

2 核心设计要求

2.1 无状态、固定次序、逐位可复现

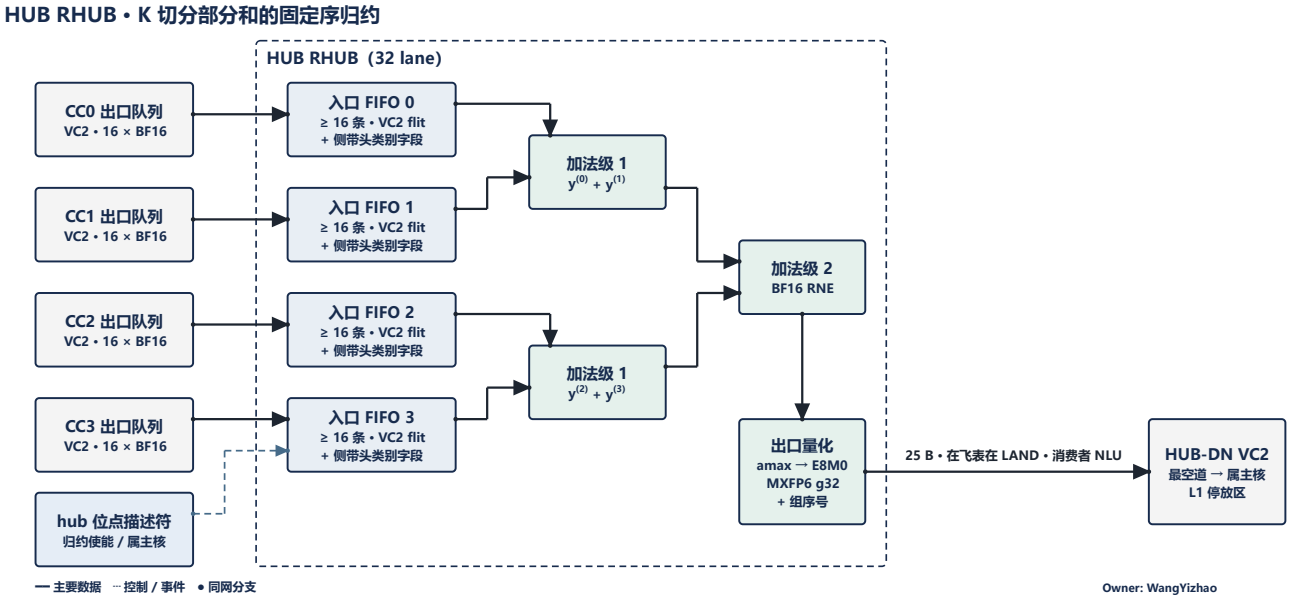
归约结果不能依赖到达次序或拍间状态，否则同一输入在不同负载下会得到不同舍入，破坏批不变与训练前向重算的可复现性。R-hub 的每个 lane 是无跨拍累加状态的组合加法节点，次序固定为 $(y^{(0)} + y^{(1)}) + (y^{(2)} + y^{(3)})$，每级 RNE；输出只依赖四个输入值。

2.2 不带标签的头对齐

给每条部分和带地址或 key 标签需要加宽上行载荷与匹配逻辑。R-hub 不带标签：正确性前提是各参与核按同一 pid 序放行（核侧出口队列内重排，重排使能随 CCU_CTL 下发的 E6 放行使能与 pid 序号给出，与 hub 位点描述符的归约配置出自同一位点模板），于是四路入口 FIFO 头部天然是同一输出，按 FIFO 位置对齐即可。

3 与周围怎么连、怎么配合

3.1 连接



图中左列是四个核的出口队列（经各自上行 VC2）与 hub 位点描述符（虚线）；虚线框内是四路入口 FIFO、两级加法与出口量化；右侧是 HUB-DN 的 VC2 回送。逐条接口如下：

- 入口（上行 VC2，协议 B，由 HUB NoC 分流进来）：每核每条 16 × BF16 = 256 bit（SFD 格式码 8，BF16 向量），无标签；归约属主号 2 bit 位于上行 14 bit 侧带头；每核入口 FIFO ≥ 16 条，四核共 2,048 B，FIFO 深度就是上行 VC2 的信用。发送方是各核 MXU 的 F1b 出口队列，不经后处理单元。〔按 56 号 §5.1 / §5.4〕
- 反压：任一入口 FIFO 满时经上行 VC2 信用反压到该核的出口队列，计入"R-hub 入口满"计数（流量性停顿，不报错）。
- 出口（D-40 VC2 → 归约属主核 L1 落地 → AB 停放区 + 在飞表）：每组 MXFP6 g32 25 B（32 × 6 bit + 1 B E8M0，SFD 格式码 12），flit 空余 7 B 中放 16 bit 按属主计数的组序号，由 LAND 的在飞表对齐、消费者为 NLU；下行 VC2 侧带头的类别字段标为部分和（类别 0，类别 1 为 HUB-SYNC 标量；原 1 bit 类型位是类别字段的一个取值）；VC2 信用按（核, VC）共享池计，hub 对每核每拍至多发 1 flit；属主按 token 交错、由 HUB NoC 选最空道。〔按 56 号 §5.1 / §5.3；按 57 号 B-43〕
- 配置：hub 位点描述符给出本位点是否启用归约、参与核集合与属主映射。

3.2 谁来配置、什么时候生效

归约配置随 hub 位点描述符在 GO 后生效；核侧出口队列的 pid 序重排使能随 CCU_CTL 下发的 E6 放行使能与 pid 序号给出（按对齐审查 §1.D），二者由 LIC 按同一位点模板生成、同一 GO 生效；R-hub 自身没有可装载的参数表，加法次序与量化规则固定。

3.3 典型场景里的配合次序

(a) Qwen Prefill gate-hi 的一组输出。四核各算四分之一归约维，F1b 出口队列按 pid 序放行 BF16 部分和；四路条目进入口 FIFO；四路头部都非空时，16 lane 同拍对这一条条目做两级加法；同 token 的前一条

结果暂存（32 B），第二条到齐后两条拼成 32 元素组〔按 54 号 C54-13 改〕，求 amax、定 E8M0、量化成 MXFP6 g32；带组序号经 VC2 回归约属主核，落 AB 停放区；归约属主核随后在本核完成激活与判决，再经 HUB-ATT 广播判决结果。

(b) 入口拥塞。某核上行较快、其入口 FIFO 先满：该核出口队列被 VC2 信用停住，计入"R-hub 入口满"；其他核继续送，直到四路头部配齐；核侧出口队列自身满由 MXU_ARR 篇另计，两类原因分开保留。

(c) 与 F 判决链的时序。R-hub 回送是 F 判决链的第一段，整条链（回送、归约属主核比较、VC3 广播）q99 60–63 拍，预算 60–75 拍。

4 需求条款

4.1 数据通路

4.1.1 lane 数与吞吐

吞吐须不低于每核上行部分和的峰值组速率：需求约 0.13 到 0.26 组/拍（按 §5.3 换算：每核 8.1 B/拍、逐任务 ≤ 16.7 B/拍，每核每组 64 B），上行带宽限定约 0.5 组/拍。参考设计为 16 lane，一拍处理一条 16 元素条目（合每拍 0.5 个 32 元素组，与上行上限相当，对需求峰值留约一倍余量）；lane 数由设计者定。〔原 REQ-L2H-35；按 54 号 C54-13、附录 B-CH-17 改〕

4.1.2 固定次序 BF16 加法节点

每 lane 为无跨拍累加状态的 4 输入加法节点，由两级三个 BF16 加法器组成，次序固定为

$$y = \mathrm{RNE}_{\mathrm{BF16}}\Big(\mathrm{RNE}_{\mathrm{BF16}}(y^{(0)} + y^{(1)}) + \mathrm{RNE}_{\mathrm{BF16}}(y^{(2)} + y^{(3)})\Big),$$

$y^{(i)}$ 为核 i 的部分和；参与核少于 4 时缺位按 $+0$ 处理，次序不变（$+0$ 不改变 RNE 结果，2 × 2 形态可复现；按对齐审查 §2 第 16 条确认）。中间 BF16 舍入按"中间结果允许 BF16 暂存"的公共合同允许。〔原 REQ-L2H-35、原 REQ-L2H-37〕

4.1.3 入口 FIFO 与头对齐

每核入口 FIFO ≥ 16 条、四核共 2,048 B；条目只含 16 × BF16、不带标签；按四路 FIFO 的位置头对齐，四路头部都到齐才出一拍。入口 FIFO 与写 L2 的路径分离，部分和不排在写口队列里。〔原 REQ-L2H-35〕

4.1.4 两条拼一组

同 token 相邻两条 16 元素条目组成一个 32 元素组：前一条的加法结果暂存（16 × BF16 = 32 B），第二条到齐后一起量化。〔原 REQ-L2H-35；按 54 号 C54-13 改〕

4.1.5 不做读改写与匹配

R-hub 不经 L2 读改写，不做 key 匹配；归约只发生在入口 FIFO 头部对齐的四个值之间。〔原 REQ-L2H-35〕

4.2 正确性前提与反压

4.2.1 同一 pid 序放行

正确性前提：各参与核按同一 pid 序放行部分和（核侧出口队列内重排，重排使能随 CCU_CTL 下发的 E6 放行使能与 pid 序号给出，与 hub 位点描述符的归约配置出自同一位点模板）。R-hub 不检测序错位；序一致由核侧保证并在验证中覆盖。〔原 REQ-L2H-36；使能来源按对齐审查 §1.D 补〕

4.2.2 入口满反压与两类计数

入口 FIFO 满时经上行 VC2 信用反压到核侧出口队列，计入"R-hub 入口满"异常计数；核侧出口队列满由 MXU_ARR 篇计入"出口队列满"，两类原因分别保留。〔原 REQ-L2H-36〕

4.3 出口量化与回送

4.3.1 MXFP6 g32 量化

归约值 = 完成归约的值：固定 BF16 树之后按 32 元素组求 $a_{\max} = \max_i |y_i|$，由此得 E8M0 共享尺度，按量化合同量化成 MXFP6 E2M3 g32（RNE、限幅），规则与后处理单元同类量化点逐位一致。〔原 REQ-L2H-37〕

4.3.2 回送与组序号

归约值经 D-40 VC2 回归约属主核（按 token 交错指定属主、选最空道；VC2 为（核, VC）共享池信用，每核每拍至多 1 flit）；25 B 载荷之外的 7 B 中放 16 bit 按属主计数的组序号，由核侧 LAND 的在飞表按序号对回（token, 列块）；侧带头类别字段标为部分和。〔原 REQ-L2H-37；按 56 号 §5.1 / §5.3〕

4.3.3 落点

归约属主核 L1 落地口按侧带头的类别字段把归约值写进 AB 停放区（56 号 a20，S 形态），在飞表归 LAND，消费者为本核 NLU；不走未完成部分和的装回口。〔原 REQ-L2H-37；按 57 号 B-43〕

4.3.4 down / o 的 K 切分预留

down 与 o 的 K 切分为预留扩展，默认不启用；启用时沿用本篇的固定次序与出口量化，不改结构。〔原 REQ-L2H-37〕

5 设计目标

带【待标定】的是设计目标，带【一阶推导】的是结构计数或闭式估算。

5.1 精度

BF16 的单位舍入为 2^{-9}，两级树对精确和 $y^{\star} = \sum_i y^{(i)}$ 的误差满足

$$|y - y^{\star}| \lesssim 2^{-9}\big(|y^{(0)} + y^{(1)}| + |y^{(2)} + y^{(3)}|\big) + 2^{-9}|y|,$$

远小于随后 MXFP6 E2M3 的量化相对步 2^{-3}。目标：归约值在 MXFP6 量化之后与"FP32 精确和再量化"一致的元素比例 $\geq 99.9\%$，不一致处只差 1 个码【待标定】。标定方法：在严格软仿硬链上对 Qwen3-4B 的 gate/up 位点比较两种归约，先测 KL 再测 top-1，验收线为落在既有测量噪声带内。可复现性：同一输入在任意到达次序与反压下逐位相同。

5.2 面积与门数

宏观总账：R-hub 0.084 mm²（0.062–0.110），已含 2,112 B RF，出口量化器另计；这一包络按 32 lane、两条并行的参考设计（96 个加法器、2,048 B FIFO + 64 B 暂存）记，是上界。按 16 lane、一拍一条的参考设计一阶结构计数：【一阶推导】〔按 54 号 C54-13 改〕

- 48 个 BF16 加法器（16 lane × 3），每个约 1.2 到 1.8 k 门：约 58 到 86 k 门。
- 出口量化器（32 入 amax 树、指数提取、移位、RNE 与限幅）：约 10 到 15 k 门。
- 入口 FIFO 控制、头对齐、组拼接与组序号：约 5 到 8 k 门；RF 2,048 B FIFO + 32 B 组暂存。
- 合计约 73 到 109 k 门加 2,080 B RF（建议值），在 0.084 mm² 包络之内，待设计者核算。

5.3 并行度

- 参考设计 16 lane，每拍一条 16 元素条目，每两拍一个 32 元素组（合 0.5 组/拍）。〔按 54 号 C54-13 改〕
- 上行 VC2 部分和负载每核 Qwen 8.1 B/拍（峰 9.4，逐任务 ≤ 16.7）；MiniCPM 现行切分下为 0（gate/up 走 N 切分、不经 R-hub），11.7（峰 13.2）为 V1.2 记账、口径待核，不作现行负载（按对齐审查 §3 第 15 条）；每核每组 64 B，对应 0.13 到 0.26 组/拍（8.1 ÷ 64 ≈ 0.13，逐任务 16.7 ÷ 64 ≈ 0.26）。〔按 54 号附录 B-CH-17 改〕

5.4 时钟数

- 入口对齐 1 拍、两级加法各 2 拍、量化 2 到 3 拍，入口头部到齐至回送 flit 出 R-hub ≤ 10 拍【待标定】。
- 回送经 VC2 单程 p99 约 12 拍；F 判决链整体 q99 60–63 拍，预算 60–75 拍。
- 入口 FIFO 16 条可吸收四核间约 16 条（每条 32 B，512 B/核）的放行错拍。〔按 54 号 C54-13 改〕

6 与其他模块的合同

- MXU_ARR 篇：F1b 出口队列按 pid 序放行部分和、发往上行 VC2（不经后处理单元）；出口队列满的计数在对方。
- CCU_CTL 篇：给出 E6 放行使能、pid 序号与上行 VC2 flit 头的 2 bit 归约属主号，是核侧 pid 序重排使能的来源。
- HUB NoC 篇：上行 VC2 分流进入口 FIFO、FIFO 信用回传、回送选最空道与 VC2 发送都在对方。

- L1 集成篇：落地口按侧带头类别字段把归约值写 AB 停放区，LAND 的在飞表按组序号对齐，消费者 NLU〔按 57 号 B-43〕。
- VNU 组：归约值的激活、判决与后续序列在归约属主核执行，判决结果经 HUB-ATT 广播。
- LIC：生成 hub 位点描述符中的归约配置与本流的 SFD（格式码 12，组 32，组内联尺度）。
- VNU_EPI 篇：后处理单元累加通路的评估（R48-02）中"以 R-hub 承担核内残差加"一项的否定依据在该篇；用户 10-24 已裁定后处理单元保留自有 lane（R57-04），本篇不承担残差加。
- 数据流篇：哪个模型、哪个位点用 K 切分及其窗口与组参数。

7 未定项

MiniCPM 上行 VC2 11.7 B/拍的 V1.2 记账来源，仿真阶段核实【待审查】；§5.1 的精度目标与 §5.4 的流水深度待实现方案定后标定【待审查】；down / o K 切分启用的条件与容量【待审查】；§5.2 一阶门数与 0.084 mm² 包络的核算【待审查】；lane 数与暂存深度按通则一为参考设计（16 lane、一拍一条），由设计者定。〔按 54 号 C54-13 改〕