VNU 损失单元（LOSS）需求

> Owner: WangYizhao｜2026-11-04｜重写稿，待用户审阅。按用户 11-04 确认的目录编写（`../V17_3_MODULE_TOC_VNU_LOSS_20261104.md` 第二版）；改变现行设计的事项汇总在 `Claude_Design_Spec/V1.8_DESIGN_REVISIONS.md`（V18-LOSS-01…04、V18-VNU-01、V18-VNU-02、V18-SEL-10）。
> 11-05 按片上数据传输协议篇（`DATA_TRANSFER_PROTOCOL.md`，V18-TP-01…16）同步：与 L1 的口改为 RRAM 口、地址由 CCU 推理、入口 stall；交 CRU 的部分量与合并值改走命令与标量网；参与词号列表按 ③ 档变长对象写出、记录级 32 B 对齐（§2、§3.1.2、§5、§8）。
> 11-05 晚第二轮同步（协议篇 §2.1、§3.2、§4.2、§7.3、§9.7，V18-TP-17…20）：32 B 单位改称存储字；读经激活类读口、写进 A 类写集合器里本单元的入口 FIFO、wr_stall 回本单元；参与词号列表 bump 分配、不预留（§2、§3.1.2、§5、§7）。
> 11-05 第三轮同步（协议篇 §4、§6.1、§6.4、§8.1、§8.2，V18-TP-21 / 24）：与 CRU 的标量经 CCU 中转——合并值由 CCU 写进合并值寄存器，LOSS 不设结果寄存器（梯度范数平方的部分和由 NLU 累加，用户 11-05 定），LOSS 在命令与标量网上无端口；"反压"作机制名处改称握手（§2、§4、§5、§7、§8）。

1 组成与位置

1.1 LOSS 做两件事：形成链首梯度、给出截断分布的 log-prob

LOSS（Loss Unit，损失单元）做两件事：

- **监督梯度**。LM Head 对一个 token 给出一行 logits：$z = \mathbf{h}\,W_{\mathrm{LM}}$，$\mathbf{h}$ 为该 token 的 hidden 行向量（$1 \times d_{\mathrm{hidden}}$），$W_{\mathrm{LM}}$ 为 $d_{\mathrm{hidden}} \times V_{\mathrm{vocab}}$，词表项是输出列。LOSS 在**参与词号集合** $\mathcal{S}$ 上形成**链首梯度** $\mathrm{d}z_{\mathcal{S}}$。$\mathcal{S}$ 是这一行里参与梯度计算的若干列下标，$|\mathcal{S}| \ll V_{\mathrm{vocab}}$；链首梯度是反传链的第一跳，下游 MXU 用它求 $\mathrm{d}\mathbf{h} = \mathrm{d}z_{\mathcal{S}}\,W_{\mathcal{S}}^{\mathsf{T}}$，$W_{\mathcal{S}}$ 是 W_{LM} 按 $\mathcal{S}$ 取出的列（$d_{\mathrm{hidden}} \times |\mathcal{S}|$）。
- **截断分布统计**。**截断分布**是只在一个采样位置的 K_{top} 个候选项上归一化的分布。LOSS 给出所选 token 在这个分布里的对数概率（log-prob），可选给出熵与最大概率。

1.2 LOSS 不做什么

- 不做矩阵乘（MXU）、选择与排序（SEL）、采样与监督信息的产生（SMP）、量化（QNT）、跨核合并（CRU）。
- 不发 DDR 请求，不参与调度。
- **M55 算好损失、随调用输入给出的 logits 梯度（入口梯度）不经 LOSS**，LOSS 没有与它相关的功能。

1.3 LOSS 是 VNU 组的一个单元，每核一个

一个计算核由 CCU、MXU 组、L1 组、VNU 组四组拼成。LOSS 是 VNU 组的六个单元之一，其余五个是 NLU、SEL、QNT、SMP、OPT。**LOSS 与 VNU 组外的模块交换数据，都经 VNU 组的对外接口**；访问 L1 和向核外上行，经 VNU 的共用口。VNU 对外口的个数与共享方式由 VNU 集成篇定义（待写）。

每个计算核一个 LOSS，全芯片 4 个，物理相同。

1.4 只规定要求，不规定损失算法

本篇只规定三条要求（§3.1）与输出合同，不规定损失怎样算（用户 11-02）。以下内容由设计者与算法侧共同确定：

- 监督信息从哪来；
- 损失公式；
- $\mathcal{S}$ 怎样选；
- **学生侧信息**保存什么。学生侧信息是 Draft 一侧在监督样本产生时就要记下、等监督到齐后才用的量，例如该 token 的 $\mathbf{h}$。

硬件与同步更新的算法参考模型逐位一致；某个口径硬件实现太难时，交回算法侧修改并同步参考模型（用户 11-02）。

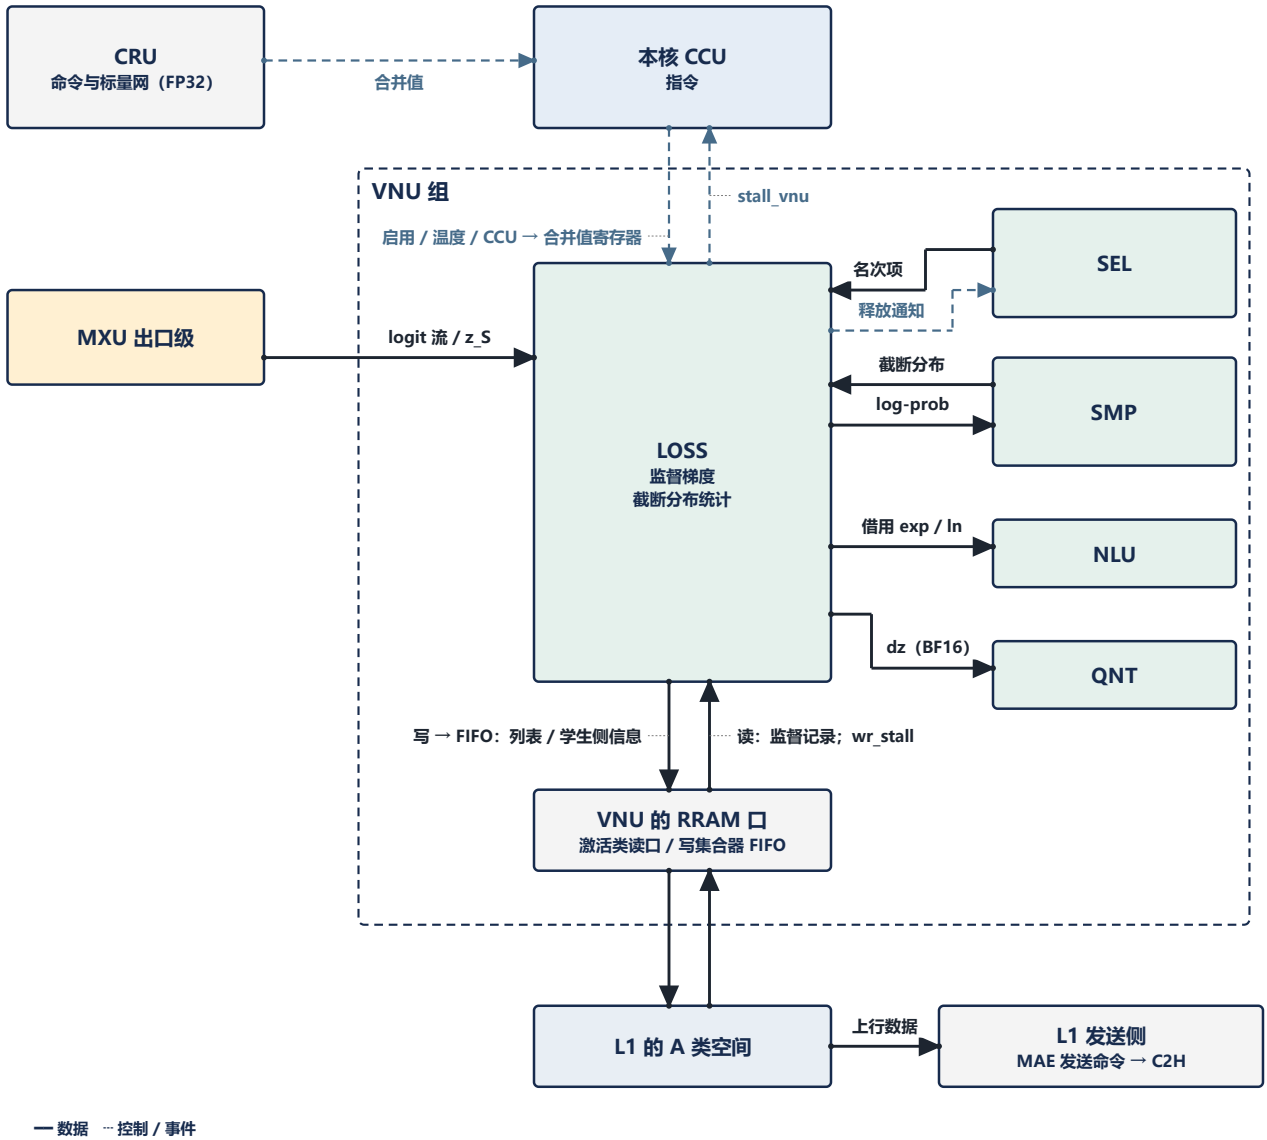
1.5 两项功能各自由指令启用

两项功能各自由指令启用；都不启用时 LOSS 不工作。**LOSS 同一时刻只执行一种功能**，先后由指令与 CCU 排定（用户 11-04，V18-VNU-03）。本篇不写指令字段，指令定稿后另补。

1.6 exp、ln 可分时借 NLU 的元件

LOSS 需要的 exp、ln 等可分时借用 NLU 的元件，**NLU 只执行**。使用时段由 CCU 与指令安排。

2 数据从哪来、到哪去



虚线框是 VNU 组：

- **框内**是 LOSS，以及和它直接往来的 SEL、SMP、NLU、QNT。这些连线不出 VNU 组。
- **跨出框的连线**都是 VNU 组的对外接口：
  - 左侧：MXU 出口级送来的 logit 流与按 $\mathcal{S}$ 重算的 logit $z_{\mathcal{S}}$（图中写作 z_S）；
  - 上方：本核 CCU 给的指令（虚线），以及 LOSS 给 CCU 的入口 stall；与 CRU 之间的标量**经本核 CCU 中转**（用户 11-05，传输协议篇 §6.1、§8.1）：**LOSS 不设结果寄存器**——要跨核合并的部分和（梯度范数平方）由 NLU 累加（用户 11-05 定）；CRU 的合并值回到 **CCU 的短消息队列，由 CCU 按类型与 token / 轮标签写进 LOSS 的合并值寄存器**，再发出使用该值的指令。**LOSS 在命令与标量网上没有端口**，合并值是 FP32、不落 L1（图中 CRU 只与 CCU 相连）。
- **下方的 L1 口**：LOSS 不直接连 L1 或核上行链路（C2H），而是经 **VNU 的 RRAM 口**（RRAM 即核内 SRAM 口协议，传输协议篇 §3）访问 L1 的 A 类空间：读经 L1 外的选择器用一个激活类读口；**写**进 L1 的 A 类写集合器里本单元自己那条 32 B 入口 FIFO，集合器每拍按优先级把各写者的队头分到对应 bank 的道上，FIFO 将满时拉 **wr_stall** 回本单元（只到本单元，不到 CCU；传输协议篇 §3.2）。要上行的数据（参与词号列表、学生侧信息）也先经这个口写入 L1，再由 L1 发送侧经 C2H 发出（MAE 的发送命令直接送本核 CCU，由 CCU 发读）（用户 11-04 / 11-05，V18-L1-03、传输协议篇 §6.1）。

2.0 组内链路只限定位宽

LOSS 与同组单元之间经组内链路交换数据。链路只规定位宽：全组统一每拍 256 bit（32 B），另加握手位（用户 11-04，V18-VNU-02）。链路上是什么格式、什么精度，由 LOSS 与对端单元的控制逻辑按指令解码，链路本身不区分格式。所以下面的接口表只写"交什么"；LOSS 须能解码的格式列在 §4.3。

链路条数与组内互连方式由 VNU 集成篇定义。

2.1 VNU 组内的接口

接口	对端	方向	内容
名次项	SEL	入	流式 TOPK 的名次项（序号 + 评分）。SEL 可在同一条评分流上同时跑两组流式 TOPK，结果可按序号升序输出
释放通知	SEL	出	LOSS 用完名次项后通知释放；**此前 SEL 保持名次项，不被下一个选择域覆盖**
截断分布	SMP	入	一个采样位置的 K_{top} 项分布与所选 token；算法需要时另有 TOPK 项的精确 logit
统计结果	SMP	出	log-prob，可选熵与最大概率；由 SMP 组装进结果记录
元件借用	NLU	入 / 出	分时使用 exp、ln 等元件（§1.6）
链首梯度	QNT	出	$\mathrm{d}z_{\mathcal{S}}$，按 BF16 交出；**由 QNT 量化成流动梯度格式后写本核 L1，LOSS 不设量化器**（用户 11-04，V18-LOSS-03）

2.2 经 VNU 组对外的接口

接口	对端	方向	内容
logit 流	MXU 出口级	入	LM Head 的 logit 流，按词表序到达；与 SEL 收到的是同一条流

接口	对端	方向	内容
按 $\mathcal{S}$ 重算的 logit	MXU 出口级	入	$z_{\mathcal{S}} = \mathbf{h}\, W_{\mathcal{S}}$，按词号升序到达
L1 读写	读：L1 外选择器 → 激活类读口；写：A 类写集合器里 LOSS 的入口 FIFO	入 / 出	读：经入站分发网（IDN）落入 L1 的监督记录、读回的学生侧信息；写：要上行的数据（见下一行）。整字 32 B；写只给 din 与记录长度
写握手	L1 的 A 类写集合器	入	LOSS 那条入口 FIFO 将满时的 wr_stall
上行	先写 L1，由 L1 发送侧经 C2H 发出（发送命令送 CCU，CCU 发读）	出	参与词号列表，写入 L2，供 MAE 的索引 gather 引擎（IGE）按列表取 W_{LM} 的列；需跨调用保存的学生侧信息，经 L2 写 DDR。**目的地址由 MAE 命令给出**
合并值寄存器（CCU 写）	本核 CCU：CRU 的合并值进 CCU 短消息队列，CCU 按类型与 token / 轮标签写入（用户 11-05）	入	CRU 合并后的值（LOSS 不设结果寄存器，梯度范数平方的部分和由 NLU 累加，用户 11-05 定）；FP32；CCU 写好后才发出使用它的指令，**LOSS 不设有效位、不因标量未到而 stall**
指令	本核 CCU	入	启用哪项功能、温度、个数等
入口 stall	本核 CCU	出	每条由 CCU 发读的入口一根 stall_vnu[i]

表中输入是可用输入，是否使用由所选损失算法决定。 这些都是 VNU 组已有的口，不为 LOSS 新增通路；新算法需要现有通路以外的输入时，再记入 V1.8 修订文档。

RRAM 口的用法（传输协议篇 §3、§4）：

- L1 没有仲裁：读经 L1 外的选择器用激活类读口（每口 32 B/拍），读时隙由 CCU 排；**写**进 L1 的 A 类写集合器里本单元自己那条 32 B 入口 FIFO，集合器每拍按优先级把各写者的队头分到对应 bank 的道上，FIFO 将满时拉 **wr_stall** 回本单元（只到本单元，不到 CCU；传输协议篇 §3.2）；读写哪一堆由地址的堆位选（用户 11-04 / 11-05，V18-L1-02）。
- **每次读写的 en / wea / addr 都由本核 CCU 发出**；LOSS 写 L1 时只给 din（一个存储字，32 B）与本条记录的长度；FIFO 将满时 LOSS 保持 en / wea / addr / din。读出固定 1 拍到达。
- **每条由 CCU 发读的入口给 CCU 一根 stall_vnu[i]**，入口缓冲占到"深度 − L"时拉起；L【设计者定】。写侧只有本单元 FIFO 的 wr_stall，不到 CCU。

2.3 由别的模块保证的事项

以下事项 LOSS 不检查，由对应模块保证：

事项	由谁保证
监督信息的产生与写出	SMP，或算法选定的生产者
监督记录与学生侧信息的 DDR 读写，经 IDN 落 L1	MAE
名次项的选出	SEL
logit 与 $z_{\mathcal{S}}$ 的计算；logit 流同时交 SEL 与 LOSS	MXU；扇出与放行先后归 CCU 与指令

事项	由谁保证
按参与词号列表 gather W_{LM} 的列；列表的实际长度经对象长度报告交 MAE 后再放行	MAE；CCU（对象长度报告，传输协议篇 §7.3）
读写 L1 的地址（基址 + 字节累加）与 dout 去向	CCU
变长列表按实际长度 bump 分配（不预留）；其余 A 类地址段的分配、写入前旧数据已读完；同一阶段并发写者总需求 ≤ 道数 × 32 B/拍	CCU（bump 分配）；编译链（指令中的基址与长度，LIC 操作 15；静态检查）
交给 LOSS 的是哪一份截断分布（拒绝采样时为父节点未经残差更新的分布）	SMP
跨核合并按固定次序（LOSS 只接收合并值）	CRU
合并值按类型与标签写进合并值寄存器，写好后才发使用它的指令（LOSS 不设结果寄存器）	CCU（传输协议篇 §8.2、§11）
链首在哪个核、何时执行；监督未就绪时等待	LIC、CCU 与数据流篇
入口梯度的读入与落位	MAE、LIC
$\mathrm{d}z$ 的量化	QNT
同一单元的不同功能不在时间上重叠	CCU 与指令
上行数据写 L1 后经 C2H 发出	L1 发送侧（MAE 发送命令送 CCU，CCU 发读）
组内链路条数与互连；VNU 对外口的个数与共享方式	VNU 集成篇（待写）

3 运算形态

形态	按矩阵维度说做什么	输入	输出	典型用途
监督梯度	在一行 logits 的参与列 $\mathcal{S}$ 上形成 $\mathrm{d}z_{\mathcal{S}}$	选定算法所需的监督信息、学生侧信息与 logit	升序去重的参与词号列表；同序压紧的 $\mathrm{d}z_{\mathcal{S}}$	Draft 同步训练的链首梯度
截断分布统计	在一个采样位置的 K_{top} 项上求所选 token 的 log-prob	K_{top} 项 logit、所选 token、温度	log-prob；可选熵与最大概率	RL rollout 记录的 log-prob
关闭	不工作	—	—	两项都不启用

3.1 监督梯度：在一行 logits 的参与列上形成 dz

3.1.1 三条要求

LOSS 的监督梯度只需满足三条要求（用户 11-02；条文用户 11-04 定，V18-LOSS-01 / 02）：

1. **计算量低**：
   - 满足第 2 条；

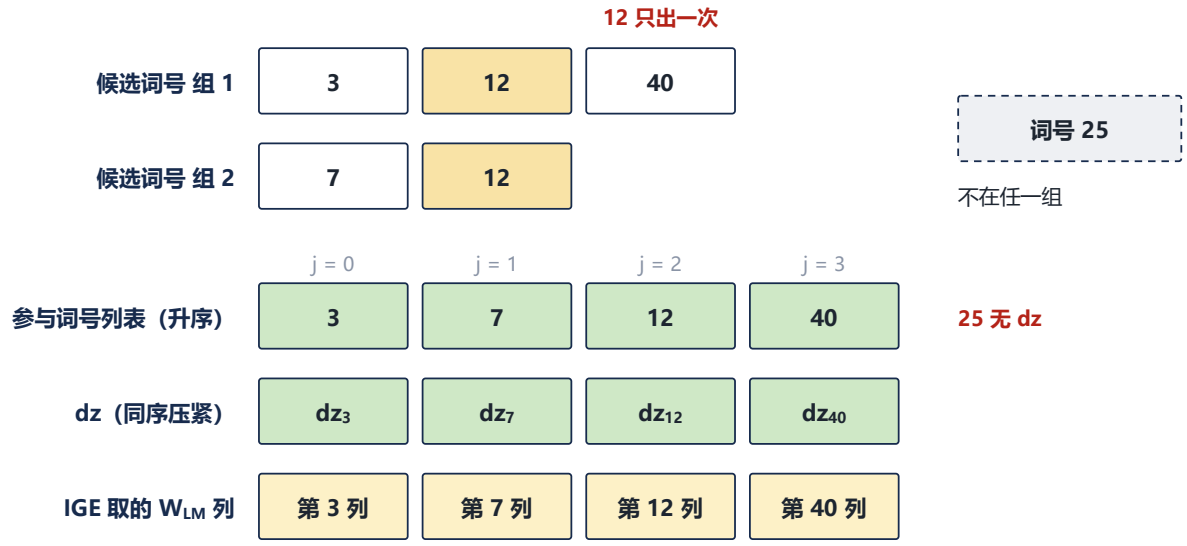
- **不反压 logit 流**；
- 门数建议值 ≤ 18 k 门（NAND2 等效），借用的 NLU 元件计入 NLU。

不规定处理时间的拍数预算，处理时间按 §5 与相关模块的设计者对接。

2. **不算 logits 的全部维度**：**LOSS 自身不对一行的全部 V_{vocab} 个 logit 逐项计算或逐项 exp。** 为出 TOPK 而跑的 LM Head 高位平面遍不计入（用户 11-02）。
3. **监督效果好**：同步训练后，Draft 接受长度 AL 相对对照基线的下降 < 0.1%。AL 是 Target 一次验证平均接受的 Draft token 数；对照基线是现行截断分布 teacher 方案按 FP32 理想值计算；量不出 0.1% 时以算法侧噪声带为准【待标定】。

3.1.2 输出合同：词号升序去重，dz 与列表同序压紧

- **参与词号列表按词号升序、去重。**
- $\mathrm{d}z_{\mathcal{S}}$ **与列表同序压紧**：第 j 个 $\mathrm{d}z$ 对应列表第 j 个词号；$\mathcal{S}$ 外不输出。IGE 按同一列表 gather $W_{\mathcal{S}}$，MXU 不再重排。
- $\mathrm{d}z$ 经 QNT 量化成**流动梯度格式**（反传梯在算子之间流动时的格式，默认 MXFP6 g32 单平面，可选 FP8 E4M3 / BF16 / FP16，格式集合在整体集成篇定义）。
- $\mathcal{S}$ **为空时不输出，不产生 NaN。**
- **参与词号列表是传输协议篇 §9.2 的 ③ 档变长对象**：对齐的单位是记录（用户 11-05，传输协议篇 §2.5、§9.1）——对象头单独占一个存储字；每个监督行的列表是一条记录，从整字起、占 $\lceil n_i/32 \rceil$ 个存储字、尾部补 0，不跨字、无字内偏移；记录内按词号升序紧凑排；每条记录的词号个数（即该行的 $|\mathcal{S}|$）由头给出，字段归数据组织篇。**源空间按实际长度由 CCU bump 分配，不预留**（用户 11-05，传输协议篇 §7.3）；上限（同一条 logit 流上两组流式 TOPK 的 k 之和，用户 11-05 认可）只用于编译期的静态检查与权重驻留下并发增长的 token 槽（传输协议篇 §9.7）。实际长度由本核 CCU 在列表写完时经命令与标量网报 MAE（对象长度报告），MAE 据此填 gather 命令的长度。



缩小例只画 1 个监督行。两组候选词号 {3, 12, 40} 与 {7, 12} 合并、去重、按升序排成列表 {3, 7, 12, 40}，$\mathrm{d}z$ 按同一顺序压紧成 4 项，IGE 按同一列表取 W_{LM} 的第 3、7、12、40 列。重复的词号 12 只出一次；列表外的词号 25 没有 $\mathrm{d}z$。$\mathrm{d}z$ 的值怎样算由选定算法决定，图中只用符号表示。

3.1.3 输入齐备才形成

某行的 $\mathrm{d}z$ 在选定算法所需的全部输入都已就绪之后才形成；**不读写到一半的记录**。

3.1.4 跨调用保存学生侧信息

算法需要跨调用保存学生侧信息时：

- 经上行写出，下次经 L1 读回；**消费前完整可读**；
- 字节数不超过数据组织篇给的训练区预算；
- 格式由生产者与消费者共同定义，并供 M55 解读。

3.2 截断分布统计：对 K_top 项分布求所选 token 的 log-prob

$$\ln p(y) = \frac{z(y)}{T_{\text{temp}}} - \ln \sum_{v \in \mathcal{K}} e^{z(v)/T_{\text{temp}}}$$

$\mathcal{K}$ 为该采样位置的 K_{top} 个候选项，y 为所选 token，T_{temp} 为采样温度。**只在 $\mathcal{K}$ 上归一化，不用全词表。** 贪心采样按同式给出，是否输出由指令给出。

- **可选：熵与最大概率。** 截断分布的熵 $H = -\sum_{v \in \mathcal{K}} p(v) \ln p(v)$ 与最大概率 $P_{\max}$，用来监视分布是否坍缩，不参与训练计算。**可选能力，默认关闭**；是否实现由设计者与算法侧按实验需要定（用户 11-04，V18-LOSS-04）。
- 不改变采样分布；不要求同时启用监督梯度。

	项 0	项 1	项 2	项 3
logit z	2	1	1	-1
z − max（max = 2）	0	-1	-1	-3
exp	1.0000	0.3679	0.3679	0.0498
概率 p	0.5601	0.2060	0.2060	0.0279

与项 1 并列，概率相同

和 = 1.7855　lse = 2 + ln 1.7855 = 2.5797

ln p(项 1) = 1 − 2.5797 = -1.5797

缩小例 $K_{\text{top}} = 4$、$T_{\text{temp}} = 1$，项 0…3 的 logit 为 2.0、1.0、1.0、−1.0，所选为项 1（logit 1.0，与项 2 并列）。先减去最大值 2.0 再求 exp，和为 1.7855，$\ln$ 和加回最大值得 2.5797；所选项的 log-prob 为 $1.0 - 2.5797 = -1.5797$。并列的两项概率相同，各为 0.2060。实际 K_{top} 参考 20。

3.3 关闭

两项功能都不启用时，LOSS 不工作。

4 精度要求、传输位宽与格式解码

4.1 精度要求：集成到算法后任务精度下降 < 0.1%

LOSS 的计算方案集成到算法后，任务精度下降 < 0.1%；中间计算精度不规定，由设计者定（用户 11-04，V18-VNU-01）。口径：

- 下降量按绝对百分点计；
- 基线为该模块各运算按 FP32 理想值计算的结果；

- 评测集为算法侧的标准评测集；
- 硬件实现与算法参考模型逐位一致，作为验证手段；参考模型随硬件实现同步。

对监督梯度，"任务精度"取 §3.1.1 第 3 条的 Draft AL。截断分布统计不设元件精度目标（用户 11-04，V18-LOSS-02）。

4.2 组内链路只限定位宽，格式由控制逻辑解码

LOSS 经组内链路收发的数据按每拍 256 bit 传输（§2.0）。**LOSS 的控制逻辑按指令解码收到的是什么格式、按什么精度处理，并按指令编码交出的数据。**

4.3 LOSS 须能解码的输入

以下是 LOSS 的解码能力，不作为口的定义：

类别	格式	来源
向量	BF16	logit 流、$z_{\mathcal{S}}$、名次项评分、截断分布的 logit
序号 / 词号	位宽覆盖词表（15 万词需 18 bit，现行 3 B）	名次项、所选 token
临时格式	由生产者与 LOSS 共同定义，供 M55 解读；设计者可选择在 QNT 统一成 BF16 / MXFP6（V18-VNU-01）	监督记录（现行为 teacher 概率，每项词号 3 B + 概率 3 B）、学生侧信息
标量	FP32 语义：结果与"按 FP32 计算、只在最后舍入一次"的参照一致，实现可用更窄的内部格式	合并值寄存器（CRU 合并值经 CCU 写入，FP32）、指令给出的温度

4.4 LOSS 交出的数据

- $\mathrm{d}z_{\mathcal{S}}$：BF16，交 QNT 量化成流动梯度格式（§2.1）。
- log-prob、熵、最大概率：FP32 语义标量。
- 参与词号列表：每项一个词号，位宽同 §4.3。

4.5 结果规则

- **同一行的结果只取决于该行的输入**，与 Batch 大小、同批其他行无关。
- 由 CCU 写入的合并值与消息到达次序无关。
- 与同步更新的算法参考模型逐位一致（§1.4）。
- $\mathcal{S}$ 为空时不产生 NaN。

5 速率与时延

5.1 每拍处理能力与处理时间匹配上下游模块

LOSS 每拍能处理的元素数和处理时间，须匹配上下游各口的需求，由 LOSS 设计者与以下模块对接确定（用户 11-04，V18-LOSS-01）。下表的参考值只作背景，不是 LOSS 的定值：

相关模块	接口	现行参考值
MXU 出口级	logit 流	15 万词 × 24 个 token 在约 10.8 ms 内送完，约 0.33 个/拍
QNT	链首梯度	统一请求接口每拍 16 个元素；参考 7 个监督行 × 84 项 = 588 个，约 37 拍
SMP	截断分布、统计结果	每个采样位置 K_{top} 次 exp 与 1 次 ln；SMP 所在 LM Head 尾段的时间需求（现行参考尾段第二段 ≤ 2,000 拍）
SEL	名次项、释放通知	名次项保持期间占用 SEL 的名次缓冲，LOSS 用完即通知释放
NLU	元件借用	借用时段由 CCU 与指令安排
MAE 的 IGE	参与词号列表	参考每拍 1 个词号；列表写完、长度报告到 MAE 的时点决定 W_S 的 gather 何时开始
CCU（合并值寄存器）	合并值	一次往返（NLU 结果寄存器 → CCU → CRU → CCU）；往返时延不定要求值，CRU 并行 lane 可配（传输协议篇 §6.4）
L1（经 VNU 的 RRAM 口）	监督记录、学生侧信息、上行数据	激活类读口 32 B/拍，与其他客户分时；读出固定 1 拍；入口将满时拉 stall_vnu[i]；写进集合器 FIFO，将满 wr_stall

5.2 LOSS 自己承诺：不反压 logit 流、不丢失

LOSS 不对 logit 流施加反压，也不丢失 logit。 这是 LOSS 能单方面保证的唯一速率承诺。

6 计数与复位

- **计数**：LOSS 不设计数。
- **复位**：清在线状态与归并状态，不跨调用保留。学生侧信息存在 DDR，不由 LOSS 持有。
- **不设运行时错误事件**：§2.3 所列前提由对应模块保证，验收时用断言检查。参与词号列表按实际长度 bump 分配，没有运行期上限（§3.1.2）。

7 要求值与验收

7.1 要求值

项	要求值	说明
运算形态	监督梯度、截断分布统计、关闭	由指令启用
计算量	不对一行全部 V_{vocab} 个 logit 逐项计算或 exp	为出 TOPK 的 LM Head 高位平面遍不计入
每拍处理能力与处理时间	匹配上下游各口（§5.1）	由 LOSS 设计者对接确定
logit 流	不反压、不丢失	—
监督效果	Draft AL 相对对照基线下降 < 0.1%	【待标定】
精度	集成到算法后任务精度下降 < 0.1%（绝对百分点）	中间精度由设计者定

项	要求值	说明
组内链路	每拍 256 bit + 握手位	全组统一
L1 口与握手	RRAM 口：读经激活类读口，每条由 CCU 发读的入口一根 stall_vnu[i]；写进 A 类写集合器里本单元的入口 FIFO（只给 din 与长度），将满 wr_stall 回本单元	L【设计者定】
CRU 的合并值	合并值寄存器（CCU 写），FP32，不落 L1；LOSS 不设结果寄存器、在命令与标量网上无端口、无有效位	传输协议篇 §8.1、§8.2
门数	建议值 ≤ 18 k 门（NAND2 等效），另加 < 1 KB 状态	借用的 NLU 元件不计

7.2 验收

对象	方法	用例
输出合同（§3.1.2）	断言	列表升序、去重；$\mathrm{d}z$ 与列表同序；$\mathcal{S}$ 外无输出；$\mathcal{S}$ 为空时无输出、无 NaN；对象头单独占一个存储字、每条列表记录从整字起尾部补 0；bump 分配下相邻对象首尾相接
计算量（§3.1.1）	审查	无全词表逐项计算或 exp
不反压 logit 流（§5.2）	周期仿真	logit 流峰值注入，同时形成链首梯度
输入齐备（§3.1.3）	断言	输入未齐时不形成 $\mathrm{d}z$；不读写到一半的记录
截断分布 log-prob（§3.2）	与算法参考模型逐位比对	不同 K_{top} 与温度；并列 logit；贪心采样
结果规则（§4.5）	逐位比对	Batch 1 / 8 / 32 结果相同；合并值到达次序不同时结果相同
监督效果（§3.1.1）	算法侧回放对拍	同模型、同数据、同调用配置的同步训练
集成精度（§4.1）	算法侧评测	目标模型在标准评测集上下降 < 0.1%
门数（§7.1）	综合	待 RTL

8 为什么

- **只规定要求、不规定方案**（用户 11-02）：监督损失的算法还在演进，硬件固定一种算法会限制算法侧。所以本篇只规定计算量、监督效果与输出合同。设计 Spec 保留现行算法基线（两级 lse、截断分布 teacher 等），作为监督效果的对照。
- **不算全部维度**：词表有十几万项，LOSS 若对每个位置逐项处理，会成为训练的主要开销；为出 TOPK 的 LM Head 高位平面遍在前向本来就要跑，不计入。
- **词号与梯度同序**：IGE 按列表直接 gather $W_{\mathcal{S}}$，$\mathrm{d}z$ 按同一顺序到达 MXU，MXU 不必再重排。

- **log-prob 按截断分布**：采样只在 K_{top} 项上进行，rollout 记录的 log-prob 必须与实际采样空间一致，训练端才能算对重要性比。
- **入口梯度不经 LOSS**：独立训练的损失由 M55 算，NPU 从入口梯度直接反传。
- **dz 交 QNT 量化**（用户 11-04）：VNU 组内向量的量化统一由 QNT 执行，LOSS 不另设量化器。
- **组内链路只限定位宽**（用户 11-04）：格式由两端控制逻辑按指令解码，换算法、换格式不改链路。
- **精度按集成后掉点要求**（用户 11-04）：$\mathrm{d}z$ 与 log-prob 都要经过量化或只作统计用，元件误差只需明显小于下游影响，所以不规定元件误差界。
- **速率由设计者对接**（用户 11-04）：LOSS 所在的 LM Head 尾段由 SMP、SEL、NLU、MAE 共同决定，拍数预算不由 LOSS 单方面决定，所以本篇列出相关模块与参考值，只保留"不反压 logit 流"这一项自身承诺。
- **对外接口经 VNU 组封装**（用户 11-04）：LOSS 访问 L1、向核外上行都经 VNU 的共用口；对外口怎样划分由 VNU 集成篇统一定义。
- **按传输协议篇同步**（用户 11-05，V18-TP-01…16）：核内与 L1 之间只有 RRAM 一种口，地址只在 CCU 一处推理；CCU 不看下游余量，所以每条入口给 CCU 一根 stall；CRU 的合并值是几个 FP32，不经 L1（11-05 用户定 LOSS 不设结果寄存器）；参与词号列表长度运行期才知道，所以按实际长度 bump 分配、实际长度由 CCU 报 MAE（第二轮，用户 11-05：已知长度后上限分区没有意义）；写侧改为集合器 FIFO 与 wr_stall。
- **标量经 CCU 中转**（用户 11-05："直接发给 CCU，由 CCU 直接配置 VNU 内部需要计算数据的寄存器吧……VNU 的控制命令本来就来自 CCU，那么刚好可以统一调配"，V18-TP-21）：LOSS 在命令与标量网上不设端口；合并值到达与使用它的指令在 CCU 一处排序，LOSS 不需要有效位、不因标量未到而 stall。