VNU 非线性单元（NLU）需求

> Owner: WangYizhao｜2026-11-04｜重写稿，待用户审阅。按用户 11-04 确认的目录编写（`../V17_3_MODULE_TOC_VNU_NLU_20261104.md` 第二版）；改变现行设计的事项汇总在 `Claude_Design_Spec/V1.8_DESIGN_REVISIONS.md`（V18-NLU-01…04、V18-VNU-01）。
> 11-05 按片上数据传输协议篇（`DATA_TRANSFER_PROTOCOL.md`，V18-TP-01…16）同步：与 L1 的口改为 RRAM 口、地址由 CCU 推理、入口 stall；交 CRU 的标量与合并值改走命令与标量网；嵌入行经 IDN 落地 L1 后读入（§1.4、§2、§3.2–§3.4、§5、§8）。
> 11-05 晚第二轮同步（协议篇 §2.1、§3.2、§4.2、§7.3、§9.7，V18-TP-17…20）：32 B 单位改称存储字；读经激活类读口、写进 A 类写集合器里本单元的入口 FIFO、wr_stall 回本单元（§2、§5、§7）。
> 11-05 第三轮同步（协议篇 §4、§6.1、§6.4、§8.1、§8.2，V18-TP-21 / 24）：交 CRU 的标量双向经 CCU 中转——部分值放结果寄存器由 CCU 读出发 CRU，合并值由 CCU 写进合并值寄存器，NLU 在命令与标量网上无端口；"反压"作机制名处改称握手（§2、§3.2、§3.4、§4、§5、§7、§8）。
> 11-05 夜（V18-D-01、V18-NLU-05）：深度卷积（DFlash2 动态卷积、GDN 短卷积）本体在 MXU 的逐通道 FIR，NLU 只合成动态系数；GDN 层的状态更新暂不写实现需求，留给 MXU、NLU、CCU 的设计者后续设计；每拍元素数为参考值、可加大（§1.1、§2.3、§3.1、§5.1、§7.1、§8）。

1 组成与位置

1.1 NLU 做两次矩阵乘之间的非矩阵、非选择运算

NLU（Nonlinear Unit，非线性单元）做**两次矩阵乘之间所有非矩阵、非选择的运算**：

- 逐元素函数，例如激活与门控乘；
- 沿一条向量的归约与归一化，例如 RMSNorm；
- 按位置的二维旋转，例如 RoPE；
- attention 的在线 softmax 与输出累加；
- 跨向量的流式累加，例如区块摘要。

比较与判决交 SEL（含 keep：按门限决定下一位点输入的各通道是否保留），量化与按判决位压紧、打包交 QNT；NLU 不做矩阵乘、不搬数据。 深度卷积（DFlash2 的动态卷积、Gated DeltaNet（GDN）的短卷积）本体在 MXU 的逐通道 FIR，NLU 只合成动态卷积的系数（用户 11-05）。**GDN 层的状态更新（每个头一个状态矩阵逐 token 递推）由 MXU、NLU、CCU 的设计者后续设计，本篇暂不规定 NLU 承担哪些步骤**（用户 11-05）。NLU 也不做跨核合并（CRU）、采样、loss 与参数更新（SMP、LOSS、OPT），不发 DDR 请求，不参与调度。

1.2 NLU 是 VNU 组的一个单元，每核一个

一个计算核由 CCU、MXU 组、L1 组、VNU 组四组拼成。NLU 是 VNU 组的六个单元之一，其余五个是 SEL、QNT、SMP、LOSS、OPT。**NLU 与 VNU 组外的模块交换数据，都经 VNU 组的对外接口**；访问 L1 和向核外上行，经 VNU 的共用口。VNU 对外口的个数与共享方式，由 VNU 集成篇定义（待写）。

每个计算核一个 NLU，全芯片 4 个，物理相同。

1.3 固定运算元件加可装载序列，组合出各种运算

NLU 由一组固定的运算元件和可装载的序列组成。**序列**是一段运算步骤：一条向量依次经过哪些元件、各步参数从哪来、结果交给哪个去向。同一组元件按不同序列组合出 §3 的五种运算形态；**新模型的新算子只要能由现有元件表达，就只换序列、不改硬件。**

序列与**参数表**（γ、ϵ_{norm}、旋转表、近似系数与查找表）都是编译产物。**每个位点跑哪条序列、用哪张参数表，由指令给出**；**位点**是一层里的一个算子实例，例如 gate/up 投影、一段 attention。元件的种类、个数与近似方法由设计者定。本篇不写序列格式与指令字段，指令定稿后另补。

NLU 同一时刻只执行一种功能（用户 11-04）：一次跑一条序列，先后由指令与 CCU 排定。VNU 内各单元都按此原则；以后有并行需求时再调整。

1.4 NLU 独占 attention 行状态

attention 的**查询行**是 Q 的一行：一个 token 在一个 q 头上的 d_h 个元素，d_h 为 head_dim（128 / 256 / 512）。NLU 为每个查询行保存 **attention 行状态**：

- 行最大值 m_{run}：本行已到达分数的最大值；
- 行和 l：本行 softmax 分母的累加值；
- 输出累加值 O：d_h 维。

行状态存在 L1 的 A 类空间里编译链分配的一段地址，**由 NLU 独占读写**，别的单元不读不写；读改写按 L1 的两堆规则做——从一堆读旧值、向另一堆写新值（用户 11-04，V18-L1-02）。读哪堆、写哪堆由 CCU 给的地址的堆位显式选，L1 没有堆角色状态；两堆按 tile 切换，切换条件 = 写完成 ∧ 最后读者完成，由 CCU 在下一 tile 的地址堆位里体现（传输协议篇 §2.2、§7.1）。行状态是 ② 档固定槽对象（传输协议篇 §9.2）。存储格式由设计者定，参考每行 $2d_h + 8$ B（O 为 BF16，m_{run} 与 l 为 FP32；head_dim 128 时 264 B）。

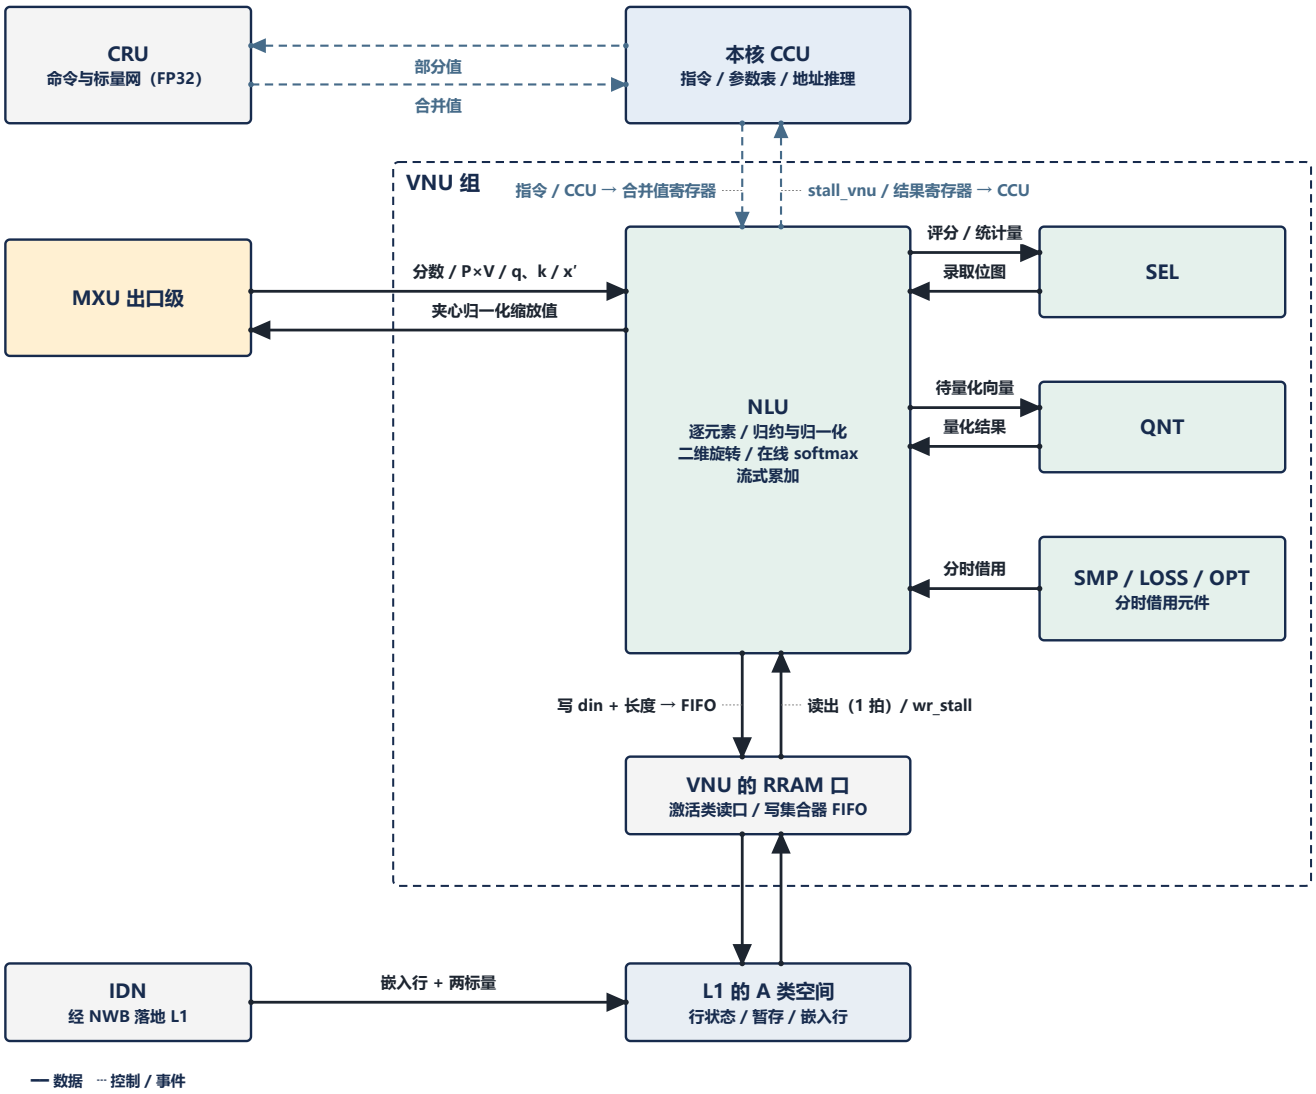
1.5 与 OPT 的合作通路

NLU 的元件可为 OPT 计算，例如梯度裁剪系数所需的开方与除法。**NLU 与 OPT 怎样合作或折叠，由指令设计考虑，具体指令由两个模块的设计者配合确定；本篇只留出这条通路。** 裁剪系数的计算与使用属于 OPT 的功能，见 OPT 篇。

1.6 元件可分时供 SMP、LOSS 使用

NLU 的元件可分时供 SMP、LOSS 的序列使用，**NLU 只执行**。使用时段由 CCU 与指令安排，借用时段内 attention 不运行（§2.3）。

2 数据从哪来、到哪去



虚线框是 VNU 组：

- **框内**是 NLU，以及和它直接往来的 SEL、QNT 和 SMP / LOSS / OPT。后三者只分时借用 NLU 的元件，合画一个框。这些连线不出 VNU 组。
- **跨出框的连线**都是 VNU 组的对外接口：
  - 左侧：与 MXU 出口级（MXU 在阵列出口缓冲之后的一段，只做 BF16 域的残差加与路由）的一进一出；入站分发网（Inbound Distribution Network，IDN）送来的嵌入行先由 L1 的接收桥 NWB 落地 L1，NLU 再从 L1 读入；交跨核归约单元（Cross-Core Reduction Unit，CRU）合并的标量**经本核 CCU 中转**（用户 11-05，传输协议篇 §6.1、§8.1）：NLU 把部分和放进**本单元的结果寄存器**，由 **CCU 读出、经命令与标量网发 CRU**；合并值回到 **CCU 的短消息队列，由 CCU 按类型与 token / 轮标签写进 NLU 的合并值寄存器**，再发出使用该值的指令。**NLU 在命令与标量网上没有端口**，部分和与合并值都不落 L1；
  - 上方：本核 CCU 给的指令与参数表（虚线），以及 NLU 给 CCU 的入口 stall；CCU 读结果寄存器、写合并值寄存器也画在这一侧（图中 CRU 只与 CCU 相连）。
- **下方的 L1 口**：NLU 不直接连 L1 或核上行链路（C2H），而是经 **VNU 的 RRAM 口**（RRAM 即核内 SRAM 口协议，传输协议篇 §3）访问 L1 的 A 类空间：读经 L1 外的选择器用一个激活类读口（4 个读口都可读任一 A 类 bank，撞 bank 由 CCU 排开）；**写**进 L1 的 A 类写集合器里本单元自己那条 32 B 入口 FIFO，集合器每拍按优先级把各写者的队头分到对应 bank 的道上，FIFO 将满时拉 **wr_stall** 回本单元（只到本单元，不到 CCU；传输协议篇 §3.2）。要出核的数据一律先写 L1，由 L1 发送侧经 C2H 发出（MAE 的发送命令直接送本核 CCU，由 CCU 发读）（用户 11-04 / 11-05，V18-L1-03、传输协议篇 §6.1）。

2.1 VNU 组内的接口

接口	对端	方向	内容	元素格式
评分与统计量	SEL	出	FFN 评分 $\lvert\mathrm{SiLU}(\tilde{g})\rvert$ 与 $\lvert\tilde{s}\rvert$（§3.1）；区块能量 $\mathcal{E}_J$（§3.5）；token 复用比值 s_{self}（§3.4）；判别器（一个旁路小分类网络，矩阵部分在 MXU）的三类分数；相对阈值所用的统计量，例如 Q 一行的 $\mathrm{mean}_d\lvert q_d\rvert$、下一位点保留判断所用的 $\sum\lvert x\gamma\rvert$（§3.2，用户 11-04）；Q 一行的逐维幅值 $\lvert q_d\rvert$，取 RoPE 之后、量化之前的值（用户 11-04）	BF16
录取位图	SEL	入	哪些 key 被录取（§3.4）；P' 只对录取 key 折出，连同 key 位置交 QNT 组装 P' 记录	每 key 1 bit
待量化向量	QNT	出	需要量化的结果，连同目标格式；K 读时旋转时另交待解码的 K 存储码（§3.3）。**序列以"交 QNT 量化"一步结尾，NLU 内不设量化器**	BF16；K 存储码为 MXINT8 g32 的 hi / lo 平面
量化结果回送	QNT	入	$\tilde{p}$ 两平面量化值之和（按 key，§3.4）；解码后的 K；归约完成的投影结果、q 与梯度	MXFP6 g32 或 BF16（§4.2）
元件借用	SMP、LOSS、OPT	入 / 出	分时使用 NLU 的元件（§1.5、§1.6）	—

2.2 经 VNU 组对外的接口

接口	对端	方向	内容	元素格式
出口向量	MXU 出口级	入	精确分数（§3.4）；区块打分的粗分数（§3.5）；$(P\times V)_{\text{tile}}$，带（行号, 列块号）标签（§3.4）；q、k 的投影结果；残差加结果 x'（投影结果加回残差之后的向量）；夹心归一化位点的投影结果（§3.2）。**每拍至多 16 个元素**	BF16
夹心归一化缩放值	MXU 出口级	出	缩放后的投影结果，出口级再与残差相加（§3.2）	BF16
L1 读写	读：L1 外选择器 → 激活类读口；写：A 类写集合器里 NLU 的入口 FIFO	入 / 出	见下文	整字 32 B；内容格式见 §4
写握手	L1 的 A 类写集合器	入	NLU 那条入口 FIFO 将满时的 wr_stall	1 bit
结果寄存器（CCU 读）	本核 CCU：读出后经命令与标量网发 CRU（用户 11-05）	出	要跨核合并的部分值：attention 部分状态 (m_{run}, l)；层入口归一化的 $\sum x^2$ 与 $\sum\lvert x\gamma\rvert$ 部分和（§3.2）；梯度平方和 $\sum g^2$ 部分和（**只在 NLU 累加，OPT / LOSS 不另设结果寄存器**，用户 11-05 定）。不落 L1；就绪由 CCU 按产出指令完成推断，NLU 不发事件（用户 11-05）	FP32；在网上由 CCU 按 ② 档槽宽打包（每 64 bit 字 2 个，传输协议篇 §8.6）
合并值寄存器（CCU 写）	本核 CCU：CRU 的合并值进 CCU 短消息队列，CCU 按类型与 token / 轮标签写入（用户 11-05）	入	CRU 合并后的标量；CCU 写好后才发出使用它的指令，**NLU 不设有效位、不因标量未到而 stall**	FP32

接口	对端	方向	内容	元素格式
嵌入行	IDN → L1 接收桥 NWB 落地 L1，再经 RRAM 口读入	入	嵌入行，以及随行尾到达的两个标量（第 0 层的 $\sum x^2$ 与 $\sum\lvert x\gamma\rvert$，§3.2）	嵌入行 MXFP6 g32；标量 FP32 语义
指令	本核 CCU	入	序列选择、屏蔽位等指令	—
入口 stall	本核 CCU	出	每条由 CCU 发读的入口一根 stall_vnu[i]	1 bit
参数表	本核 CCU	入	γ、ϵ_{norm}、旋转表、近似系数与查找表，带版本（§4.4）	—

NLU 经 VNU 的 RRAM 口访问 L1 的 A 类空间：

- 读：V 尺度表、行状态、分数暂存、CRU 归约值（K 切分的归约结果，是数据，由 hub 经 H2C 写进 L1，传输协议篇 §6.1）、区块摘要部分和、夹心归一化暂存、经 IDN 落地的嵌入行；K 在 RoPE 之前量化存储时，读未旋转的 K 存储码（§3.3）；
- 写：行状态、分数暂存、区块摘要部分和、夹心归一化暂存。lse 的跨核合并就是 (m_{run}, l) 状态合并：部分状态放结果寄存器，经 CCU 交 CRU，合并值由 CCU 写进 NLU 的合并值寄存器后再算 lse（§3.4，传输协议篇 §8.1），不经 L1。

RRAM 口的用法（传输协议篇 §3、§4）：

- L1 没有仲裁：读经 L1 外的选择器用激活类读口（每口 32 B/拍，从一堆读旧值），读时隙由 CCU 排；**写**进 L1 的 A 类写集合器里本单元自己那条 32 B 入口 FIFO，集合器每拍按优先级把各写者的队头分到对应 bank 的道上，FIFO 将满时拉 **wr_stall** 回本单元（只到本单元，不到 CCU；传输协议篇 §3.2），向另一堆写新值（用户 11-04 / 11-05，V18-L1-02）；VNU 对 L1 的口怎样划分，由 VNU 集成篇定义。
- **每次读写的 en / wea / addr 都由本核 CCU 发出，读出的 dout 送哪条入口也由 CCU 定**；NLU 写 L1 时只给 din（一个存储字，32 B）与本条记录的长度；FIFO 将满时 NLU 保持 en / wea / addr / din。读出固定 1 拍到达。
- **每条由 CCU 发读的入口给 CCU 一根 stall_vnu[i]**，入口缓冲占到"深度 − L"时拉起；L = CCU 停发 1 拍 + L1 读返回 1 拍，【设计者定】。写侧只有本单元 FIFO 的 wr_stall，不到 CCU；同一阶段并发写者总需求 ≤ 道数 × 32 B/拍由编译链保证。
- 各地址段的基址与长度由指令给出（编译链分配），容量建议值见 §7.1。

2.3 由别的模块保证的事项

以下事项 NLU 不检查，由对应模块保证：

事项	由谁保证
量化、按判决位压紧与打包；Q 粗算记录与 P' 记录的组装与写出	QNT
keep 判断（下一位点输入各通道的保留）	SEL
比较与判决	SEL
屏蔽位的内容（§3.4）	指令
$(P \times V)_{\text{tile}}$ 条目带（行号, 列块号）标签	MXU 出口级
P×V 在该更新组的 P' 记录写完后才放行；序列在位点边界切换；算子融合与放行先后	CCU 与指令
同一单元的不同功能不在时间上重叠	CCU 与指令
参数表的装载时机	LIC
标量跨核合并的次序	CRU
读结果寄存器发 CRU；合并值按类型与标签写进合并值寄存器， 写好后才发使用它的指令	CCU（传输协议篇 §8.2、§11）
读写 L1 的地址（基址 + 字节累加、环形回绕）与 dout 去向	CCU
区块摘要未收满部分和的跨次写回与读回，次序不变	MAE

事项	由谁保证
K 存储码搬入本核 L1（只按字节搬运，不做变换）	MAE
旋转后的 K 量化、写本核 L1，由 L1 发送侧经 C2H 写 L2，再由 MAE 命令经 H2C 多播进需要的核的 L1；K 存储码的解码	QNT、L1 发送侧、MAE（用户 11-04，V18-L1-05）
K 读时旋转按核调度，与 K 落地、粗分数计算的先后	LIC 与 CCU
A 类各地址段的分配，以及写入前旧数据已读完	编译链（指令中的基址与长度，LIC 操作 15）
借用时段内 attention 不运行	CCU 与指令
VNU 对外口的个数与共享方式（RRAM 读侧经选择器接哪个激活类读口；写侧在集合器里的优先级）	VNU 集成篇（待写）；集合器优先级表由 CCU 随位点命令装
临时格式统一转换成 BF16 / MXFP6（若设计者选用，§4.2）	QNT
深度卷积本体（DFlash2 动态卷积、GDN 短卷积及其反传，逐通道 FIR）	MXU
GDN 层状态更新在各模块之间的分工	MXU、NLU、CCU 的设计者后续设计（用户 11-05）

3 运算形态

一个位点之后通常跑一到三条序列，例如归一化 → 旋转 → 交 QNT 量化。各种用途都是下面五种运算形态换了序列与参数，同一形态的不同用途不另设机制：

运算形态	按矩阵维度说做什么	输入	输出	典型用途
逐元素运算	对一条或两条同长向量逐元素计算，元素之间不交换数据	向量、标量参数	同长向量	FFN 门控与评分、嵌入的 $\sqrt{d_{\text{hidden}}}$ 缩放、GDN 门与每层嵌入（PLE）门控、DFlash2 动态卷积系数合成、判别器隐层激活、K 减均值、P' 折叠、反传导数
沿向量的归约与归一化	沿一个 token 的 hidden 维（d_{hidden} 个元素）或一个头的 head_dim（d_h 个元素）求统计量，再用统计量缩放这条向量	向量；统计量（本核算出、经 CRU 合并后回送或随数据到达）	统计量；缩放后的向量	层入口 RMSNorm、按头归一化、夹心归一化、相对阈值的行均值、梯度范数、判别器归一化
二维旋转	把向量里成对的两维看作二维坐标，按位置给出的角度旋转	向量、位置	同长向量	q / k 位置编码、K 读时旋转（K 在 RoPE 之前量化存储时）、K 段位移复用、反传
在线 softmax 与 attention 输出累加	对分数矩阵 $S = QK^{\mathsf{T}}$ 的一行按 key 分组到达做 softmax，同时把 PV 累加进该行的 O	精确分数、$(P \times V)_{\text{tile}}$、QNT 回送的量化值	P' 与 $\tilde{p}$（交 QNT）、O/l、lse、token 复用比值	attention

运算形态	按矩阵维度说做什么	输入	输出	典型用途
跨向量的流式累加	一串向量逐通道累加到一个状态向量	一串向量；读回的部分和	状态向量； 区块结束时的摘要	区块摘要、 区块能量、dK / dV 跨 chunk 累加

3.1 逐元素运算：每个元素独立计算

- **激活**：SiLU $\mathrm{SiLU}(x) = x\,\sigma(x)$，其中 $\sigma(x) = 1/(1+e^{-x})$；GELU 的 tanh 近似 $\mathrm{GELU}(x) \approx \frac{1}{2}x\big(1+\tanh(\sqrt{2/\pi}\,(x+0.044715\,x^3))\big)$；sigmoid；tanh。**SiLU、GELU tanh 近似、sigmoid、tanh 必须支持**；GELU 的 erf 形式 $\frac{1}{2}x\,(1+\mathrm{erf}(x/\sqrt{2}))$ 由现有元件以序列拼出（用户 11-04）。
- **门控乘**：$\tilde{s} = \tilde{u} \odot \mathrm{SiLU}(\tilde{g})$。$\tilde{g}$、$\tilde{u}$ 是 gate、up 两个投影的输出（一个 token 一行，d_{ff} 个元素）。FFN 评分 $|\mathrm{SiLU}(\tilde{g})|$ 与 $|\tilde{s}|$ 以 BF16 交 SEL 判决，不另量化；$\tilde{s}$ 交 QNT 量化。
- **算术**：加、减、乘、乘加、按标量缩放、绝对值、平方、饱和。
- **加减通道均值**：减去或加回一个逐通道均值向量 μ（每个通道一个值），例如 K 在旋转之后减均值。
- **通道置换**：按编译期固定的置换表重排一条向量的通道。
- **尺度折叠与反量化**：乘一个 2 的幂尺度，只加指数，例如 $P'_j = \tilde{p}_j \cdot S_{V,j}$（§3.4）；反量化即码 × 尺度。
- **逐元素导数**：$\mathrm{SiLU}'(x) = \sigma(x)\big(1+x(1-\sigma(x))\big)$、GELU′，用于反传。
- **动态卷积系数**：DFlash2 的两抽头动态卷积，系数 $k_{\mathrm{dc}} = k_{\mathrm{dc,base}} + \delta_{\mathrm{dc}}$ 由 NLU 逐元素相加得出，交 QNT 量化后写 L1；**卷积本体在 MXU 的逐通道 FIR，NLU 不做卷积**（用户 11-05，V18-D-01）。

3.2 沿向量的归约与归一化：先求统计量，再缩放

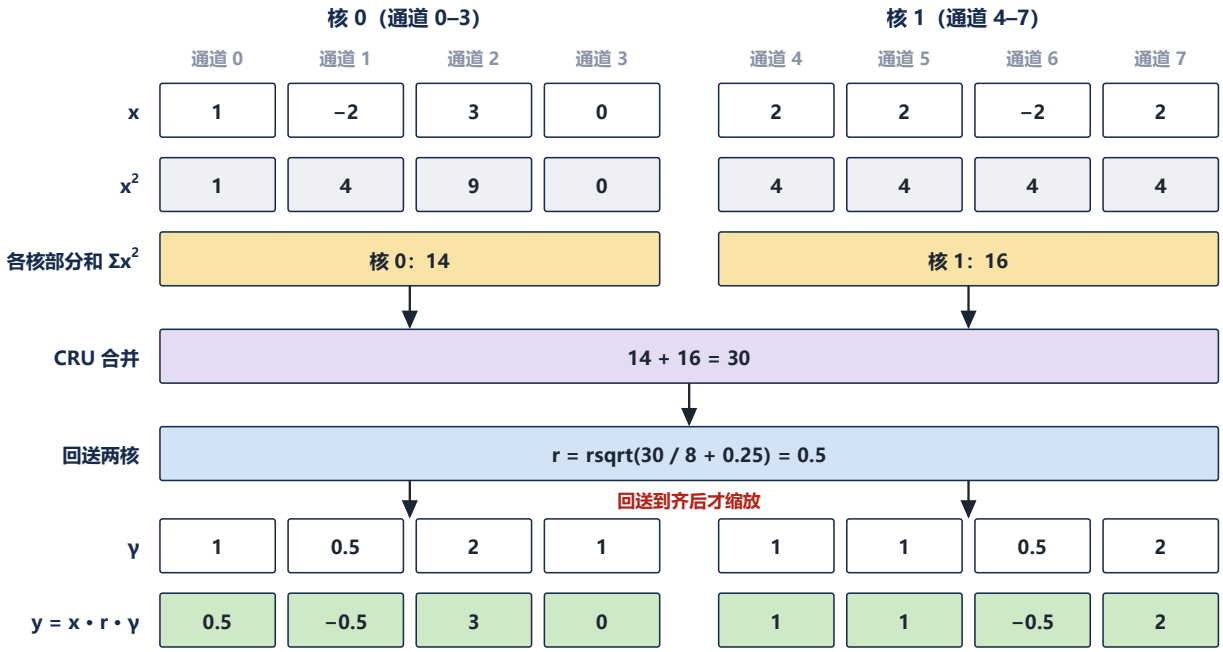
归约维是一个 token 的 hidden 维，或一个头的 head_dim（d_h = 128 / 256 / 512）。NLU 沿归约维求 sum、max、均值，以及 MX 组（32 个元素）内的最大幅值 amax，并用统计量做归一化：

- **RMSNorm**：$y_i = x_i \cdot \mathrm{rsqrt}\Big(\frac{1}{d}\sum_j x_j^2 + \epsilon_{\mathrm{norm}}\Big) \cdot \gamma_i$，$d$ 为归约维长度，γ、ϵ_{norm} 取自参数表。
- **QK-Norm**：对 q、k（以及带 v 归一化的模型里的 v）按头做 RMSNorm，归约维为 d_h。
- **LayerNorm**：$y_i = (x_i - \bar{x}) \cdot \mathrm{rsqrt}(\sigma_x^2 + \epsilon_{\mathrm{norm}}) \cdot \gamma_i + \beta_i$，$\bar{x}$、$\sigma_x^2$ 为沿归约维的均值与方差。
- $1+\gamma$ **变体**：RMSNorm 中 γ_i 换成 $1+\gamma_i$。

统计量有三种来源：

1. **本核算出**：整条向量都在本核，例如按头的 QK-Norm。
2. **各核部分和经 CRU 合并后回送**：一个 token 的 hidden 维分散在几个核上，例如层入口 RMSNorm。各核对自己持有的通道求部分和（FP32），**放进 NLU 的结果寄存器，由本核 CCU 读出、经命令与标量网发 CRU 合并；合并值回到各核 CCU 的短消息队列，由 CCU 写进 NLU 的合并值寄存器，不落 L1**（用户 11-05，传输协议篇 §8.1）。层入口用两个标量：平方和 $\sum x^2$，以及供下一位点 keep 判断使用的增益加权绝对值和 $\sum|x\gamma|$，由 NLU 交 SEL 作相对阈值的统计量。
3. **随数据到达**：第 0 层的两个标量预先算好存在嵌入表里，随嵌入行的行尾经 IDN 落地 L1，NLU 随嵌入行一并读入，只转发、不重算。

统计量到齐后才缩放。 到齐由 CCU 判断：CCU 把合并值写进合并值寄存器后才发出缩放的指令，NLU 不设有效位、不因标量未到而 stall。回送到齐之前，待缩放的向量暂存在 L1 的 A 类空间；暂存容量【设计者定】，地址由指令给出。缩放后的向量交 QNT 量化；**夹心归一化**（o / down 投影之后、残差加之前另做一次 RMSNorm 的模型结构，如 Gemma 类）的缩放值则交回 MXU 出口级，由出口级再与残差相加。



缩小例：一条 8 通道的向量，核 0 持通道 0–3，核 1 持通道 4–7；实际 hidden 维为几千（例如 2,560），分在参与计算的各核上。ϵ_{norm} 取 0.25 只为好算，实际约 10^{-6}。

- 两核各算平方和部分和 14、16，CRU 合并得 30。
- $r = \text{rsqrt}(30/8 + 0.25) = 0.5$ 回送两核。
- 两核各用 r 与自己通道的 γ 缩放，结果与单核对整条向量直接计算相同。

核 0 若不等回送、只用自己的 14 按 4 个通道算，会得到 $\text{rsqrt}(14/4 + 0.25) \approx 0.516$，结果错误。

归约类的其他运算：

- **归一化的导数**：RMSNorm′、QK-Norm′ 需要一次沿归约维的归约。以 RMSNorm 为例，$\mathrm{d}x_j = r\,\gamma_j\,\mathrm{d}y_j - \frac{r^3}{d}\,x_j \sum_i x_i \gamma_i\,\mathrm{d}y_i$，其中 $r = \text{rsqrt}(\frac{1}{d}\sum_i x_i^2 + \epsilon_{\text{norm}})$。
- **softmax′ 的行内归约**：P 为 softmax 概率矩阵（行为查询行，列为 key），$\mathrm{d}P$ 为它的梯度。NLU 先求 $D_i^{\text{sm}} = \sum_j P_{ij}\,\mathrm{d}P_{ij}$，再逐元素算 $\mathrm{d}S_{ij} = P_{ij}\,(\mathrm{d}P_{ij} - D_i^{\text{sm}})$。
- **梯度平方和部分和**：对本核持有的梯度矩阵累加 $\sum g^2$（FP32），放结果寄存器，经 CCU 交 CRU 合并；合并值由 CCU 写进 OPT 的合并值寄存器，使用归 OPT（§1.5）。
- **相对阈值所用的行均值**：SEL 的相对阈值判断需要本域均值时，由 NLU 求好交 SEL。例如对 Q 的一行沿 d_h 维选维时，NLU 求 $\text{mean}_d|q_d|$，SEL 再与逐维幅值 $|q_d|$ 比较。**两者同源：都取 RoPE 之后、量化之前的 BF16 值**（用户 11-04）。

3.3 二维旋转：按位置旋转成对的两维

把向量中成对的两维 (a_i, b_i)（哪两维成对随模型而定，由参数表给出）看作二维坐标，旋转角度 $\theta_i = p\,\omega_i$，p 为位置，ω_i 取自旋转表的频率：

$$a_i' = a_i \cos\theta_i - b_i \sin\theta_i, \qquad b_i' = a_i \sin\theta_i + b_i \cos\theta_i.$$

- **正向旋转**：可只旋转前若干维，其余维不变。
- **按位置差重旋转**：已旋转到位置 p 的向量再转 $\theta_i = \Delta_{\text{pos}}\,\omega_i$，即得位置 $p + \Delta_{\text{pos}}$ 的结果。用于已存的 K 段换到新位置复用。
- **逆旋转**：θ_i 取负，用于反传（RoPE′）。
- **位置 = 基址 + 记录内偏移**，基址与偏移由指令与记录给出。

K 读时旋转（用户 11-04）。K 可以在 RoPE 之前量化存储：QK-Norm 之后、旋转之前，由 QNT 量化成 MXINT8 g32 的高位、低位两个 4 bit 平面（hi / lo），另每个 key 1 B 的 kmax。这时从 L1 读出的 K 存储码还没有旋转，NLU 在使用前先做读时旋转。**它与本次新算出的 K 走同一条链，只是输入不同**：

1. 解码：由 QNT 把存储码重建成数值；
2. 加回源均值：若写入时减过；
3. 按 key 的绝对位置旋转；
4. 减目标均值：可配；
5. 交 QNT 量化：通道置换若用，在量化时施加。

两段用法：

段	输入	重建	输出
粗算段	本核负责的那部分 key 的 hi 平面、E8M0 与 kmax	只用 hi 平面	量化后只取 hi 平面 + E8M0 + kmax，写本核 L1，由 L1 发送侧经 C2H 写 L2，再经 H2C 多播进需要的核的 L1 的 W 类空间，供粗分数计算
精算段	录取 key 的 hi 与 lo 平面	用全部数字	量化成完整的 hi + lo，同上路径写 L2、多播进需要的核的 L1，供精确分数计算

旋转后的 K 由 QNT 写本核 L1，再由 L1 发送侧按 MAE 的发送命令经 C2H 写 L2，由 MAE 命令经 H2C 多播进需要的核；NLU 不写 K 的存储区。 K 存储码由 MAE 只按字节搬入本核 L1；多个核需要同一批 K 时，key 可按核切分，各核旋转自己那一部分后互相多播，不重复旋转（用户 11-04，V18-L1-05）。位置来源（随 K 流读入的位置数组，或段基址 + 偏移）【待确认】；旋转后作粗分数的精度【待标定】。

3.4 在线 softmax 与 attention 输出累加：分数分组到达，按更新组统一基准

attention 按 AW 写法为 $S = QK^{\mathsf{T}}$、$P = \mathrm{softmax}(S)$（按行）、$O = PV$，其中 Q 为 $T \times d_h$，K^{T} 为 $d_h \times N$，V 为 $N \times d_h$，T 为查询行数，N 为 key 数。对一个查询行：

- **录取 key** 是 SEL 为该行选中的 key；
- **精确分数** A_j 是该行对录取 key j 的分数，由 MXU 用 K 的全部数字算出；
- **到达组**是连续 N_{u} 个录取 key，精确分数按到达组到达；
- **更新组**是连续 N_{adm} 个录取 key，P'、α、l 与 O 按更新组各更新一次。

N_{u}、N_{adm} 由指令给出（参考 $N_{\mathrm{u}} = 32$，$N_{\mathrm{adm}} = 128$–512）。

第 1 步：到达组到达时更新行最大值。 一个到达组里本行的录取 key 集合记 $\mathcal{A}_u$：

$$m'_{\mathrm{run}} = \max\Big(m_{\mathrm{run}},\ \max_{j \in \mathcal{A}_u} A_j\Big), \qquad \tilde{p}_j = e^{\,A_j - m'_{\mathrm{run}}} \quad (j \in \mathcal{A}_u),$$

以 m'_{run} 作本行新的 m_{run}。录取以外的 key 不进 exp。更新组结束前，早到 key 的中间结果存在 L1 的分数暂存；保存哪些量【设计者定】，不得改变 P'、α 与 l 的数值。

第 2 步：更新组结束时统一基准。 基准 m_{tile} 取本组最后一个精确分数到达后的 m_{run}：

- 早到的 $\tilde{p}_j$ 乘 $e^{\,m_{\mathrm{old}} - m_{\mathrm{tile}}}$ 统一到基准，m_{old} 为算它时所用的 m_{run}；
- $\alpha = e^{\,m_{\mathrm{tile,prev}} - m_{\mathrm{tile}}}$，$m_{\mathrm{tile,prev}}$ 为上一更新组的基准；
- 折出 $P'_j = \tilde{p}_j \cdot S_{V,j}$。V 以 MXINT8 存储，$S_{V,j}$ 为 key j 那一行 V 的组尺度，读自 V 尺度表；它是 2 的幂，乘法只加指数；
- P' 与 $\tilde{p}$ 交 QNT，各量化成两个 MXFP6 平面，例如 $P'_1 = \mathrm{MX}(P')$、$P'_2 = \mathrm{MX}(P' - P'_1)$，$\mathrm{MX}(\cdot)$ 表示按 MXFP6 g32 量化；
- **行和与 P' 同口径**：用 QNT 回送的两平面量化值之和更新

$$l \leftarrow \alpha\, l + \sum_j \Big[\mathrm{MX}(\tilde{p}_j) + \mathrm{MX}\big(\tilde{p}_j - \mathrm{MX}(\tilde{p}_j)\big)\Big];$$

- **P' 记录由 QNT 组装并写 L1**（用户 11-04）：QNT 手里已有两个平面、组尺度与共用基准，按录取位置与数据组织篇的格式拼成 P' 记录，供 MXU 做 P×V。NLU 只收回 $\tilde{p}$ 的两平面和值，不组装、不写 P' 记录。

第 3 步：按标签累加输出。 MXU 用 P' 记录与该组 key 的 V 行算出 $(P \times V)_{\mathrm{tile}} = \sum_{j \in \text{本组}} P'_j V_j$，按**列块**（head_dim 中连续 16 维）交出，每个条目带（行号, 列块号）标签。NLU 按标签读出该行 O 的这 16 维，做

$$O \leftarrow \alpha\, O + (P \times V)_{\mathrm{tile}}$$

后写回行状态。**条目次序不必与行序一致。** 本组没有录取 key 的行不出条目，O 与 l 不变。m_{run} **变大时，此前的** O **与** l **只乘** α**，不重新量化。** head_dim > 128 且 V 每 128 维一个尺度时，同一行的 $(P \times V)_{\text{tile}}$ 按 128 维分组到达，各组写行状态中互不重叠的维段【待确认】。

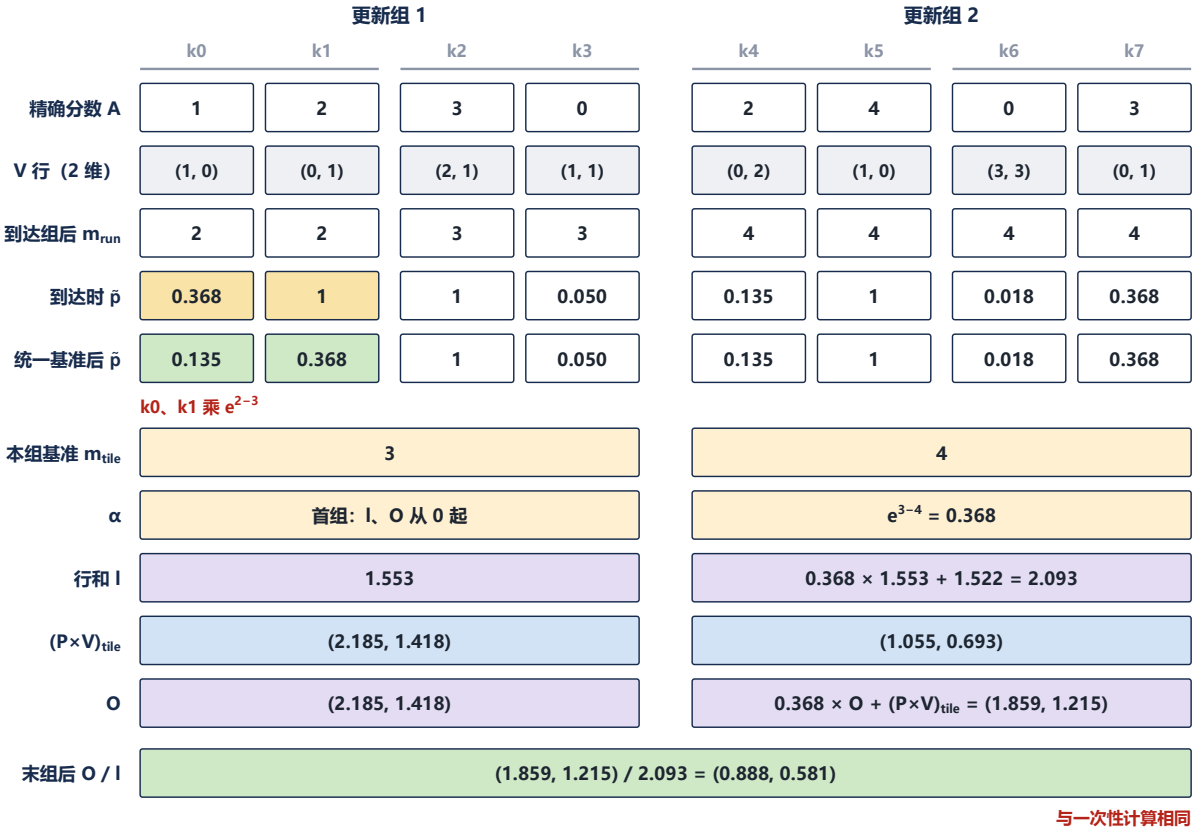
第 4 步：末组之后输出。

- O/l 交 QNT 量化，作下一位点（o 投影）的输入；
- 给出 $\text{lse} = m_{\text{run}} + \ln l$；
- 多个核各持一行的一部分 key 时，各核的部分状态 (m_{run}, l)（FP32）放结果寄存器，经 CCU 交 CRU 合并（$m = \max(m_a, m_b)$，$l = l_a e^{m_a - m} + l_b e^{m_b - m}$）；合并值由 CCU 按 token 标签写进本核 NLU 的合并值寄存器后，CCU 再发算 lse 的指令，不落 L1。

对录取 key 的子集另算行和。 对录取 key 中由指令指定的一个子集，用同一 m_{run} 与 α 另累加行和 l_{self}，与全部录取 key 的行和 l_{total} 相除得 token 复用比值 $s_{\text{self}} = l_{\text{self}}/l_{\text{total}}$；跨 q 头的聚合方式（如取均值）由序列给出，结果交 SEL 判决。

参与 softmax 的元素集合（用户 11-04）：

- **被屏蔽的位置不得计入行最大值、行和与输出，等价于权重为 0。** 屏蔽的来源包括因果截断、树形 token 之间的祖先关系、有效 key 范围、被剪掉的 token；屏蔽位由指令给出。
- **整行全被屏蔽时输出零向量，不产生 NaN。**
- 本篇只写这一需求。逐元素置 $-\infty$ 后照算是最差的做法：**被屏蔽的元素不应白占运算拍**，做法应均衡各运算元件的利用率，【设计者定】。



缩小例：一个查询行的 8 个录取 key，到达组 $N_{\text{u}} = 2$（灰色短线），更新组 $N_{\text{adm}} = 4$；V 只取 2 维，$S_V = 1$，不画两平面量化。实际参考 $N_{\text{u}} = 32$、$N_{\text{adm}} = 128$–512，$d_h = 128$，O 每个列块 16 维。

- **更新组 1**：到达组 {k0, k1} 到达后 $m_{\text{run}} = 2$，k0、k1 按 2 算 $\tilde{p}$；到达组 {k2, k3} 到达后 m_{run} 升到 3。组末统一基准 $m_{\text{tile}} = 3$，早到的 k0、k1 乘 e^{2-3}，得 0.135、0.368。首组的 l 与 O 从 0 起：$l = 1.553$，$O = (2.185,\ 1.418)$。
- **更新组 2**：第一个到达组就把 m_{run} 升到 4，第二个到达组不变，所以组内不必统一。$\alpha = e^{3-4} = 0.368$；$l = 0.368 \times 1.553 + 1.522 = 2.093$；$O = 0.368 \times O + (1.055,\ 0.693) = (1.859,\ 1.215)$。
- **末组后** $O/l = (0.888,\ 0.581)$，与对 8 个分数一次性做 softmax、再加权 V 的结果相同（脚本断言，浮点容差内）。

3.5 跨向量的流式累加：逐通道累加，可从读回的部分和继续

一串向量逐通道累加到一个状态向量，**结果与一次性成批计算一致**：

- **区块摘要**：**区块**是连续 L_{blk} 个 key（参考 128，取 2 的幂），**区块摘要**是区块内 K 的逐通道聚合量。NLU 对每个到达的 key 向量（d_h 维）按 key 升序累加：
  - 逐通道 sum，区块收满后乘 $1/L_{\text{blk}}$ 得均值；L_{blk} 为 2 的幂，乘法只改指数；
  - 逐通道 min / max。

  两种摘要都必须能做，用哪种由序列选择。收满的摘要交 QNT 量化。
- **区块能量**：MXU 用查询行与区块摘要算出区块打分的粗分数 S_{iJ}（查询行 i 对区块 J），经出口级交 NLU。NLU 按（query 行块, q 头, 区块）把同一区块的 S_{iJ} 聚合成区块能量 $\mathcal{E}_J$，交 SEL 做区块选择。聚合形式由序列给出；**聚合按行号升序进行，结果与到达次序无关。**
- **两个部分和相加**：attention 反传按 query 分块（chunk）计算时，本块的 dK / dV 部分和与读回的累加值逐元素相加。
- **从读回的部分和继续累加**：区块未收满时，部分和由 MAE 写出；下次读回后从这个状态继续累加，次序不变，结果与一次性成批计算一致。



缩小例：6 个 key，每个 2 个通道，区块长 $L_{\text{blk}} = 4$；实际参考 128 个 key、$d_h = 128$ 个通道。

- 区块 0 收满 K0–K3 后输出：均值 $= \text{sum} \times 2^{-2} = (1,\ 2)$，min $(-2,\ -2)$，max $(3,\ 6)$，与对 4 个 key 成批计算相同。
- 区块 1 只到了 K4、K5，sum $(4,\ 4)$、min $(-1,\ 1)$、max $(5,\ 3)$ 是未收满的部分状态。写出、下次读回后从这个状态继续累加，结果与对整个区块成批计算相同（脚本以 2 个后续 key 断言）。

4 精度要求与数据格式

4.1 精度要求：集成到算法后任务精度下降 < 0.1%

NLU 的计算方案集成到算法后，任务精度下降 < 0.1%。中间计算精度不规定，由设计者定（用户 11-04）。口径：

- 下降量按绝对百分点计；
- 基线为同一算法下 VNU 各运算按 FP32 理想值计算的结果；
- 评测集为算法侧的标准评测集；
- 硬件实现与算法参考模型逐位一致，作为验证手段；参考模型随硬件实现同步。

4.2 输入格式：向量只有 BF16 与 MXFP6 g32 两类

类别	格式	来源
向量	BF16	MXU 出口级、VNU 内部
向量	MXFP6 g32：每个元素 6 bit（E2M3 码），每 32 个元素共享一个 8 bit 指数尺度（E8M0）	存储（L1 读回、IDN 嵌入行）、QNT 回送
标量	FP32 语义：结果与"按 FP32 计算、只在最后舍入一次"的参照一致，实现可用更窄的内部格式	合并值寄存器（CRU 合并值经 CCU 写入，FP32）、随嵌入行经 IDN 落地 L1

还有几种需要临时处理的格式：

- OPT 自己的格式：MXINT8 权重副本、优化器状态；
- 可选格式：MXFP6 装不下时的 FP8 / BF16 / FP16 梯度；元素位宽取 8 的位点所用的 MXFP8 E4M3；
- 经 IDN 交 LOSS 的 teacher 概率。

设计者可选择在 QNT 把这些格式统一成上述两类后再交 NLU（用户 11-04）。

4.3 输出格式

- 交 QNT、SEL、MXU 出口级的向量为 BF16。
- 交 CRU 的标量为 FP32，放结果寄存器，由 CCU 读出后经命令与标量网发出，在网上按 ② 档槽宽打包（每个 64 bit 字 2 个，传输协议篇 §8.6）。
- 反传逐元素运算的输出经 QNT 按位点配置的流动梯度格式（反传梯度在算子之间流动时的格式，默认 MXFP6 g32 单平面）量化后才离开 VNU。$\mathrm{d}S$ 取其中哪一种格式、梯度 MXFP6 的组轴（逐 token 沿通道或沿 token）【待确认】。

4.4 结果规则

- **在线 softmax 的结果与 key 的到达次序无关。** 例外是两平面量化：它按更新组内每 32 个录取 key 一段分组，段的成员随到达次序变化，输出在量化舍入级与次序有关【待标定】。
- 区块能量与到达次序无关。
- 流式区块摘要与一次性成批计算一致，跨次读回后续累加时次序不变。
- K 读时旋转与本次新 K 的复算链是同一条链，同一输入下逐位相同。
- **序列在位点边界切换，切换不打断在途向量。**
- **参数表带版本；在途序列一直用旧版，直到用完。** 不出现半更新状态。

5 速率与时延

5.1 每拍处理能力匹配上下游模块

NLU 每拍能处理的元素数，须匹配上游各口的产出速率与下游各口的接收要求，由 NLU 设计者与以下模块对接确定（用户 11-04）。下表的参考值只作背景，不是 NLU 的定值；**现行每拍 16 个元素是参考值，设计者可按需求加大并行数**（用户 11-05："NLU可以增加它并行处理的数量，当前的值可以是一个Reference值"）：

相关模块	接口	现行参考值
MXU 出口级	出口向量、 夹心归一化缩放值	出口级交 VNU 每核每拍至多 16 个元素；**NLU 的合计负载不得使出口级反压阵列出口缓冲（Array Egress Buffer，AEB）**
QNT	待量化向量、 量化结果回送	统一请求接口每拍 16 个元素
SEL	评分与统计量	SEL 的 NLU 口每拍 16 个评分
L1（经 VNU 的 RRAM 口）	行状态读改写、 分数暂存	每个有录取的（行, 更新组）读改写一次行状态（§5.3）；读出固定 1 拍；入口将满时拉 stall_vnu[i]；写进集合器 FIFO，将满 wr_stall
CCU（结果寄存器 / 合并值寄存器）	标量部分和、合并值	层入口归一化每 token 一次往返（CCU → CRU → CCU）；往返时延不定要求值，CRU 并行 lane 可配（传输协议篇 §6.4）
MAE（K 存储码流入）	K 读时旋转	粗算段的旋转不得慢于本核 K 存储码的流入：每（key, kv 头）69 B，DDR 参考 19.2 B/拍时全芯片约 0.28（key, kv 头）/拍、约 36 元素/拍，按参与的核分摊；单核时约 36 元素/拍，约为向量路径的 2.2 倍【待标定】

5.2 exp 能力匹配录取率上限下的精确分数到达速率

exp 的能力须匹配"精确分数到达速率 × 录取率上限 $\phi_{\max}$"（用户 11-04）：按录取率达到上限 $\phi_{\max}$（一行里被录取的 key 所占比例的上限）时的精确分数到达速率定容。现行参考：粗算每核每拍扫过约 21.8 个 key，$\phi_{\max} = 0.5$ 时精确分数约 11 个/拍，即 exp 约 11 次/拍；SiLU 等逐元素场合每拍 16 个。参考值来自旧供数结构下的粗算节奏【待标定】。

5.3 O 更新每（行, 更新组）d_h / 16 拍

每个有录取的（行, 更新组）读改写一次 O，耗时 $d_h/16$ 拍（head_dim 128 时 8 拍）。耗时与 N_{adm} 无关；N_{adm} 越大，一行的更新次数越少。

5.4 自身流水深度

投影后处理（投影结果进 NLU 后跑的归一化、旋转等序列）的流水深度，即一条向量的首个元素从进入 NLU 到交给 QNT 的拍数，≤ 40 拍【待标定】。整条向量的耗时另按每拍 16 个元素计，例如 2,560 个元素约 160 拍。

5.5 exp 超载时经握手停上游，不丢分数

精确分数的到达超过 exp 的能力时，NLU 经握手让上游停发，**不丢分数**。握手只用传输协议篇 §4 的相邻级 stall：对出口级是相邻级的一根 stall（VNU → 出口级）；对由 CCU 发读的入口是 stall_vnu[i]。

6 计数与复位

- **计数**：溢出按饱和处理，饱和次数计数，供 LIC / MAE 读取。
- **复位**：清行状态、分数暂存、平方和暂存与各部分和。**NLU 没有需要跨次保留的状态**：区块摘要的未收满部分和由 MAE 写出、下次读回。
- **不设运行时错误事件**：§2.3 所列前提由对应模块保证，验收时用断言检查。

7 要求值与验收

7.1 要求值

项	要求值	说明
运算形态	逐元素、沿向量的归约与归一化、二维旋转、在线 softmax 与 attention 输出累加、跨向量的流式累加	序列与参数由指令与参数表给出；GDN 状态更新的分工待 MXU、NLU、CCU 设计者后续设计
每拍处理能力	匹配上下游各口（§5.1）	由 NLU 设计者对接确定；向量路径参考每拍 16 个元素，可加大
exp 能力	匹配录取率上限下的精确分数到达速率（§5.2）	参考约 11 次/拍【待标定】；逐元素场合每拍 16 个
O 更新	每（行, 更新组）$d_h/16$ 拍	head_dim 128 时 8 拍
K 读时旋转	粗算段不慢于本核 K 存储码流入（§5.1）	单核参考约 36 元素/拍【待标定】；并行度【设计者定】
流水深度	投影后处理 ≤ 40 拍	【待标定】
head_dim	128 / 256 / 512	归一化、旋转、O 更新都要支持
精度	集成到算法后任务精度下降 < 0.1%（绝对百分点）	基线为 VNU 各运算按 FP32 理想值；中间精度由设计者定
门数	参考 ≤ 150 k 门（NAND2 等效），另加 3–5 KB 存储	不含 L1 中的行状态与记录；行状态更新与归一化缩放部分的门数增量

项	要求值	说明
		【待标定】
L1 建议值	分数暂存：$N_{\mathrm{adm}} = 512$ 时约 19 KB；区块摘要部分和每 kv 头 $d_h \times 4$ B（均值）或 $2d_h \times 4$ B（min / max）；行状态每行 $2d_h + 8$ B（head_dim 128 / 256 / 512 时 264 / 520 / 1,032 B）	A 类地址段由编译链分配
L1 口与握手	RRAM 口：读经激活类读口，每条由 CCU 发读的入口一根 stall_vnu[i]；写进 A 类写集合器里本单元的入口 FIFO（只给 din 与长度），将满 wr_stall 回本单元	将满阈值 = 深度 − L，L【设计者定】
交 CRU 的标量	结果寄存器（CCU 读）/ 合并值寄存器（CCU 写），FP32，不落 L1；NLU 在命令与标量网上无端口、无有效位	传输协议篇 §8.1、§8.2

7.2 验收

对象	方法	用例
逐元素运算（§3.1）	与算法参考模型逐位比对	各激活、门控乘、导数；饱和与大幅值输入
归约与归一化（§3.2）	逐位比对	hidden 与 head_dim 两种归约维；head_dim 128 / 256 / 512； 三种统计量来源；多核部分和合并后与单核整体计算相同； 全零输入给出有限值
二维旋转（§3.3）	逐位比对	正向、部分维、按位置差重旋转、逆旋转
K 读时旋转（§3.3）	与"解码 → 同一条链 → 重量化"的参照逐位比对；周期仿真	粗算段与精算段；单核与多核；旋转不拖慢粗分数计算
在线 softmax（§3.4）	逐位比对	多种 N_{u}、N_{adm}；条目乱序到达与行序到达结果相同；本组无录取的行 O 不变；多核部分状态合并后与单核结果相同
参与 softmax 的元素（§3.4）	逐位比对；周期仿真	因果、树形祖先、有效范围、被剪掉的 token；整行全屏蔽输出零向量、无 NaN；被屏蔽元素不白占运算拍
流式累加（§3.5）	逐位比对	均值与 min / max；未收满部分和写出、读回后续累加； 区块能量乱序到达
集成精度（§4.1）	算法侧评测	目标模型在标准评测集上下降 < 0.1%
不反压出口级（§5.1）	周期仿真	出口级每拍 16 个元素的峰值注入，在线 softmax、O 更新与归一化缩放同时进行
RRAM 口与入口 stall（§2.2）	周期仿真；断言	写只给 din 与长度；stall_vnu 拉起后入口缓冲不溢出；wr_stall 拉起后不丢写；行状态读写堆位一致
标量经 CCU 中转（§3.2、§3.4）	断言	部分和只出现在结果寄存器、合并值只由 CCU 写入，不经 L1； 多核合并后与单核结果相同
exp 超载（§5.5）	周期仿真	录取率扫描，超过上限时经 stall 停上游、不丢分数
O 更新与流水深度（§5.3、§5.4）	周期测量	head_dim 128 / 256 / 512
复位（§6）	检查状态	运算进行中复位
门数（§7.1）	综合	待 RTL

8 为什么

- **两次乘加之间的运算落 NLU**：MXU 只做矩阵乘加，两次乘加之间的非矩阵、非选择运算都落到 NLU；比较与判决在 SEL，量化与打包在 QNT，各单元只做一类事。
- **对外接口经 VNU 组封装**（用户 11-04）：NLU 是 VNU 组内的单元，访问 L1、向核外上行都经 VNU 的共用口；对外口怎样划分由 VNU 集成篇统一定义。
- **固定元件 + 可装载序列**：新模型的新算子只要能由现有元件表达就不改硬件；序列与参数表是编译产物，换模型只换序列与参数。
- **精度按集成后掉点要求，中间精度交设计者**（用户 11-04）：NLU 的输出几乎都要再量化成 MXFP6 这类块格式，元件误差只需明显小于下游量化步。所以本篇不规定元件误差界与内部格式，只规定集成后的任务精度，由设计者在精度与门数之间取舍。
- **输入格式两类**（用户 11-04）：NLU 只面对 BF16 与 MXFP6 g32 两类向量，元件不必为每种格式各备一套；其余格式可在 QNT 先统一。
- **在线 softmax 的到达组与更新组**：精确分数按到达组到达，m_{run} 随之更新，不等整行分数到齐；一个更新组的 P' 要以同一个基准折成，才能作为一组交 MXU 做 P×V，所以组末统一基准。N_{u}、N_{adm} 由指令给出，硬件只固定粒度；更新组越大，O 的读改写越少。N_{adm} 的参考值来自 11-01 的真实位图回放（旧供数结构下仿真【待标定】）。
- **行和与 P' 同口径**：MXU 用两平面量化后的 P' 做 P×V，分子带量化；分母也用 $\tilde{p}$ 的两平面量化值累加，分子分母才同口径，而不是用未量化的 $\tilde{p}$。
- **O 与行状态归 NLU**（用户 11-03）：αO 要乘任意实数 α，MXU 的累加器与 CRU 都没有这一乘法；m_{run}、l 与 O 同在 NLU 读写，α、l 与 O 更新的先后只在单元内部排序。这与 TPU（矩阵单元只出累加结果，逐元素与归一化在向量单元）和昇腾（Cube 单元只做矩阵乘，向量后处理在 Vector 单元）的分工一致。
- **按传输协议篇同步**（用户 11-05，V18-TP-01…16）：核内与 L1 之间只有 RRAM 一种口，地址只在 CCU 一处推理，NLU 只给数据与长度；CCU 不看下游余量，所以每条入口给 CCU 一根 stall；交 CRU 的标量与合并值不经 L1 / L2，部分和与合并值都是几个 FP32，没有必要占数据网与 L1 的时隙；IDN 与 H2C 只落 L1，所以嵌入行先落地再读入。
- **标量经 CCU 中转**（用户 11-05："直接发给 CCU，由 CCU 直接配置 VNU 内部需要计算数据的寄存器吧……VNU 的控制命令本来就来自 CCU，那么刚好可以统一调配"，V18-TP-21）：NLU 在命令与标量网上不设端口；合并值到达与使用它的指令在 CCU 一处排序，NLU 不需要有效位、不因标量未到而 stall。
- **统计量跨核合并后再缩放**：一个 token 的 hidden 维分散在各核，RMSNorm 要整行的平方和；只用本核部分和会算错缩放系数（FIG-VNU_NLU-NORM-SPLIT 的 0.516 对 0.5）。
- **K 读时旋转归 NLU**（用户 11-04 晚）：K 在 RoPE 之前量化存储时，读出后要先旋转。把旋转放到各核 NLU，工作量随核并行、每核只旋自己要用的头；MAE 只按字节搬运，不设专门的旋转通路。
- **Q 粗算记录改由 QNT 写**（用户 11-04）：QNT 组装 Q 全维记录时已有 SEL 给的选维位与全部码，顺带写出只保留选中维的粗算记录，不必由 NLU 再从 L1 读回重打包。**P' 记录同理由 QNT 组装**（用户 11-04）：两个平面、组尺度与共用基准都在 QNT 手里，省去两平面回送 NLU 一程和 NLU 的一次 L1 写。
- **屏蔽只写需求，优先均衡利用率**（用户 11-04）：屏蔽位由指令给出，NLU 只需保证被屏蔽元素不计入结果；逐元素置 $-\infty$ 后照算会让被屏蔽元素白占运算拍，所以做法交设计者，以均衡利用率为先。
- **与 OPT 只留合作通路**（用户 11-04）：裁剪系数是 OPT 的功能；它需要的开方与除法可借 NLU 的元件，怎样配合由指令设计与两个模块的设计者确定。
- **每拍处理能力由设计者对接**（用户 11-04）：上游出口级与下游 QNT、SEL 的节奏都随相关模块的设计而定，所以本篇列出相关模块与参考值，不写死跨模块的数字。
- **GDN 状态更新暂不写实现需求**（用户 11-05："不要现在写入GDN的实现需求了……GDN的状态更新，留出MXU，NLU，CCU的设计者后续设计"）：状态更新跨 MXU、NLU、CCU 三个模块，分工与数据通路由三方设计者后续共同设计。
- **深度卷积留在 MXU 的逐通道 FIR**（用户 11-05："MXU利用率再低，它的输出维度也能保持在64并行输出（4个Pod）"）：FIR 没有专用缓冲，只是激活进阵列的接线选择加控制；NLU 只合成 DFlash2 的动态系数。
- **每拍元素数只是参考值**（用户 11-05）：新负载按需加大并行数，由设计者与上下游对接。
- **覆盖目标模型**：Qwen3-4B、MiniCPM5-1B 与现行 Draft 模型的全部非矩阵、非选择算子；新增目标 Qwen3.5-4B（GDN 门的逐元素部分、head_dim 256；状态更新的分工待后续设计）与 Gemma 4 E2B（GELU、q / k / v 归一化、嵌入 $\sqrt{d_{\mathrm{hidden}}}$ 缩放、PLE 门控的逐元素乘）；Llama 类结构作同类覆盖。不能由现有元件表达的新算子记为缺口，不承诺任意函数可配。