VNU 量化单元（QNT）需求

> Owner: WangYizhao｜2026-11-04｜重写稿，待用户审阅。按用户 11-04 确认的目录编写（`../V17_3_MODULE_TOC_VNU_QNT_20261104.md` 第三版）；改变现行设计的事项汇总在 `Claude_Design_Spec/V1.8_DESIGN_REVISIONS.md`（V18-QNT-01…09，以及 V18-SEL-11 / 12、V18-NLU-01、V18-VNU-01 / 02、V18-LOSS-03）。
> 11-05 按片上数据传输协议篇（`DATA_TRANSFER_PROTOCOL.md`，V18-TP-01…16）同步：与 L1 的口改为 RRAM 口、地址由 CCU 推理、入口 stall；amax 改走命令与标量网；写出改为记录级 32 B 对齐（对象头单独占一个存储字，每条记录从整字起、尾部补 0）、记录头带 token 序号、按 MX 组产生段、权重驻留下写进 token 槽、反传流动梯度按 ③ 档打包（§2、§3.5、新增 §3.7、§7、§8、§10）。
> 11-05 晚第二轮同步（协议篇 §2.1、§3.2、§4.2、§7.3、§9.7，V18-TP-17…20）：32 B 单位改称存储字；读经激活类读口、写进 A 类写集合器里本单元的入口 FIFO、wr_stall 回本单元；变长对象 bump 分配、上限只用于 token 槽（§2、§3.7、§7、§9）。
> 11-05 第三轮同步（协议篇 §4、§6.1、§6.4、§8.1、§8.2，V18-TP-21 / 24）：amax 双向经 CCU 中转——部分 amax 放结果寄存器由 CCU 读出发 CRU，共同 amax 由 CCU 写进合并值寄存器，QNT 在命令与标量网上无端口；"反压"作机制名处改称握手（§2、§3.2、§7、§8、§10）。

1 组成与位置

1.1 QNT 只做量化、编码、压紧、组装与解码

QNT（Quantization Unit，量化单元）把高精度向量变成存储或传输格式，反方向把 K 的存储码还原成计算用的值。它做五件事（§3）：

- 按组量化编码：沿向量的一维每 g 个元素求一个共享尺度，逐元素编码成窄码；
- 两平面表示：把一个码按位拆成高、低两个平面，或把量化误差再量化一次；
- 按判决位压紧：按 SEL 给的判决位去掉不读的元素；
- 定长记录组装：把码、尺度与附带字段拼成记录，写往指令给的去向；
- 解码与还原：码乘尺度，还原成计算用的值。

QNT 不做比较与判决，也不做向量算术。 具体地：

- Norm、RoPE、加减均值、softmax、O 更新在 NLU；
- 残差加、BF16 直通、残差与特征行的还原在 MXU 出口级（用户 11-04）；
- 一切逐元素阈值判断，包括下一位点输入各通道是否保留，在 SEL（用户 11-04）；
- 跨核合并在 CRU；
- QNT 不决定用什么格式、不调度、没有 DDR 口、不发访存描述符。

1.2 QNT 是 VNU 组的一个单元，每核一个

一个计算核由 CCU、MXU 组、L1 组、VNU 组四组拼成。QNT 是 VNU 组的六个单元之一，其余五个是 NLU、SEL、SMP、LOSS、OPT。**QNT 与 VNU 组外的模块交换数据，都经 VNU 组的对外接口**；访问 L1 和向核外上行，经 VNU

的共用口。VNU 对外口的个数与共享方式，由 VNU 集成篇定义（待写）。

每个计算核一个 QNT，全芯片 4 个，物理相同。

1.3 格式与去向由指令和模型级配置给出

QNT 只提供运算形态（§3）。 每个请求出什么格式、组长多少、是否拆平面、是否压紧、结果交到哪里，由指令与模型级配置给出。本篇不写指令字段，指令定稿后另补。

QNT 同一时刻只执行一种功能（用户 11-04）：一次处理一个请求，先后由指令与 CCU 排定。VNU 内各单元都按此原则；以后有并行需求时再调整。

1.4 执行范围：VNU 组内向量的量化都由 QNT 执行

VNU 组内向量的量化、编码与记录打包由 QNT 执行，同一格式只有这一处实现（用户 11-04）。请求来自 NLU、LOSS 与 MXU 出口级。另有两处在 QNT 以外量化，都按同一套量化规则（§6.1）：

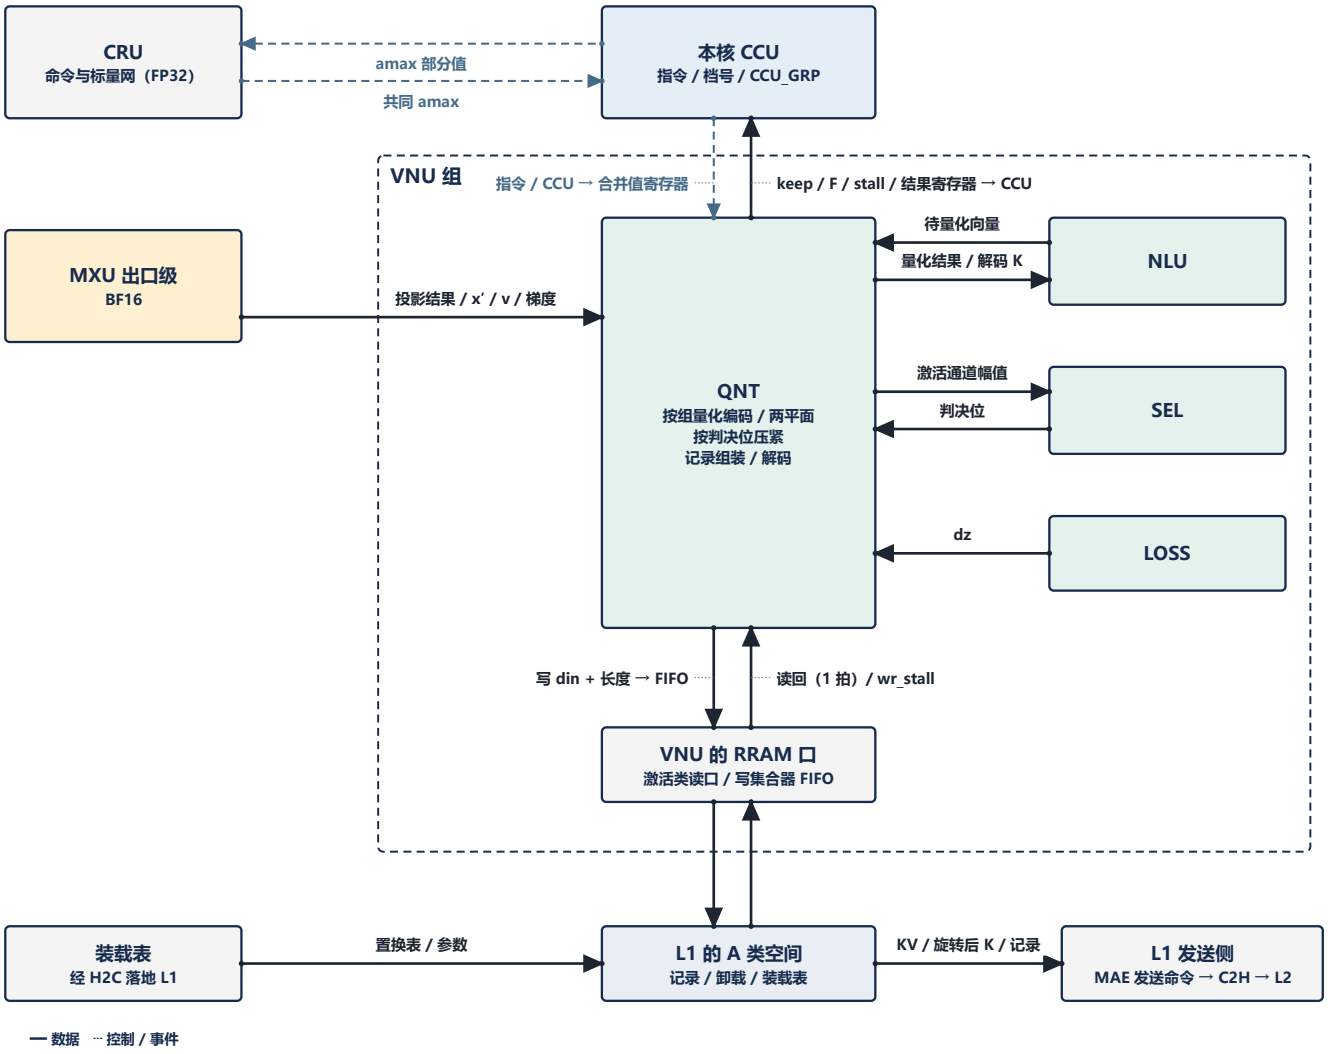
- CRU 对核间归约值（按归约维 k 切分到多核时的部分和合并结果）的量化；
- OPT 对自有格式（权重副本、优化器状态）的重量化。

1.5 训练反传经过量化点：梯度直通

训练反传时，梯度要穿过前向的量化点。以线性位点为例：前向把激活 X（$T \times K$）量化成 $\hat{X}$ 再算 $Y = \hat{X}W$；反传先得 $\mathrm{d}\hat{X} = \mathrm{d}Y\, W^{\mathsf{T}}$，再由 $\mathrm{d}\hat{X}$ 得 $\mathrm{d}X$。

- **需求：梯度直通**，$\mathrm{d}X = \mathrm{d}\hat{X}$，即反传时把量化看成恒等。这一步不需要 QNT 有任何动作。
- **饱和截断由设计者思考方案**（用户 11-04）：前向被饱和的元素（超出格式最大值），改变 $x_{t,k}$ 不再改变 $\hat{x}_{t,k}$，可选让其梯度置零。这需要前向为每个元素记下是否饱和（一张 $T \times K$ 的位图），并保存、传递到反传。是否支持、怎样记录与传递，由设计者与算法侧对齐后定【设计者定】。

2 数据从哪来、到哪去



虚线框是 VNU 组：

- **框内**是 QNT，以及和它直接往来的 NLU、SEL、LOSS。这些连线不出 VNU 组。
- **跨出框的连线**都是 VNU 组的对外接口：
  - 左侧：MXU 出口级交来的 BF16 向量；置换表与量化参数（经 H2C 落地 L1，再经 RRAM 口读入）；交 CRU 取最大的 amax **经本核 CCU 中转**（用户 11-05，传输协议篇 §6.1、§8.1）：QNT 把本核的 amax 部分值放进**本单元的结果寄存器**，由 **CCU 读出、经命令与标量网发 CRU**；共同 amax 回到 **CCU 的短消息队列，由 CCU 按类型与 token 标签写进 QNT 的合并值寄存器**，再发出按共同尺度编码的指令。**QNT 在命令与标量网上没有端口**，两者都不落 L1（FP32）；
  - 上方：与本核 CCU 之间的指令、档号（虚线）、交给 CCU 分组单元的 keep / F 位图、入口 stall，以及 CCU 读结果寄存器、写合并值寄存器（图中 CRU 只与 CCU 相连）；
  - 下方：**VNU 的 RRAM 口**（RRAM 即核内 SRAM 口协议，传输协议篇 §3），读经 L1 外的选择器用一个激活类读口（每口 32 B/拍，4 个读口都可读任一 A 类 bank，读时隙由 CCU 排）；**写**进 L1 的 A 类写集合器里本单元自己那条 32 B 入口 FIFO，集合器每拍按优先级把各写者的队头分到对应 bank 的道上，FIFO 将满时拉 **wr_stall** 回本单元（只到本单元，不到 CCU；传输协议篇 §3.2）；读写哪一堆由地址的堆位选，L1 不仲裁（用户 11-04 / 11-05，V18-L1-02）。**要出核的记录一律先经这个口写 L1，再由 L1 发送侧经 C2H 发出**

（MAE 的发送命令直接送本核 CCU，由 CCU 发读）（用户 11-04 / 11-05，V18-L1-03、传输协议篇 §6.1）。读时旋转后的 K 也走这条路写 L2，再由 MAE 命令经 H2C 多播进需要它的核（V18-L1-05）。

- QNT 不直接连 L1 或 C2H，都经 VNU 的 RRAM 口。

2.1 VNU 组内的接口

组内链路只规定位宽（用户 11-04）：链路上是什么格式，由收发两端按指令解码。下表"格式"一列写内容的规范格式，供两端解码。

接口	对端	方向	内容	格式
待量化向量	NLU	入	RoPE 之后的 q；k（POST 为 RoPE 与减目标均值之后，PRE 为 QK-Norm 之后，或读时旋转之后）；P' 与 $\tilde{p}$，连同录取 key 的位置；按 RMS 缩放后的下一位点输入；O/l；门控激活 $\tilde{s}$；嵌入行 x_0；区块摘要；反传逐元素输出	BF16，每拍至多 16 个元素
待解码的 K 存储码	NLU	入	读时旋转从 L1 读出的 K 存储码：粗算段为 hi 原码 + E8M0 + kmax，精算段为 hi + lo 原码	MXINT8 g32 的 hi / lo 平面
量化结果回送	NLU	出	$\tilde{p}$ 两平面量化值之和（按 key，§3.3）；解码后的 K（全码 / 只 hi，§3.6）；量化后的投影结果与流动梯度；（可选）统一格式后的临时格式向量（§3.6）	BF16 或 MXFP6 g32
待量化梯度	LOSS	入	$\mathrm{d}z$（LM Head logit 的梯度），按流动梯度格式量化（用户 11-04）	BF16
待判断幅值	SEL	出	下一位点输入一个 token 各通道的幅值 $\lvert x_k \rvert$，供保留判断	BF16
判决位	SEL	入	Q 一行的选维位（每维 1 bit）；下一位点输入各通道的保留码 Z / C / F（每通道 2 bit）	每元素 1 或 2 bit
临时格式	OPT	入 / 出	只在设计者选择统一临时格式时存在（§3.6）	—

Q 一行的逐维幅值由 NLU 直接交 SEL，不经 QNT（用户 11-04）。

2.2 经 VNU 组对外的接口

接口	对端	方向	内容	格式
出口级请求	MXU 出口级	入	残差加结果 x'、归约完成的投影结果（q、gate、up 等）、v、反传归约完成的梯度、已在出口级还原的特征行（用户 11-04）。**QNT 来不及收时经相邻级 stall 与出口级握手、让其停发**（VNU → 出口级，传输协议篇 §4.3）	BF16，与 NLU 合计每拍至多 16 个元素

接口	对端	方向	内容	格式
L1 读写	读：L1 外选择器 → 激活类读口；写：A 类写集合器里 QNT 的入口 FIFO	出 / 入	写：Q 全维记录、Q 粗算记录、P' 记录，以及要出核的全部记录（下一行）。卸载：来不及处理的请求数据、等数据到齐时的暂存，写到 L1 再读回（§2.3）（用户 11-04）。读：卸载读回、经 H2C 落地的置换表与量化参数	整字 32 B；写只给 din 与记录长度（§3.7）
写握手	L1 的 A 类写集合器	入	QNT 那条入口 FIFO 将满时的 wr_stall（只到 QNT）	1 bit
上行（记录 / KV 等）	经 RRAM 口写 L1 → L1 发送侧经 C2H 发出（发送命令送 CCU，CCU 发读）	出	K / V 存储记录与本次 attention 用的新 K、读时旋转后的 K、紧凑记录、残差记录、反传流动梯度，写 L2，目的地址由 MAE 命令给出（V18-L1-03）。读时旋转后的 K 进 L2 后，由 MAE 命令经 H2C 多播进需要它的核的 L1（V18-L1-05）	见 §3.5、§3.7
结果寄存器（CCU 读）	本核 CCU：读出后经命令与标量网发 CRU（用户 11-05）	出	一组跨核时本核的 amax 部分值（F5 amax）。**不落 L1**；就绪由 CCU 按产出指令完成推断，QNT 不发事件（用户 11-05）	FP32；在网上由 CCU 按 ② 档槽宽打包（传输协议篇 §8.6）
合并值寄存器（CCU 写）	本核 CCU：CRU 的共同 amax 进 CCU 短消息队列，CCU 按类型与 token 标签写入（用户 11-05）	入	CRU 取最大后的共同 amax；CCU 写好后才发出按共同尺度编码的指令，**QNT 不设有效位、不因标量未到而 stall**	FP32
装载表	经 H2C 落地 L1，再经 RRAM 口读入	入	按（层, kv 头）装载的通道置换表与量化参数	表
指令与档号	本核 CCU	入	每个请求的格式、组长、拆平面、压紧与否、去向；每个 token 的 2 bit 档号（档号 3 表示该 token 不参与）	—
keep / F 位图	本核 CCU 分组单元（CCU_GRP）	出	每（token, 位点）的 keep 字数、每段 keep 位图与 F 位图	—
入口 stall	本核 CCU	出	每条由 CCU 发读的入口一根 stall_vnu[i]（卸载读回、装载表读入）	1 bit

2.3 统一请求接口：一次处理一个请求，来不及处理的卸载到 L1

- **所有量化请求经一个入口进入。** 每个请求说明目标格式、组长、是否拆平面、是否压紧、去向。BF16 直通的去向不进 QNT。
- **一次处理一个请求**，先后由指令与 CCU 排定（§1.3）。
- **来不及处理的数据卸载到 L1**：QNT 正忙时到达的请求数据（例如 P'），以及等跨核 amax 回送、等 SEL 判决位期间的暂存，可经 RRAM 口写到 L1 的 A 类空间，之后读回处理，不在入口排队等待。卸载与否、容量与时机【设计者定】；卸载的地址段由指令给出，每次写的地址由 CCU 推理，QNT 只给 din 与长度。
- **卸载写进一堆，读回要等两堆切换之后**（V18-L1-02）：L1 的 bank 分成两堆 ping-pong，同一时刻一堆只读、一堆只写，**读哪堆、写哪堆由 CCU 给的地址的堆位显式选，L1 没有堆角色状态**。卸载的数据写入当前写的一堆，切换条件 = 写完成 ∧ 另一堆的最后读者完成，由 CCU 在下一阶段的地址堆位里体现，此后才能从这一堆读回（传输协议篇 §7.1）；两次卸载与读回之间的切换时机由 CCU 与指令安排。
- **读回的握手**：读回由 CCU 发 en，QNT 的读回入口缓冲将满（深度 − L）时拉 stall_vnu[i] 让 CCU 停发；L = CCU 停发 1 拍 + L1 读返回 1 拍，【设计者定】。写侧只有本单元 FIFO 的 wr_stall，不到 CCU。

2.4 由别的模块保证的事项

以下事项 QNT 不检查，由对应模块保证：

事项	由谁保证
每个请求的格式、组长、拆平面与去向	指令
模型级配置的装载	LIC
向量的算术（Norm、RoPE、softmax、缩放）	NLU、MXU 出口级
残差与特征行还原成 BF16	MXU 出口级
一切逐元素阈值判断、门限按档号选、偏置	SEL
相对阈值所用统计量（行均值、$\sum\|x\gamma\|$）与 Q 逐维幅值	NLU 求并交 SEL；跨核合并由 CRU
档号的给出与在位点边界翻转	CCU_CTL
跨核 amax 的合并与次序；核间归约值的量化	CRU
读结果寄存器发 CRU；共同 amax 按类型与标签写进合并值寄存器，写好后才发按共同尺度编码的指令	CCU（传输协议篇 §8.2、§11）
CCU 与 CRU 之间传 amax 的命令与标量网（物理经 hub 控制道）	传输协议篇 §8、HUB
放行先后与算子融合	CCU 与指令
同一单元的不同功能不在时间上重叠	CCU 与指令
写 L1 的地址：对象基址、逐记录字节累加、权重驻留下每 token 一个写累加器、环形回绕	CCU（§3.7）
变长对象按实际长度 bump 分配；权重驻留下 token 槽的上限与编译期静态检查	CCU（bump 分配）；SEL 的选择模式与编译链（槽上限）

事项	由谁保证
变长对象的实际长度报 MAE（对象长度报告）	CCU
写 L2 的目的地址	MAE 命令
C2H 发出的完成（末拍 + 固定时延）报 MAE	L1 发送侧
K 入站按字节搬运；PRE 存储码落 L1	MAE
读时旋转序列的调度	LIC
V 4 bit 展开与尺度减 4	MAE_NI_INT
A 类各地址段（记录区、卸载区、token 槽）的分配， 以及写入前旧数据已读完	编译链（指令中的基址与长度，LIC 操作 15）
VNU 对外口划分、组内链路位宽	VNU 集成篇（待写）
上行产出写 L1 后经 C2H 发出；读时旋转后的 K 从 L2 多播进需要的核	L1 发送侧（MAE 发送命令送 CCU， CCU 发读）；MAE
VNU 的 RRAM 口的时隙；两堆的切换（地址的堆位）	CCU 与指令
各记录的字段布局	数据组织篇
BF16 / FP16 激活拆段进阵列	MXU

3 运算形态

3.1 五种运算形态一览

形态	按矩阵维度说做什么	输入	输出	典型用途
按组量化编码	沿向量的一维每 g 个元素求一个 2 的幂尺度，逐元素编码	BF16 向量； 可选共同 amax	码 + 组尺度 + 每行最大指数	Q、K、V、投影结果、 下一位点输入、残差、 嵌入行、区块摘要、 流动梯度
两平面表示	一个码按位拆成 hi / lo； 或量化误差再量化一次	码，或 BF16 向量	两个平面 + 共用尺度或基准	K、V 8 bit 存储；P'
按判决位压紧	去掉判决位未选的元素， 其余按原序连续存放	向量或码 + SEL 判决位	压紧的段	下一位点输入的紧凑记录、 Q 粗算记录
定长记录组装	码、 尺度与附带字段拼成记录， 写往指令给的去向	上面三种的输出	记录	Q 记录、P' 记录、 残差记录、K / V 存储记录、读时旋转后的 K
解码与还原	码 × 尺度	K 存储码	计算用的值	PRE 下的 K 链

术语：

- **位点**：一层里的一个算子实例，例如第 5 层的 o 投影 $Y = OW_o$。
- **MX 组格式**：沿向量的某一维每 g 个元素（g = 32 或 128）一组，组内共用一个 8 bit 的 2 的幂尺度（E8M0，表示 2^e），每个元素只存窄码。MXFP6 E2M3 是 6 bit 浮点码（1 符号、2 指数、3 尾数，可表示的最大幅值 7.5），MXINT8 是 8 bit 整数码，FP8 E4M3 是 8 bit 浮点码。

3.2 按组量化编码：沿一维每 g 个元素求共享尺度，逐元素编码

成组方式：

张量	沿哪一维成组	组长
激活（投影结果、下一位点输入、残差、嵌入行、流动梯度）	一个 token 内沿 hidden 维	32 通道
Q、K	一个 token、一个头内沿 head_dim，Q 按 K 的通道置换组序	32 维
V	一个 key、一个 kv 头内沿 head_dim	128 维
BF16 / FP16 激活	不成组，整值交出；进阵列时的拆段在 MXU 侧【设计者定】	—

目标格式：MXFP6 E2M3、FP8 E4M3（元素位宽 $w = 8$ 的位点）、E5M2、MXINT8、4 bit（V）、BF16 / FP16 整值。

默认选码规则（量化合同；按 §6.1 第 3 层，可在掉点 < 0.1% 的约束下改动）：

格式	组尺度指数	元素舍入	越界
MXFP6 E2M3	$\lfloor \log_2 a_{\max} \rfloor - 2$（E2M3 最大指数为 2）	RNE	饱和到 ±7.5
FP8 E4M3	$\lfloor \log_2 a_{\max} \rfloor - 8$	RNE	饱和到 ±448
MXINT8	$\lfloor \log_2 a_{\max} \rfloor - 6$	RNE	限幅 ±127
4 bit（V）	$\lfloor \log_2 a_{\max} \rfloor - 2$	RNE	限幅 ±7

$a_{\max}$ 是本组参与量化的元素的最大幅值（§4）。

可选前置步骤：通道置换。 按编译期固定的置换表重排一个 token 的全部通道，再分组。用于 K 与区块摘要：POST 在量化入口施加，PRE 在读时旋转后的重量化入口施加。PairFold（RoPE 通道对的缩放）离线折入 Q、K 归一化权重，QNT 不做折叠；是否需要运行时可选【设计者定】。

附带输出：每行各组尺度中的最大指数——Q 的 qmax、K 的 kmax、记录头的 tokmax。MXU 以 qmax + kmax 作 $S = QK^{\mathsf{T}}$ 的累加基准。

凑组。 MXU 一拍只交出一个 token 的 16 个输出通道，凑不满一组。QNT 按 token 凑满 32 个通道再量化：**打包单位是 MX 组**（一个 token 的 32 个相邻输出通道），阵列两个 pass 凑一组，QNT 即量化、按 SEL 判决压紧，产出"该

token 该组"的一段（传输协议篇 §9.7）。段怎样拼成记录见 §3.7。

尺度有两种来源：

- **本核求出**：一组的 32 个通道都在本核。
- **跨核取最大**：输出维 m 切分到多核（$Y = XW$ 中 W 的列分给不同核）时，一组 32 个通道可能分在两核上。各核把本核的部分 amax（FP32）放进 QNT 的结果寄存器，由本核 CCU 读出、经命令与标量网发 CRU（不落 L1）；CRU 取最大后把共同 amax 发回各核 CCU，由 CCU 写进 QNT 的合并值寄存器（用户 11-05）；**CCU 写好之后才发按共同尺度编码的指令**，QNT 不设有效位、不因 amax 未到而 stall，等待期间的数据可卸载到 L1（§2.3）。同一部分值只发一次。档号 3 的 token 不进跨核 amax。

K 在 RoPE 之前存储（PRE）必须支持（用户 11-04）：PRE 与 POST（RoPE 之后存储）用同一格式，区别只在量化位置。

	元素 0	元素 1	元素 2	元素 3	元素 4	元素 5	元素 6	元素 7
x（BF16）	31.2	-4.24	1.6	10.5	-0.12	12.4	0	21.2
$x / 2^2$	7.8	-1.06	0.4	2.625	-0.03	3.1	0	5.3
	7.8 > 7.5 饱和			2.625 中点取偶				
E2M3 值	7.5	-1	0.375	2.5	0	3	0	5.5
还原 = 值 × 2^2	30	-4	1.5	10	0	12	0	22

组内最大幅值 31.2，$\lfloor \log_2 31.2 \rfloor = 4$；E2M3 最大指数为 2，组尺度 E8M0 = $2^{4-2} = 2^2$

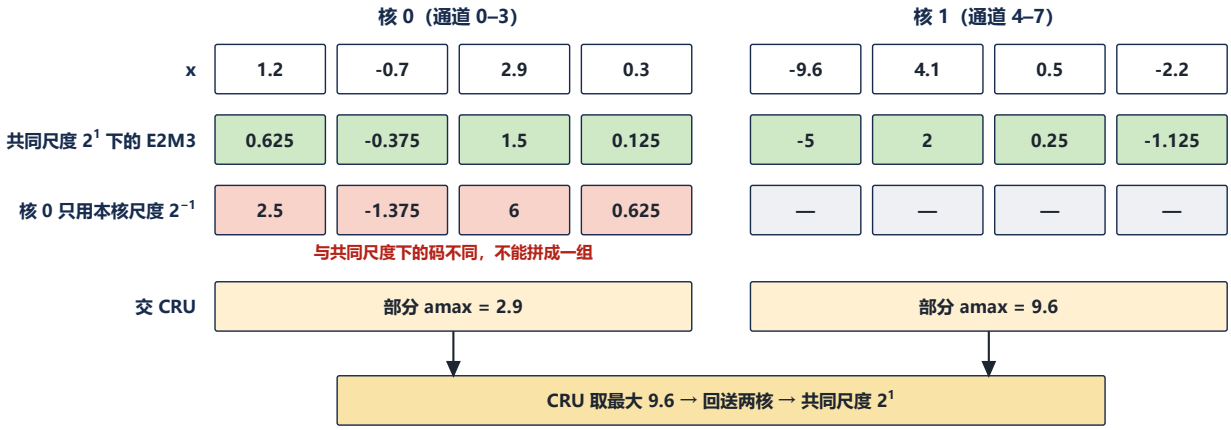
全零组	0	0	0	0	0	0	0	0

尺度取合同约定值，码全 0，不产生 NaN

缩小例一组 8 个元素，实际一组 32 个。组内最大幅值 31.2，组尺度 $2^{4-2} = 2^2$。各元素除以 4 后按 E2M3 取最近的可表示值：

- 元素 0 的 7.8 超过 E2M3 最大值 7.5，饱和到 7.5；
- 元素 3 的 2.625 恰在可表示值 2.5 与 2.75 正中，按 RNE 取尾数为偶的 2.5；
- 元素 2 的 0.4 落在非规格化区，取 0.375。

全零组给出确定的尺度与零码，不产生 NaN；尺度取值由量化合同约定。

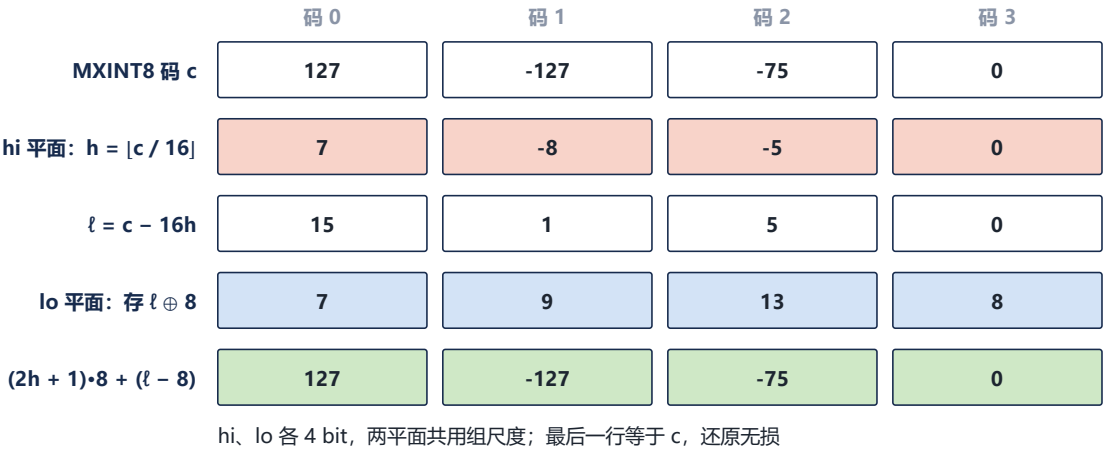


一组 8 个通道（实际 32 个），核 0 持通道 0–3、核 1 持通道 4–7。两核的部分 amax 为 2.9 与 9.6，CRU 取最大 9.6，共同尺度 2^1，两核按它编码，拼起来就是整组一起量化的结果。若核 0 只用本核尺度 2^{-1}，得到的码与共同尺度下的码不同，两半不能拼成一组。

3.3 两平面表示：一个码按位拆成 hi / lo，或把量化误差再量化一次

码位拆分（K 存储与读时重量化、V 8 bit）：

- MXINT8 码 $c = 16h + \ell$，h 为有符号 4 bit，$\ell \in [0, 15]$；
- hi 平面存 h，lo 平面存 $\ell \oplus 8$、读作 $\ell - 8$；两平面共用一个组尺度；
- **还原式** $(2h + 1) \cdot 8 + (\ell - 8) = c$；
- 只读 hi 的消费者（粗算）按 $(2h + 1) \cdot 8$ 近似 c，即取 hi 区间的中点。



四个码 127、−127、−75、0 拆成 hi / lo，最后一行按还原式算回原码，无损。

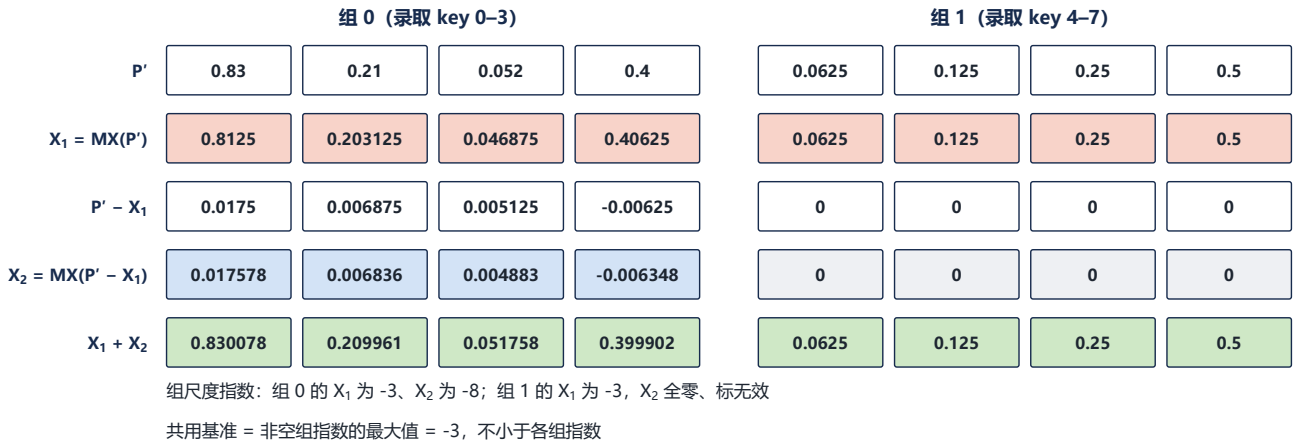
残差再量化（P'）。P' 是 P×V（$O = PV$）的左操作数，一个查询行对录取 key j 的元素为 $P'_j = \tilde{p}_j \cdot S_{V,j}$（未归一化的 softmax 权重乘该 key 的 V 尺度）。它要拆成两个 MXFP6 平面：

$$X_1 = \mathrm{MX}(P'), \qquad X_2 = \mathrm{MX}(P' - X_1),$$

$\mathrm{MX}(\cdot)$ 表示按 MXFP6 E2M3、每 32 个录取 key 一组量化。

- **只量化录取位置。**
- **两平面共用一个基准指数**：一个查询行在一个 P×V 录取 tile 内、两平面所有非空组的最大指数。MXU 以它为累加基准，所以基准须不小于各组的指数；具体取法【设计者定】。
- 全零的第二平面组标无效，不参与基准。
- head_dim 为 256 / 512 时，V 每 128 维一个尺度，P' 按 128 维组出 2 / 4 套，每套各自两平面。

和值回送。 对同一批 $\tilde{p}_j$ 做同样的两次量化，按 key 把 $\mathrm{MX}(\tilde{p}_j) + \mathrm{MX}(\tilde{p}_j - \mathrm{MX}(\tilde{p}_j))$ 回送 NLU 累加行和 l，使分母与分子同口径。行和只累加一次，不随套数增加。



一行 8 个 P' 分 2 组（实际每组 32 个录取 key），图中数值保留 6 位小数。组 0 的 X_1 尺度指数 −3，残差再量化后 X_2 尺度指数 −8，$X_1 + X_2$ 的误差比只用 X_1 小一个数量级以上。组 1 的值恰好可表示，X_2 全零，标无效、不参与基准。共用基准取非空组指数的最大值 −3。

3.4 按判决位压紧：去掉不读的元素，其余按原序连续存放

判决位一律来自 SEL，QNT 不做比较（用户 11-04）。下一位点输入的保留判断：QNT 把一个 token 各通道的幅值交 SEL，暂存对应的一段向量，收回保留码后再压紧。暂存与往返的时序【设计者定】。

保留码的含义：下一位点 $Y = XW$ 中，token t 的输入通道 k——

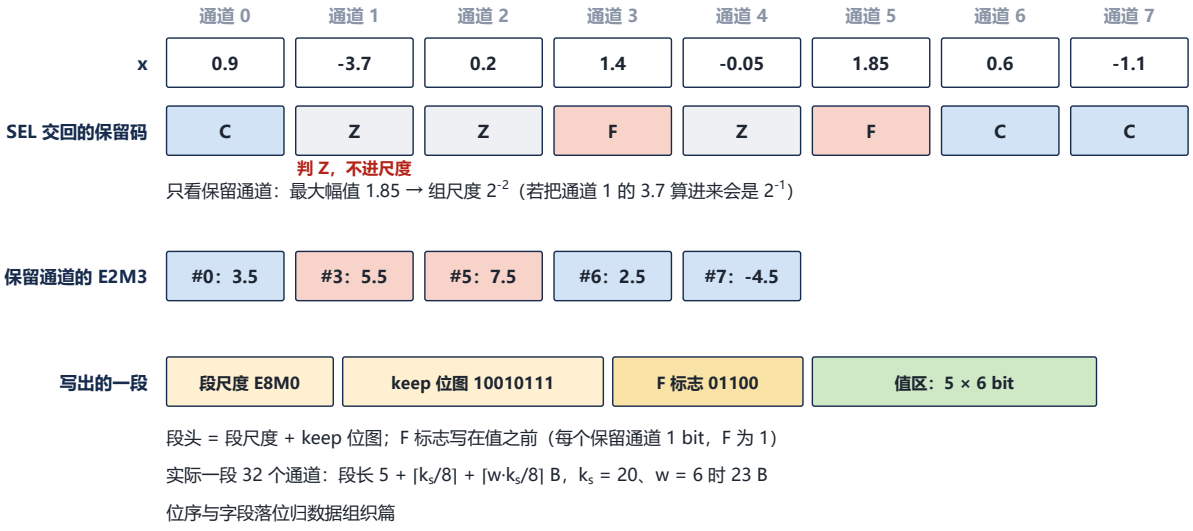
- **Z**：不读，下一位点跳过 W 的第 k 行；
- **C**：只读权重 hi 平面；
- **F**：读权重 hi + lo 两个平面。

先压紧后量化（下一位点输入的紧凑记录、尾部特征行）：

- 按保留码去掉 Z 通道，**组尺度只取保留通道的最大幅值**，再编码；
- 每段（32 个输入通道）写出：段头（段尺度 + keep 位图）、F 标志（每个保留通道 1 bit，写在值之前）、值区；
- 段长 $5 + \lceil k_s/8 \rceil + \lceil w\,k_s/8 \rceil$ B，k_s 为该段保留的通道数，w 为元素位宽 6 或 8；
- 同时把每（token, 位点）的 keep 字数、keep 位图与 F 位图交 CCU 分组单元；
- 输出维 m 切分到多核时，各核写本核的子记录；
- **所有位点写出时即压紧**（用户 11-04）。

先量化后压紧（Q 粗算记录）：

- 码与组尺度逐位不变，只去掉未选的元素；
- SEL 给的选维位按 NLU 的维序，QNT 用 K 的通道置换表把它重排成 Q 记录的维序；
- Q 粗算记录与 Q 全维记录同时写出（§3.5），粗分数 $\tilde{S} = QK_{\text{hi}}^{\text{T}}$ 只在选中维上求和。



一段 8 个通道（实际 32 个），以 SEL 交回的保留码为输入。通道 1 的幅值 3.7 最大，但被判 Z，不进组尺度：保留通道的最大幅值 1.85，组尺度为 2^{-2}；若把 3.7 也算进来会是 2^{-1}，保留通道都要多丢一位精度。写出的一段依次是段尺度、keep 位图、F 标志（5 个保留通道中通道 3、5 为 F）、5 个 6 bit 值。实际一段 32 个通道、保留 20 个、$w = 6$ 时段长 23 B。

3.5 定长记录组装：码、尺度与附带字段拼成记录，按指令给的去向写出

所有记录都先经 RRAM 口写本核 L1。 去向写"L2"的，再由 L1 发送侧按 MAE 的发送命令经 C2H 写 L2；写"L1"的留在本核。"打包档"一列是传输协议篇 §9.2 的三档（② 固定槽 + 有效计数，③ 变长紧凑 + 头）。

记录	组成	每单位字节（head_dim 128、hidden 2,560 时）	去向	打包档
Q 全维记录	MXFP6 码 + 每 32 维一个 E8M0 + qmax + 选维位	每（行, q 头）码 96 B + 尺度 4 B + qmax + 选维位 16 B	L1；不落 DDR	数据组织篇定
Q 粗算记录	选中维的码 + 段 E8M0， 与全维记录逐位一致	随选中维数	L1	③ （随选中维数变长）
P' 记录	两平面、组尺度、 共用基准、录取位置	每（行, 32 个录取 key） 两平面各 24 B 码 + 各 1 B 尺度	L1	③（随录取 key 数变长）

记录	组成	每单位字节（head_dim 128、hidden 2,560 时）	去向	打包档
残差记录	64 通道一个 tile：48 B 码 + 2 B E8M0	每 tile 50 B，每 token 2,000 B	L2	数据组织篇定
紧凑记录	记录头（含 token 序号，§3.7）+ 各段（§3.4）	全保留、$w = 6$ 时每段 33 B，每 token 8 + 80 × 33 = 2,648 B（记录头按现行 8 B 计）	L2	③
反传流动梯度记录（dX / dY / dH / dP / dS / dz）	记录头 + 各段，按流动梯度格式量化	随格式与保留数	L2 或 L1（由指令给去向）	③（用户 11-05）
K 存储记录（PRE、POST 同）	hi 平面 + E8M0 + kmax；lo 平面	每（key, kv 头）hi 68 B（64 B 码 + 4 B 尺度）+ kmax 1 B；lo 64 B	L2（再经 MAE 写 DDR）	②
V 存储记录	8 bit：hi、lo 两平面；4 bit：单平面；尺度写入每存储 tile 的尺度数组	每（key, kv 头）8 bit 128 B + 1 B 尺度；4 bit 64 B + 1 B 尺度	L2	②
本次 attention 用的新 K	同 K 存储记录	同上	L2	②
读时旋转后的 K	粗算段：hi + E8M0 + kmax；精算段：录取 key 全码	粗算段每（key, kv 头）68 B + 1 B；精算段 132 B	写 L1 → L1 发送侧经 C2H 进 L2 → 经 H2C 多播进需要的核的 L1	②
区块摘要	MXINT8，与 K 同一通道置换	每（区块, kv 头）128 B 码 + 4 B 尺度	L2	数据组织篇定

要点：

- **Q 全维记录在选维位回来之后才写出完整记录头**；同时写 Q 粗算记录（用户 11-04）。

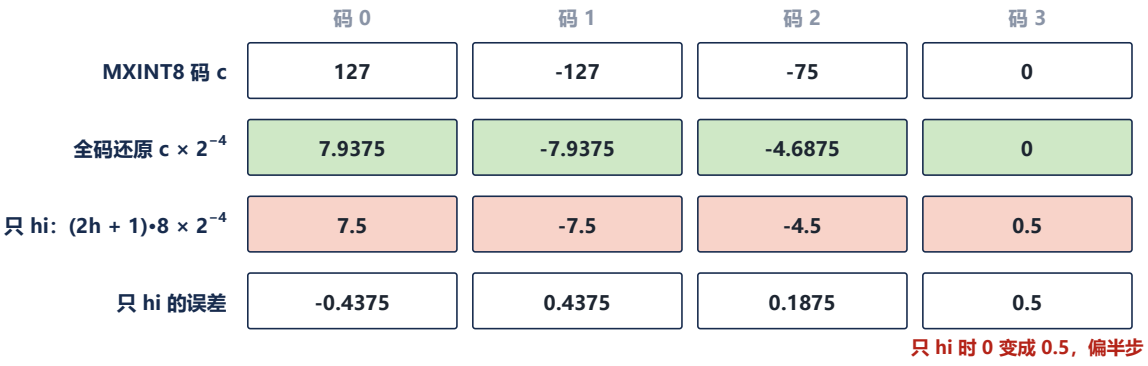
- P' **记录由 QNT 组装**（用户 11-04）：两平面、组尺度、共用基准都在 QNT 手里，NLU 随 P' 交来录取 key 的位置，QNT 拼成记录写 L1，供 MXU 算 $(P \times V)_{\text{tile}}$。NLU 只收回 $\tilde{p}$ 的两平面和值。
- **残差只在出口级残差加之后编码一次**；第 0 层的嵌入行按同一规则编码；不设大值旁路、不设 BF16 旁带（用户 10-23）。
- K 的**粗算部分 = hi 平面 + 尺度 + kmax，补读部分 = lo 平面**（用户 11-04）：粗算只读粗算部分，录取的 key 才补读 lo。
- **读时旋转后的 K 按 K 存储记录的字节格式上行写 L2，再由 MAE 命令经 H2C 多播进需要它的核的 L1**（用户 11-04，V18-L1-05）：格式与 POST 下的 K 相同，进核时与入站 K 同一条落地路径，由落地一侧排成 MXU 读 K 区所需的存储形态。多个核需要同一批 K 时，key 可按核切分：各核只旋转一部分，再互相多播，不必每核重复旋转全部 key；切分由 LIC 安排。QNT 不排 L1 的存储形态。
- 各记录的字段位置与位序归数据组织篇。

3.6 解码与还原：码 × 尺度，还原成计算用的值

K 存储码的还原（PRE 下的 K 链）。PRE 下，K 以未旋转的码存储；用之前要解码、交 NLU 旋转、再交 QNT 重量化。本次新算出的 K 与从 L1 读出的历史 K 走**同一条链**，只是输入不同：

还原方式	用到的平面	算式	用途
全码	hi + lo	$c \cdot 2^e$	精算段（录取 key）
只 hi	hi	$(2h+1) \cdot 8 \cdot 2^e$	粗算段

按本层 K 存储精度码选还原方式（§5.1）。



与 FIG-VNU_QNT-PLANE-BITSPLIT 同一组码，组尺度取 2^{-4}。只 hi 时取区间中点，误差不超过半个 hi 步长（$8 \cdot 2^{-4} = 0.5$）；码 0 只 hi 还原为 0.5，正好偏半步。

残差与特征行的还原不在 QNT，在 MXU 出口级（用户 11-04）。

可选：统一临时格式（用户 11-04）。VNU 的规范输入只有 BF16 与 MXFP6 g32 两类，下列临时格式可由设计者选择在 QNT 统一成这两类之一，再交其他单元：

- OPT 自有格式（MXINT8 权重副本、优化器状态 m、v）；
- MXFP6 装不下时可选的 FP8 / BF16 / FP16 梯度；
- 元素位宽 8 位点的 MXFP8 E4M3；

- 交 LOSS 的 teacher 概率。

是否做、做哪些【设计者定】。

3.7 写出：记录级 32 B 对齐，记录带 token 序号，权重驻留下按 token 槽拼接

本节是 QNT 写 L1 时须遵守的传输协议篇 §2.4、§2.5、§3.4、§9 的规则（用户 11-05，V18-TP-03 / 10 / 11 / 16）。

QNT 写 L1 只给数据与长度，地址由 CCU 推理。 QNT 经 RRAM 口交出 din（一个存储字，32 B）与本条记录的长度，进 A 类写集合器里 QNT 的入口 FIFO（将满时 wr_stall 回 QNT）；en / wea / addr 由 CCU 发出：CCU 按记录长度 n_i 累加存储字数，只记每条记录的首字号，环形回绕也由 CCU 做。QNT 不算地址、不解析 L1 的空间布局。

记录级 32 B 对齐（用户 11-05，传输协议篇 §2.5、§9.1）。**对象**是一个 token 组的紧凑激活记录、一段反传流动梯度、一张位图、一个列表、一组 TOPK 项、一组 K / V 平面等；**记录**是对象里按 token（或按项）独立取用的单位。**对齐的单位是记录，不是对象：**

- 对象头单独占一个存储字，不足补 0；
- 每条记录（紧凑激活记录、流动梯度记录、位图、列表、TOPK 项）从一个整字开始，占 $\lceil n_i/32 \rceil$ 个存储字（n_i 为该记录的字节数），尾部补 0 到字边界；下一条记录从下一个整字起；
- **没有记录跨字被拆开取用，也没有字内偏移**：任一存储字只属于一条记录或一个对象头，读一条记录就是从它的首字号起连续读 $\lceil n_i/32 \rceil$ 个存储字；
- **L1 的最小写单位是一个存储字（32 B）**：QNT 攒满 32 B 才写一个字，记录的尾字补 0 后整字写出。

存储字是传输协议篇给 32 B 单位起的名字（用户 11-05，§2.1），地址里的字号就是它的序号；本篇里"行"只指矩阵的行与 token 行。

- 代价：每条记录平均浪费 16 B；紧凑激活记录一条 KB 级，占比 < 1%。

对象头与记录头（骨架见传输协议篇 §9.3，字段位宽归数据组织篇）：

头	字段	QNT 怎样填
对象头	类型、总长（字节）、记录数、首 token 序号、token 数	首 token 序号与 token 数随指令给出； 总长与记录数在对象写完时才确定。**对象头单独占一个存储字，由 QNT 在对象写完后整字写一次**（用户 11-05）；记录从对象头的下一个字起写，不受对象头补写影响
记录头（③ 档）	本记录的 token 序号（16 bit）、段头序列（E8M0、keep 位图、F 标志）	token 序号随请求给出；记录长度由各段 keep 位图的 popcount × 元素位宽 + 头长算出，CCU 据此累加存储字数、 得到下一条记录的首字号

② 档对象（K / V 平面）按槽存放，对象头的记录数即有效计数，末槽填 0（传输协议篇 §9.2）。

段按 MX 组产生，记录按到达顺序或 token 槽拼接（传输协议篇 §9.7）：

驻留	段到达顺序	QNT 写出
token 驻留（先算完一个 token 的全部输出通道）	token 0 的组 0、1、…；再 token 1	顺序追加，每条记录从整字起、尾部补 0； 对象按实际长度 bump 分配；CCU 一个写累加器
权重驻留 （先算完一个列块的全部 token）	组 0 的 token 0…$T-1$；再组 1 …	输出激活对象 = T 个按记录上限定长的 token 槽；**CCU 每 token 一个写累加器**，段按到达顺序续写该 token 槽；记录尾字补 0，槽尾留空

两种驻留的记录格式相同，消费方不感知。**记录级对齐后，一个 MX 组的段（例如 23 B）仍可能不足一个存储字，而权重驻留下相邻到达的段属于不同 token，L1 又只能整字写**，所以 QNT 攒字：为每个在写的 token 槽各保留一个未满字，攒满 32 B 才写进集合器 FIFO，记录写完时把尾字补 0 写出（T 个槽约 $T \times 32$ B，$T = 128$ 时 4 KB）；这块缓冲放在 QNT 内还是另有做法【设计者定】，容量随之计入自有存储。

变长对象按实际长度分配；上限只用于 token 槽。 紧凑记录、反传流动梯度、Q 粗算记录、P' 记录是 ③ 档变长对象，**源空间由 CCU 按实际长度 bump 分配，不预留上限**（用户 11-05，传输协议篇 §7.3）。只有权重驻留下并发增长的 token 槽按上限留，编译期的静态检查也用同一上限（传输协议篇 §9.7）：有封顶的位点 = k + 本域强制入选数；没有封顶的阈值位点 = 全保留时的记录长度（hidden 2,560、$w = 6$ 时 2,648 B，比稠密 MXFP6 的 2,000 B 多出段头与 F 标志，取整为 83 个存储字）（用户 11-05 认可）。**在 token 槽里，QNT 与 SEL 保证写出的记录不超过槽上限**；超过是传输协议篇 §10 的致命错误。实际长度由 CCU 在对象结束时经命令与标量网报 MAE，QNT 不报。

反传在算子之间流动的梯度（dX / dY / dH / dP / dS / dz）按 ③ 档打包：对象头 + 记录头 + 段，与前向紧凑记录同一种结构，元素按位点配置的流动梯度格式量化（用户 11-05，传输协议篇 §9.2）。

用整行统计量判决的位点（相对阈值、QDS 行均值）在权重驻留下，判决要等全部列块算完：这些位点的输出先以 BF16 写 L1，行统计就绪、SEL 给出判决位后，QNT 再从 L1 读回、压紧与量化。哪些位点如此，由 CCU 篇按 SEL 的选择模式逐位点列出（用户 11-05）。

散写不由 L1 解析。 token 切分时各核的记录散写到各自位置，由 hub 按道顺序发出、地址由发送方累加；记录头里的 token 序号用于接收方校验、乱序到达时落位与仿真对拍，L1 不按它定位（传输协议篇 §9.5、§9.8）。

4 参与量化的元素与特殊值

1. **只量化请求给出的位置**：P' 只有录取位置。
2. **判为 Z 的通道不参与组尺度**（§3.4）。
3. **档号 3 的 token 不量化、不出记录、不进跨核 amax。**
4. **全零组**给出确定的尺度与零码，不产生 NaN；全零的第二平面组标无效（§3.3）。
5. **超出格式范围的值**按 §3.2 的饱和或限幅处理，并计数（§8）。

5 参数与配置的来源

5.1 模型级配置在调用开始时锁存

以下配置在调用开始时锁存，调用内不变（用户 11-03）：

- **K 存储位置**：PRE 或 POST，两种都必须支持。
- **逐层 K 存储精度码**：4 bit，0000 表示每个有效元素存 8 bit（尺度等元数据另计），其余 15 码保留。**同一层的量化写入、MAE 的地址计算与 QNT 的解码共用这一个码。**
- **V 位宽**：4 bit 或 MXINT8，与 K 存储位置无绑定。

5.2 通道置换表

按（层, kv 头）装载。PRE 下本次新 K 的复算与读时旋转共用同一张表。

5.3 每个请求的参数由指令给出

格式、组长、是否拆平面、是否压紧、元素位宽 w、流动梯度格式都由指令给出。**新配置在位点边界生效，在途的向量按旧配置做完。**

5.4 QNT 不存门限

保留判断的门限、按档号选门限、偏置都在 SEL（用户 11-04）。QNT 只按 SEL 的判决位与 CCU 的档号行事。

6 精度要求、格式合同与结果规则

6.1 精度要求分三层

QNT 的输出会被别的模块按约定解读：MXU 把码乘上 2^e，对 hi 取 $(2h+1)\cdot 8$ 直接乘；MAE 按字节搬 K / V 平面；DDR 中的 KV 下次调用、其他核还会再读。所以要求分三层（用户 11-04）：

1. **格式定义逐位一致**：码与尺度的含义、hi / lo 的拆法与只 hi 时取中点的还原、各记录的字节布局。解码方不在 QNT 里，这一层错一位就是功能错误。
2. **同一个量在多处产生时逐位一致**（§6.2）。
3. **选码规则按集成后掉点 < 0.1% 放开**：QNT 的计算方案集成到算法后，任务精度下降 < 0.1%（按绝对百分点；基线为同一算法下各运算按 FP32 理想值计算；评测集为算法侧标准评测集）。§3.2 的规则是默认；设计者要改尺度指数、舍入或饱和规则，须交回算法侧同步参考模型并重测。P' 的共用基准只约束"不小于各组指数"。

中间精度不规定。与参考模型逐位比对只作验证手段，参考模型随硬件实现同步。

6.2 同一个量在多处产生时必须一致

- **PRE 本次新 K 复算与读时旋转是同一条链**：同一存储码、同一 key 位置、同一均值与置换设置下，输出逐位相同。所以本次用的 K 与后续调用、训练前向重算读入后旋转得到的 K 相同。
- 残差的编码（出口级残差加之后、第 0 层嵌入行）与出口级的还原按同一残差格式定义。
- q 经出口级交出的格式无论取 MXFP6 g32 还是 BF16，RoPE 之后都得到同一种 Q 格式。

6.3 确定性

- 结果与请求到达的先后、所在的核无关。
- 线性位点的结果与同批 token 数无关。

- P' 的分组是否随同批其他行变化【设计者定】。

6.4 写出次序

- 一段的 F 标志先于该段的值可读：它决定下一位点每行读一个权重平面还是两个。
- 压紧的记录晚于该 token 的判决位到达。
- Q 全维记录晚于该行的选维位。

6.5 输入与输出

输入为 BF16 向量、FP32 语义的标量（amax）与 K 存储码；输出见 §3。

6.6 交设计者定的格式项

以下各项由设计者定（用户 11-04）；**属于格式合同的项定下后，须同步算法参考模型与各解码方**：

- q 经出口级交出的格式（MXFP6 g32 或 BF16）的取法；
- BF16 / FP16 激活进阵列时的拆段位置（MXU 侧）；
- 流动梯度的组轴与尺度：逐 token 沿通道成组，还是为 $\mathrm{d}W$ 的跨 token 归约沿 token 成组；
- $\mathrm{d}P$ / $\mathrm{d}S$ 用流动梯度格式集合中的哪一种；
- P' 共用基准的取法；
- PairFold 是否需要运行时可选。

7 速率与时延

7.1 每拍处理能力匹配上下游模块

QNT 每拍能处理的元素数，须匹配上下游各口的需求，由 QNT 设计者与以下模块对接确定（用户 11-04）。参考值只作背景，不是 QNT 的定值：

相关模块	接口	现行参考值
MXU 出口级	出口级请求	交 VNU 合计每拍至多 16 个元素。**QNT 与 NLU 的合计负载不得使出口级持续反压阵列出口缓冲，不得反压 FBA**
NLU	待量化向量、回送	每拍至多 16 个元素
NLU（PRE 读时旋转）	待解码的 K 存储码、解码后的 K、旋转后的 K	K hi 入流单核约 36、2 核约 18、4 核约 9 元素/拍；**每个元素经 QNT 两次**（解码、重量化），单核约需每拍 72 元素·次；并行度【设计者定】
SEL	待判断幅值、判决位	选维每行一次往返；保留判断每拍至多 16 个通道

相关模块	接口	现行参考值
CCU（结果寄存器 / 合并值寄存器）	amax 往返（CCU → CRU → CCU）	每（token, 跨核组）一次往返；FP32，网上每 64 bit 字 2 个；往返时延不定要求值，CRU 并行 lane 可配（传输协议篇 §6.4）
CCU 分组单元	keep / F 位图	每（token, 位点）一次
LOSS	$\mathrm{d}z$	随 LM Head logit 流
L1 发送侧（先写 L1 再发出）	上行	先写 L1，再由 L1 发送侧经 C2H 发出（发送命令送 CCU，CCU 发读）；读 L1 占一个激活类读口时隙，由 CCU 排；发送命令送 CCU、CCU 发读；上行负载归 HUB 流量预算
VNU 的 RRAM 口	L1 读写	读：经选择器用一个激活类读口（32 B/拍），时隙由 CCU 排，固定 1 拍，读回入口将满时拉 stall_vnu[i]；写：进 A 类写集合器里 QNT 的入口 FIFO，写整字，将满 wr_stall 回 QNT；同一阶段并发写者总需求 ≤ 道数 × 32 B/拍由编译链保证

若设计上认为 PRE 读时旋转所需的速率极难支持，可重新考虑由 MAE 加回 RoPE（用户 11-04），即 K 在入核时就完成旋转，不再经 QNT 解码与重量化。

7.2 QNT 自身时延

项	参考
一条 2,560 元素的向量	按每拍 16 个约 160 拍

QNT 不丢请求，只经握手让上游停发（传输协议篇 §4）：对出口级是相邻级的一根 stall（VNU → 出口级）；对由 CCU 发读的入口是 stall_vnu[i]；组内来自 NLU、LOSS 的请求按组内链路的握手停发。写 L1 只受本单元写 FIFO 的 wr_stall 控制，QNT 保持待写的字、不丢。

8 计数与复位

- **计数**：饱和与限幅的次数，供 LIC / MAE 读取。
- **复位**：清在途量化、凑组缓冲与等判决位的暂存。
- **QNT 不保留跨调用状态**；模型级配置与置换表在调用开始重新装载。
- **不设运行时错误事件**：§2.4 所列前提由对应模块保证，验收时用断言检查。token 槽不超上限由 SEL 与 QNT 保证（§3.7）；万一超出，属传输协议篇 §10 的致命错误，报 LIC；QNT 在命令与标量网上没有端口，由本核 CCU 转报（用户 11-05 定；槽的 bump 计数在 CCU，通常由 CCU 直接发现）。

9 要求值与验收

9.1 要求值

项	要求值	说明
运算形态	按组量化编码、两平面表示、按判决位压紧、定长记录组装、解码与还原	格式与去向由指令给出
目标格式	MXFP6 E2M3、FP8 E4M3、E5M2、MXINT8、4 bit、BF16 / FP16 整值	组长 32 / 128
每拍处理能力	匹配上下游各口（§7.1）	由 QNT 设计者对接确定
精度	集成后掉点 < 0.1%；格式定义与多处产生的量逐位一致（§6.1）	—
门数	参考 ≤ 35 k 门（NAND2 等效，现行估算）	不含 L1 内的记录区与卸载区
自有存储	凑组缓冲与等判决位的暂存【设计者定】；权重驻留下每个在写 token 槽一个未满字（约 $T \times 32$ B，§3.7）【设计者定】	不存门限
L1 建议值	P' 记录 3 份；卸载区【设计者定】	A 类地址段由编译链分配
写出	记录级 32 B 对齐：对象头单独占一个存储字，每条记录从整字起、占 $\lceil n_i/32 \rceil$ 个存储字、尾部补 0、整字写出；变长对象 bump 分配，token 槽留上限；记录头含 token 序号 16 bit；对象头含首 token 序号与 token 数	传输协议篇 §2.5、§9
L1 口与握手	RRAM 口，写只给 din 与长度；读回入口一根 stall_vnu[i]	L【设计者定】
交 CRU 的 amax	结果寄存器（CCU 读）/ 合并值寄存器（CCU 写），FP32，不落 L1；QNT 在命令与标量网上无端口、无有效位	传输协议篇 §8.1、§8.2

9.2 验收

对象	方法	用例
按组量化编码（§3.2）	与参照量化器逐位比对	各格式 × 组长；RNE 中点、饱和、全零组；跨核 amax 回送后的共同尺度
两平面表示（§3.3）	逐位比对；还原式断言	hi / lo 拆分全码域；P' 共用基准不小于各组指数；第二平面全零组标无效；head_dim 256 / 512 多套 P'
按判决位压紧（§3.4）	给定判决位，与参照打包器逐位比对	全保留、全 Z、最大幅值通道被判 Z；$w = 6$ / 8；Q 粗算记录与全维记录逐位一致

对象	方法	用例
记录组装（§3.5）	与数据组织篇布局逐字节比对	各记录
解码（§3.6）	逐位比对	全码、只 hi
同一量多处产生（§6.2）	断言	PRE 新 K 复算与读时旋转对同一存储码输出相同；残差两处编码相同
确定性（§6.3）	断言	乱序注入、换核运行结果相同；同批 token 数变化不影响线性位点结果
集成精度（§6.1）	算法侧标准评测集	掉点 < 0.1%
卸载与读回（§2.3）	周期仿真；逐位比对	卸载到 L1 再读回处理的结果与直接处理相同；stall_vnu 拉起后读回入口不溢出
写出规则（§3.7）	与数据组织篇布局逐字节比对；断言	对象头单独占一个存储字；每条记录从整字起、尾部补 0、不跨字；记录头 token 序号；token 驻留与权重驻留两种段到达顺序下记录逐字节相同；token 槽不超上限；wr_stall 拉起后不丢写
不持续反压出口级（§7.1）	周期仿真	出口级峰值注入；PRE 读时旋转同窗口
门数（§9.1）	综合	待 RTL

10 为什么

- **对外接口经 VNU 组封装**（用户 11-04）：QNT 是 VNU 组内的单元，访问 L1、向核外上行都经 VNU 的共用口。
- **一个单元同一时刻只执行一种功能**（用户 11-04）：VNU 内各单元的功能由指令排先后，不必为几种功能同时到达预留并行与仲裁；以后有并行需求再调整。
- **来不及处理就卸载到 L1**（用户 11-04）：P' 等请求不必在入口排队，经 L1 读写接口写到 L1 再读回。
- **旋转后的 K 经 L2 多播**（用户 11-04，V18-L1-05）：经 C2H 写 L2 再多播，多个核需要同一批 K 时可各转一部分、互相多播；进核后与入站 K 同一条落地路径，QNT 只按 K 存储记录的格式交出。
- **上行先写 L1、由 L1 发送侧发出；L1 不仲裁**（用户 11-04 / 11-05，V18-L1-02 / 03、V18-TP-06）：发送源只有 L1 发送侧与 AEB 直达口两个，VNU 的 RRAM 口按 CCU 排的时隙分时使用。
- **按传输协议篇同步**（用户 11-05，V18-TP-01…16）：地址只在 CCU 一处推理，QNT 只给数据与长度；amax 是几个 FP32，不占 L1 与数据网；记录级 32 B 对齐（用户 11-05："以 32B 为单位去对齐，这样还可以和一个 Bank 的位宽匹配"），没有跨字与字内偏移，CCU 只记每条记录的首字号，L1 不需要字节写使能与跨深度拼接；第二轮（用户 11-05）写侧改为集合器 FIFO + wr_stall，变长对象按实际长度 bump 分配、上限只留给并发增长的 token 槽；权重驻留下段按列块顺序到达，必须按 token 槽拼接；记录头带 token 序号，落位可校验。
- **amax 经 CCU 中转**（用户 11-05："直接发给 CCU，由 CCU 直接配置 VNU 内部需要计算数据的寄存器吧…… VNU 的控制命令本来就来自 CCU，那么刚好可以统一调配"，V18-TP-21）：QNT 在命令与标量网上不设端口；共同 amax 到达与按共同尺度编码的指令在 CCU 一处排序，QNT 不需要有效位、不因 amax 未到而 stall。
- **量化与打包只在 QNT 一处做**（用户 11-03）：同一格式只有一处实现，逐位一致的检查也落在一处；出口级只做 BF16 域的运算。

- **判断统一在 SEL**（用户 11-04）：保留判断与 Q 选维、F / C / Z、gate 先筛是同一种逐元素阈值判断，统一在 SEL 做，门限、档号选法、偏置只存一份；QNT 只做量化与打包。
- **Q 粗算记录与 P' 记录都由 QNT 组装**（用户 11-04）：码、尺度与基准都在 QNT 手里，省去回送 NLU 一程与 NLU 的一次 L1 读写。
- **Q 逐维幅值由 NLU 交 SEL**（用户 11-04）：NLU 求行均值时已逐维算过，与均值同源自动成立。
- **残差与特征行在出口级还原**（用户 11-04）：QNT 只面对 BF16 输入。
- **所有位点写出时即压紧**（用户 11-04）：o 位点原有"写出不压紧、读入时再判"的变体，没有意义，已取消。
- **Q 恒为 MXFP6 单平面**（用户 10-24）：新算法的开发不以改动 Q 或其他组件的操作数格式为前提。
- **残差纯 MXFP6、加完只编码一次、不设大值旁路**（用户 10-23）：实测 ΔKL Qwen3-4B +0.084、MiniCPM5-1B +0.054（10-12）。
- P' **用两平面**：精度上的妥协，单平面误差 1.9–2.3%；FP8 E4M3 单平面在试。两平面共用基准，MXU 才能按一个基准累加；全零的第二平面不参与基准，免得拉低基准。
- **凑满 32 个通道再成组**：MXU 一拍只交出 16 个。
- **跨核按共同尺度编码**：一组的尺度必须由整组决定，否则两核的码拼不成一组（FIG-VNU_QNT-AMAX-SPLIT）。
- **组尺度只看保留通道**：被判 Z 的大值通道不读，不该拉大尺度、损失保留通道的精度（FIG-VNU_QNT-KEEP-PACK）。
- **F 标志写在值之前**：它决定下一位点每行读一个权重平面还是两个。
- **PRE 与 POST 同格式，读时旋转复用新 K 复算的链**（用户 11-04 晚，D25）：存储码不含位置相位，前缀复用与压实不改写已存 K；速率极难支持时可回退为 MAE 加回 RoPE（用户 11-04）。
- **K 量化前减通道均值；E4M3 饱和取 ±448**（OCP MX v1.0）。
- **流动梯度默认 MXFP6 单平面**：依据 E30 证据。
- **KV 低位宽是后续可能拓展的方向**（用户 11-04）：沿 token 成组、2 + 2 bit 等格式当前不考虑支持方法。