VNU 选择单元（SEL）需求

> Owner: WangYizhao｜2026-11-04｜重写稿，待用户审阅。按用户 11-04 确认的目录编写（`../V17_3_MODULE_TOC_VNU_SEL_20261104.md` 第二版）；改变现行设计的事项汇总在 `Claude_Design_Spec/V1.8_DESIGN_REVISIONS.md`（V18-SEL-01…10）。
> 11-05 按片上数据传输协议篇（`DATA_TRANSFER_PROTOCOL.md`，V18-TP-01…16）同步：与 L1 的口改为 RRAM 口、地址由 CCU 推理、入口 stall、上行先写 L1 由 L1 发送侧发出、记录级 32 B 对齐、变长输出的上限（§2、§6.7、§7、§8）。
> 11-05 晚第二轮同步（协议篇 §2.1、§3.2、§4.2、§5.2、§6.1、§7.3、§9.7，V18-TP-17…20）：32 B 单位改称存储字；写 L1 = 向 A 类写集合器里本单元的入口 FIFO 写、wr_stall 回本单元；变长对象 bump 分配、上限只用于 token 槽；跨核 OR 的位图以 TUSER 的 CRU 类码直送 CRU（§2、§6.7、§7、§8、§9、§10）。
> 11-05 第三轮同步（协议篇 §4、§5.2、§6.1、§8.3，V18-TP-23 / 24）：CRU 的该项功能改称读集合并（录取读集 / 区块读集 / lo 读集），TUSER 以目的位 = CRU 直送；"反压"作机制名处改称握手（§2、§7、§9、§10）。

1 组成与位置

1.1 SEL 只做比较与排序

SEL（Selection Unit，选择单元）从一组评分里挑出成员：每个元素与门限比较，或在一组元素里取前若干名。**SEL 只做比较与排序。** 门限上的运算只有两种：乘相对系数 α（§3.3），以及只收紧的偏置（§5.3）。SEL 不改评分值、不量化、不取数；需要求和的统计量（如均值）由 NLU 算好交来。

1.2 SEL 是 VNU 组的一个单元，每核一个

一个计算核由 CCU、MXU 组、L1 组、VNU 组四组拼成。SEL 是 VNU 组的六个单元之一，其余五个是 NLU、QNT、SMP、LOSS、OPT。**SEL 与 VNU 组外的模块交换数据，都经 VNU 组的对外接口**；访问 L1 和向核外上行，经 VNU 的共用口。VNU 对外口的个数与共享方式，由 VNU 集成篇定义（待写）。

每个计算核一个 SEL，全芯片 4 个，物理相同。

1.3 模式与参数由指令给出

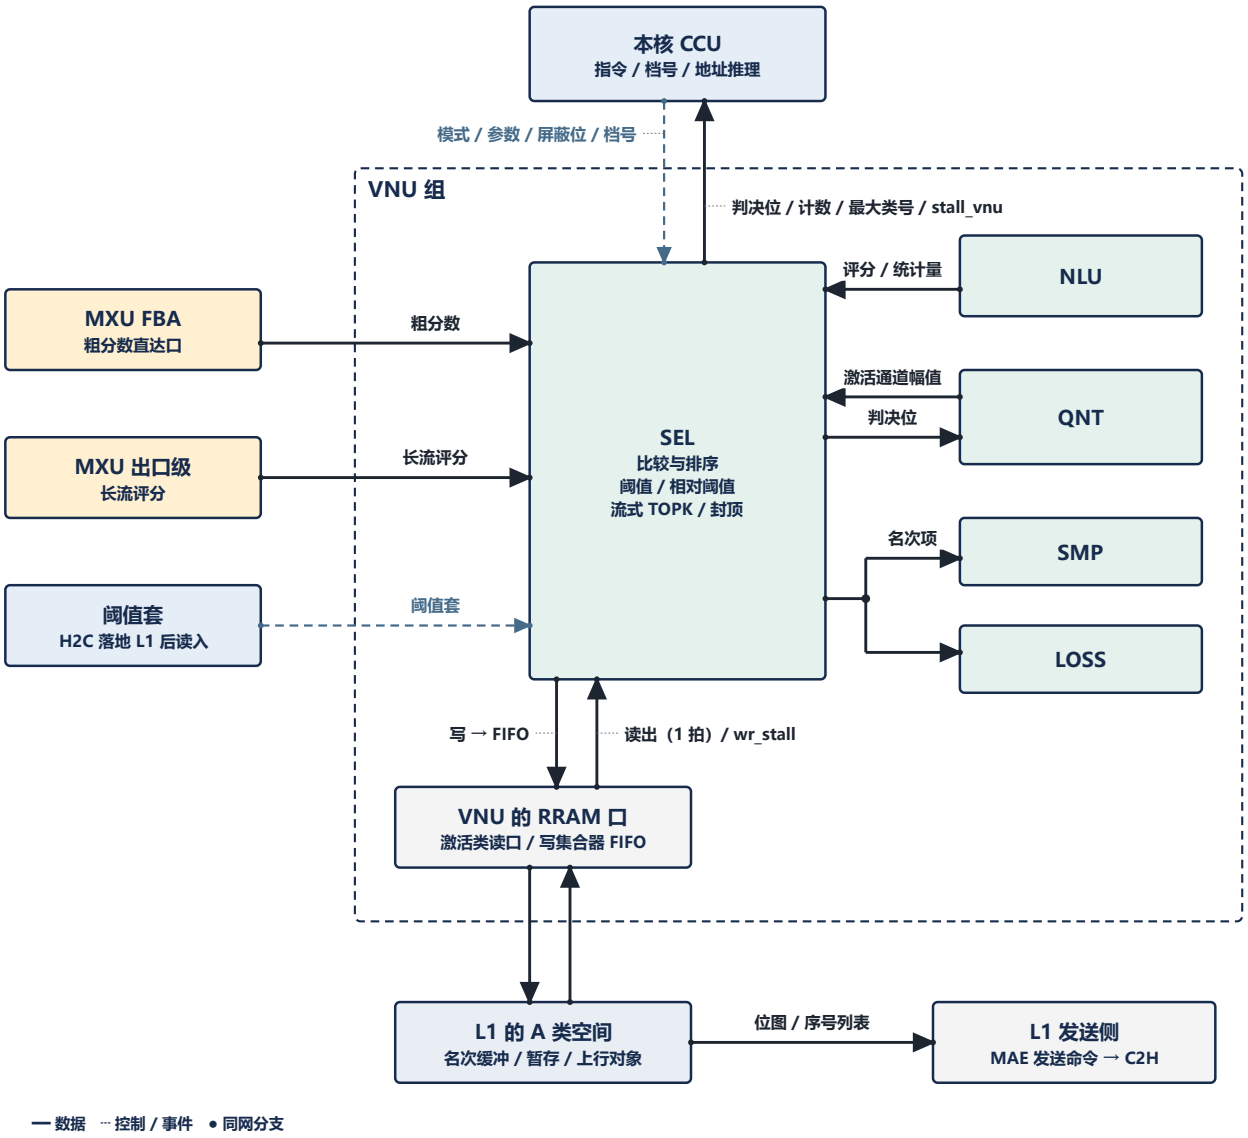
SEL 只提供选择模式（§3）。 一次选择用哪种模式、门限从哪来、取前几名、结果交给哪个接口，都由指令给出。本篇不写指令字段，指令定稿后另补。

SEL 同一时刻只执行一种功能（用户 11-04）：一次做一种选择，先后由指令与 CCU 排定。VNU 内各单元都按此原则；以后有并行需求时再调整。

1.4 稠密计算不经 SEL

指令把一次计算配置成稠密时，SEL 关闭：不先算粗分数，也不产生任何选择结果，全部元素都参与后续计算。

2 数据从哪来、到哪去



虚线框是 VNU 组：

- **框内**是 SEL，以及和它直接往来的 NLU、QNT、SMP、LOSS。这些连线不出 VNU 组。
- **跨出框的连线**都是 VNU 组的对外接口：
  - 左侧从 MXU 进来的粗分数与长流评分；
  - 阈值套：经 H2C 落地本核 L1，再经 VNU 的 RRAM 口读入 SEL 的门限表（虚线，§5.1）；
  - 上方与本核 CCU 之间的指令、档号（虚线）、判决结果与入口 stall。
- **下方的 L1 口**：SEL 不直接连 L1 或 C2H。
  - **VNU 的 RRAM 口**（RRAM 即核内 SRAM 口协议，传输协议篇 §3）分读、写两侧（用户 11-05）：**读**经 L1 外的选择器用 L1 的一个激活类读口（4 个读口都可读任一 A 类 bank，同拍撞 bank 由 CCU 排开，固定 1 拍）；**写**是向 L1 的 A 类写集合器里 SEL 自己那条 32 B 入口 FIFO 写，集合器每拍按优先级把各写者的队头分到对应 bank 的道上，FIFO 将满时拉 **wr_stall** 回 SEL（传输协议篇 §3.2）。读写哪一堆由地址的堆位选，L1 内无仲裁。**每次读写的 en / wea / addr 都由本核 CCU 发出**；SEL 写 L1 时只给 din 与本条记录的长度，不算地址（传输协议篇 §3.4）。
  - **要出核的产出一律先写 L1**：位图与序号列表写进 L1 的 A 类空间，再由 L1 发送侧发出——MAE 的发送命令直接送本核 CCU，由 CCU 发读（用户 11-04 / 11-05，V18-L1-03、传输协议篇 §6.1）。**要做读集合并的位图**（读集合并：把几个核各自要读的数据集合合成一份并集，只读一次再多播；对象分录取读集、区块读集、lo 读集，用户 11-05 定名）经 C2H 以 TUSER 的目的位 = CRU 直送 hub 中心的 CRU，合并后的读集经 HUB-DN 数据网回核写 L1（传输协议篇 §5.2、§6.1）。

FBA 粗分数口是核内唯一的直达口，图中直接穿过 VNU 边界到 SEL。

2.1 VNU 组内的接口

接口	对端	方向	内容	元素格式
NLU 口	NLU	入	评分，每拍 16 个； 相对阈值所用的统计量（如按行均值、$\sum\|x\gamma\|$）；Q 的逐维幅值：一个 query 行的 head_dim 个 $\|q_d\|$	BF16；Q 逐维幅值取 RoPE 之后、 量化之前的值， 与求均值用的数值同源（用户 11-04）
QNT 口	QNT	入	待做保留判断的幅值： 下一位点输入激活一个 token 各通道的 $\|x_k\|$	BF16
判决位交 QNT	QNT	出	阈值判断的逐元素判决位（例如 Q 一行 head_dim 个维的选维位、	每元素 1 bit 或 2 bit

接口	对端	方向	内容	元素格式
			下一位点输入激活各通道的保留位），QNT 按它压紧与打包	
名次口	SMP、LOSS	出	流式 TOPK 的名次项（§3.4）	序号 + 评分

2.2 经 VNU 组对外的接口

接口	对端	方向	内容	元素格式
粗分数口	MXU 定基累加器（Fixed-Base Accumulator，FBA）出口，直达，不经出口级	入	粗分数，即 $\tilde{S} = Q\,K_{\mathrm{hi}}^{\mathsf{T}}$ 的元素：一个 query 行对一个 key 的近似分数，只用 K 的高位平面算出。MXU 每核 4 个同构 pod（计算分组），每个 pod 每算完一个（query 行, 16 个 key）交出 16 个粗分数。**SEL 不反压这个口，判完即丢，不保存粗分数**	BF16 级判决格式
长流评分口	MXU 出口级	入	一条按存储序到达的长评分流，例如 LM Head 的 logit：$Z = H\,W_{\mathrm{head}}$，W_{head} 为 $d \times V$，每个 token 一行 V 个 logit（V 约 15 万）	BF16
指令与档号	本核 CCU	入	选择模式、参数、每个元素的屏蔽位与强制入选位（§4）；每个 token 一个 2 bit 档号，用来选门限档（§5.2）	—
阈值套	经 H2C 落地 L1，再经 RRAM 口读入	入	当前一套门限（§5.1）	—
判决口	本核 CCU	出	每元素 1 bit 或 2 bit 判决、按行计数、最大类号	—
入口 stall	本核 CCU	出	每条由 CCU 发读的入口一根 stall_vnu[i]（§2.3）	1 bit

接口	对端	方向	内容	元素格式
写握手	L1 的 A 类写集合器	入	SEL 那条入口 FIFO 将满时的 wr_stall（只到 SEL，不到 CCU）	1 bit
上行	写 L1 → L1 发送侧经 C2H 发出（发送命令送 CCU，CCU 发读）	出	升序序号列表、不需跨核合并的位图（写入 L2，目的地址由 MAE 命令给出）；要做读集合并的位图经 C2H 以 TUSER 的目的位 = CRU 直送 CRU，合并后的读集经 HUB-DN 回核	见 §6.1；③ 档变长对象，bump 分配（§6.7）
L1 读写	读：L1 外选择器 → 激活类读口；写：A 类写集合器里 SEL 的入口 FIFO	入 / 出	名次缓冲与暂存（§2.3）	整字 32 B

每个结果交给哪个接口由指令选。

2.3 经 VNU 的 RRAM 口读写 L1 的 A 类空间

SEL 经 VNU 的 RRAM 口访问 L1 的 A 类（激活类）空间里的一段地址，存放流式 TOPK 的名次缓冲和相对阈值第一遍的暂存。读经 L1 外的选择器用一个激活类读口，与 SMP、LOSS、OPT 及其他客户分时，读时隙由 CCU 排；写进 A 类写集合器里 SEL 自己的入口 FIFO，与其他写者并行排队，由集合器按优先级分道；L1 内不仲裁（用户 11-04 / 11-05）。**比较结果不等 L1 读回**，L1 访问不在比较的关键路径上。地址段的基址与长度由指令给出，容量建议值见 §9.1。

RRAM 口的用法（传输协议篇 §3、§4）：

- **写**：SEL 交 din（一个存储字，32 B）与本条记录的长度；en / wea / addr 由 CCU 发出，进 SEL 在 A 类写集合器里的入口 FIFO，集合器选中的那拍写入，无应答；**FIFO 将满时集合器拉 wr_stall 回 SEL，SEL 保持 en / wea / addr / din**（传输协议篇 §3.2、§4.2）。**对齐的单位是记录**（用户 11-05）：名次项、位图、列表的对象头单独占一个存储字；每条记录（一个选择域的位图、列表或一组名次项）从整字起、占 $\lceil n_i/32 \rceil$ 个存储字、尾部补 0，CCU 只记每条记录的首字号（传输协议篇 §2.5、§9.1）。
- **读**：CCU 发 en / addr，下一拍 dout 整字到达 SEL 的入口缓冲；读一条记录就是从它的首字号起连续读 $\lceil n_i/32 \rceil$ 个存储字，没有跨字拼接、没有字内偏移（传输协议篇 §9.4）。

- **握手**：**SEL 每条由 CCU 发读的入口给 CCU 一根 stall_vnu[i]**，入口缓冲占到"深度 − L"时拉起，CCU 停发该入口的读；L = CCU 停发 1 拍 + L1 读返回 1 拍，【设计者定】。
- **两堆**：读哪一堆、写哪一堆由 CCU 给的地址的堆位决定；第一遍暂存与第二遍读回之间的堆切换，条件是写完成 ∧ 最后读者完成，由 CCU 在下一阶段的地址里体现（传输协议篇 §7.1）。

2.4 由别的模块保证的事项

以下事项 SEL 不检查，由对应模块保证：

事项	由谁保证
评分与统计量怎样算；NLU 求均值用的数值与它交来的逐维幅值同源	MXU、NLU、QNT
阈值套的内容，以及装载前按最松一档离线核过 H2C 口宽	编译链
阈值套在首次使用前经 H2C 落地 L1 并读入门限表	LIC、MAE、CCU
档号的给出，以及在位点边界翻转	CCU_CTL
每个元素的屏蔽位与强制入选位	指令
稠密计算时被屏蔽的位置不进 softmax	NLU（只写需求，见 VNU_NLU 篇）； 屏蔽位由指令给出； 被屏蔽元素不白占运算拍，由 CCU、MXU、NLU 设计者均衡利用率
判决结果与下游计算的放行先后； 判决结果转发给其他核（作 ③ 档小消息经 C2H → L2 → H2C，传输协议篇 §6.1）	CCU 与指令
同一单元的不同功能不在时间上重叠	CCU 与指令
读集合并（录取读集 / 区块读集 / lo 读集）	CRU：位图经 C2H 以 TUSER 的目的位 = CRU 直送，合并后的读集经 HUB-DN 回核；CRU 的合并配置由 MAE 操作 18 下发（用户 11-05，传输协议篇 §5.2、§6.1、§8.3）
VNU 对外口的个数与共享方式（RRAM 读侧经选择器接哪个激活类读口； 写侧在集合器里的优先级）	VNU 集成篇（待写）；集合器优先级表由 CCU 随位点命令装

事项	由谁保证
读写 L1 的地址（基址 + 字节累加、环形回绕）与 dout 去向	CCU
上行产出写 L1 后经 C2H 发出； 变长对象的实际长度报 MAE	L1 发送侧（MAE 发送命令送 CCU，CCU 发读）；CCU（对象长度报告）
名次项何时可以释放	消费方（发释放通知）
变长对象按实际长度 bump 分配； 定长的名次缓冲与暂存段够用、 写入前旧数据已读完；同一阶段并发写者总需求 ≤ 道数 × 32 B/拍	CCU（bump 分配）；编译链 （指令中的基址与长度，LIC 操作 15； 静态检查）

3 选择模式

3.1 五种模式一览

选择域是一次选择面对的元素集合和它的结束点，结果只在相应时点发布。例如：

- 一个 query 行在连续 N_{ct} 个 key 上的粗分数，N_{ct} 默认 64，称为一个录取窗口；
- 一个 token 的整行 logit；
- 一个（query 行块, q 头）的全部区块能量。区块是连续 128 个 key，区块能量由 NLU 按摘要分数聚合得到。

模式	比较什么	输出	何时发布	典型用途
阈值	每个元素与 1 个或 2 个门限	每元素 1 bit 或 2 bit	元素到达即出	FFN gate 先筛、FFN 输出通道分档、 attention 固定阈值录取、 区块绝对阈值、token 复用判决
相对阈值	每个元素与 α × 本域统计量	每元素 1 bit	统计量就绪后	区块相对阈值、Q 一行各维的选维
流式 TOPK	本域内取前 k 名	名次项或位图	选择域结束	attention 每行每窗口录取、 区块名次选择、LM

模式	比较什么	输出	何时发布	典型用途
				Head 词表、判别器取最大类（$k = 1$）
阈值后封顶	过门限的元素里取前 k 名	名次项或位图	选择域结束	attention 封顶录取
关闭	—	—	—	稠密计算

3.2 阈值模式：与 1 个或 2 个门限比较

- **1 个门限**：$x \geq \tau$ 输出 1，否则 0。
- **2 个门限**（$\tau_{\mathrm{hi}} \geq \tau_{\mathrm{lo}}$）：输出 2 bit 分档，即 $\geq \tau_{\mathrm{hi}}$、$[\tau_{\mathrm{lo}}, \tau_{\mathrm{hi}})$、$< \tau_{\mathrm{lo}}$ 三档。用于 FFN 输出通道分档时，三档记作 F / C / Z：F 读权重高位与低位两个平面，C 只读高位平面，Z 不参与后续计算。
- 可选**按幅值比较** $|x|$。
- **评分按 BF16 进比较器，不另量化。** 有的阈值在算法侧定义在平方尺度上，例如 FFN 分档的 τ_F、τ_C 定义在 $\tilde{s}^2$ 上。这类阈值由编译链换算成 BF16 平方根门限后装表，SEL 只比较 $|\tilde{s}| \geq \mathrm{bf16}(\sqrt{\tau})$，**不做开方**。
- 门限取"恒通过""恒不通过"两个哨兵值时，判决与算法参考模型一致。



缩小例只画 8 个元素，实际 NLU 口每拍交 16 个。平方尺度阈值 $\tau_F = 0.25$、$\tau_C = 0.0625$ 换算成门限 0.5 与 0.25，各元素按 $|\text{评分}|$ 分档：

元素	0	1	2	3	4	5	6	7
评分	0.625	0.125	0.3125	0.0625	0.5	0.1875	0.875	0.25
分档	F	Z	C	Z	F	Z	F	C

元素 4 的 0.5 等于门限 F，判 F；元素 7 的 0.25 等于门限 C，判 C。

3.3 相对阈值模式：门限随本选择域的统计量变化

门限 = α × 本选择域的统计量，α 由指令给出。统计量有两种：

- **最大值，由 SEL 自己求。** 第一遍扫完本域，求出最大值，评分暂存在 L1 的 A 类空间；第二遍逐个与 $\alpha \times \max$ 比较。例如区块相对阈值 $\mathcal{E}_J \geq \alpha_{\text{blk}} \cdot \max_{J'} \mathcal{E}_{J'}$。
- **均值，由 NLU 求好随评分交来**（用户 11-04）。SEL 只算 α × 均值再比较。例如对 Q 的一行沿 head_dim 维判断 $|q_d| \geq \alpha \cdot \text{mean}_d |q_d|$，输出 head_dim bit 的选维位，粗分数只在选中维上求和。

阈值判断沿哪一维、对哪条向量做，由指令给出（用户 11-04）：

- FFN 输出通道的分档（F / C / Z）、gate 先筛、下一位点输入激活的保留判断（keep）、Q 一行各维的选维，都是同一种逐元素阈值判断；
- 区别只在被判断的向量、门限个数与门限来源（固定值或相对于本域统计量）。

所以本篇不为它们各设机制。保留判断原在 QNT，现在也由 SEL 执行，QNT 只按 SEL 给的判决位压紧与打包。

用整行统计量判决的位点（相对阈值、QDS 行均值）在权重驻留下，行统计量要等全部列块算完才有，判决前的值须先存 BF16、再判决与压紧，不能逐 MX 组流式打包。规则见传输协议篇 §9.7；**哪些位点如此，由 CCU 篇按 SEL 的选择模式逐位点列出**（用户 11-05）。

α × 统计量的舍入与算法参考模型一致。大选择域的暂存方案交设计者（用户 11-01）。参考规模：32K 上下文、128 key 区块时一个域有 256 个区块能量，上限 512。



8 个元素，$\alpha = 0.5$。第一遍逐个更新当前最大值，扫完得 10；第二遍与 $0.5 \times 10 = 5$ 比较，元素 1、3、6、7 选中，其中元素 7 的 5 等于门限、判选中。

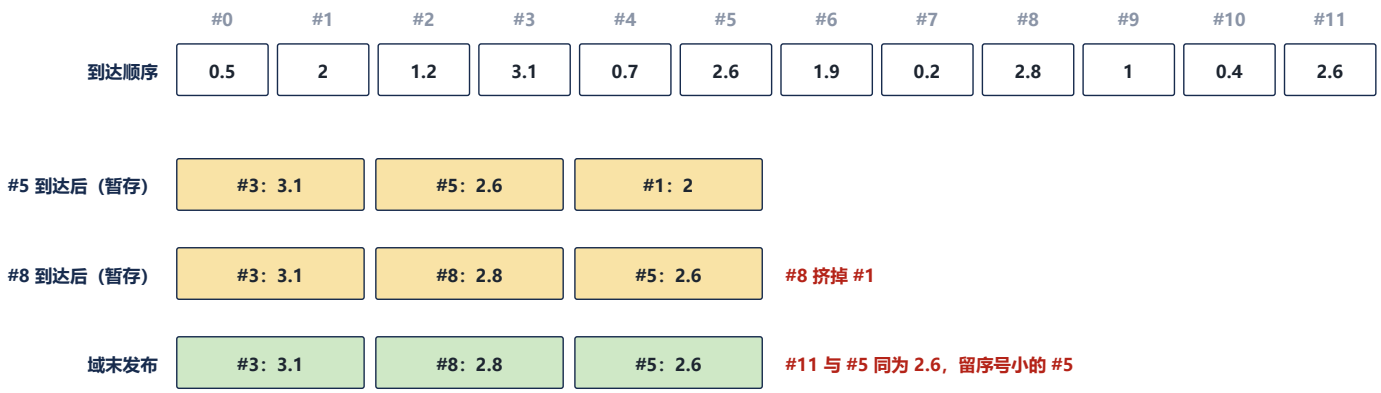
3.4 流式 TOPK 模式：边到达边插入，选择域结束时发布前 k 名

- **每到一个评分，与本域暂存的第 k 名比较，胜出就插入。整个选择域结束才发布，中途不发布。** 发布内容是前 k 个名次项（序号 + 评分），或对应的位图。

- **无近似**：结果与对整个域排序后取前 k 名逐位相同。并列取序号小者。
- **选择域长度不限**：一个窗口的几十个元素、一个 token 的整行 logit、超长上下文的全部区块，都用这一个模式。同时在选的域可以有多个，例如一个窗口里多个 query 行各一个域，一条 logit 流上多个 token 各一个域。
- k **由指令配置，不设硬上限**，只受名次缓冲所在 A 类地址段的长度约束：

$$n_{\mathrm{dom}} \times k \times b_{\mathrm{item}} \le L_{\mathrm{rank}},$$

  其中 n_{dom} 为同时在选的域数，b_{item} 为每个名次项的字节数（参考 5 B：序号 3 B + BF16 评分 2 B），L_{rank} 为名次缓冲地址段的长度（指令给出）。参考值：attention 录取 $k \le N_{\mathrm{ct}}/4$（$N_{\mathrm{ct}} = 64$ 时 ≤ 16），LM Head 20，判别器取最大类 $k = 1$。
- **一条评分流上可同时跑两组流式 TOPK**，k 各自配置（可为 0），各组结果都可按序号升序输出。
- **名次项保持到消费方通知释放**，此前不被下一个选择域覆盖。



12 个评分按 #0…#11 的顺序到达，$k = 3$。#5 到达后暂存的前 3 名是 #3、#5、#1；#8（2.8）到达后挤掉 #1；#11 与 #5 同为 2.6，按并列规则留序号小的 #5。域末发布 #3、#8、#5。如果在 #5 到达后就发布，下游会用到最终不在前 3 名的 #1。

3.5 阈值后封顶模式

先按门限判决，**过门限的元素里再按流式 TOPK 取前** k **名**，在选择域结束时发布。过门限的不足 k 个时，只发布过门限的，不补。

3.6 关闭

SEL 不工作，见 §1.4。

4 哪些元素参与选择：屏蔽与强制入选

4.1 屏蔽位与强制入选位由指令给出

每个元素可以带一个屏蔽位和一个强制入选位，**都由指令给出**（用户 11-04）；以区间、位图还是其他形式给出，随指令定。典型来源：

- 屏蔽：attention 的因果截断、树形 token 之间的祖先关系、有效 key 范围。
- 强制入选：序列开头的若干 key、对角区块等。

4.2 强制入选的元素不占名额

在流式 TOPK 和阈值后封顶模式里，强制入选的元素不参与名次竞争，也不占 k 个名额。

4.3 屏蔽优先

被屏蔽的元素一律不选中，即使同时带强制入选位。 选择按以下先后进行：

1. 去掉被屏蔽和强制入选的元素，在其余元素里按模式选；
2. 把结果与强制入选位按位 OR；
3. 被屏蔽的元素置 0。

4.4 档号 3 的 token 不参与

档号为 3 的 token（§5.2）不参与选择，也不产出任何结果。

	元素 0	元素 1	元素 2	元素 3	元素 4	元素 5	元素 6	元素 7
评分	0.2	1.5	0.4	2.1	0.9	1.1	3	2.5
屏蔽位	0	0	0	0	0	0	1	1
强制入选位	1	0	0	0	0	0	0	1
前 2 名（不含强制与屏蔽）	0	1	0	1	0	0	0	0
最终选中	1	1	0	1	0	0	0	0

屏蔽优先

8 个元素，取前 2 名：

- 元素 6、7 被屏蔽，元素 0、7 强制入选。

- 前 2 名只在其余元素 1–5 里取，得元素 3（2.1）与元素 1（1.5）。
- 与强制位 OR 后加入元素 0。
- 元素 7 既强制入选又被屏蔽，按屏蔽优先不选中。元素 6 的评分 3.0 最高，但被屏蔽，同样不选中。

5 门限

5.1 只存当前一套阈值

阈值套是一次运行要用的全部门限：attention 录取表（固定阈值或 k）、各阈值判断的门限与相对系数 α（FFN 分档的 τ_F 与 τ_C、gate 先筛的 τ_g、保留判断的门限、选维的系数）等，每（层, 位点）一组。**位点**是一层里的一个算子实例，例如 gate/up 投影。

编译期准备多套阈值存在 L2，由控制方选一套经 H2C 落地本核 L1（H2C 只接 L1 的接收桥，传输协议篇 §6.2），再经 RRAM 口读入 SEL 的门限表，读地址由 CCU 给出。**SEL 只存当前一套**，装入新的一套之前一直有效。**装载完成前不读表。** 保留判断（keep）的门限也在这一套里，只存这一份，QNT 不存门限（用户 11-04）。

5.2 按档号选门限

同一次选择里，不同 token 可以用不同门限。 每个门限按档存最多 4 个值：档 0、1、2 有效，档 3 表示该 token 不参与。比较时按评分所属 token 的档号选档。

- 档号由控制方给出，每 token 2 bit；以什么形式交给 SEL【设计者定】。
- 选套与选档两级独立：一套门限在装入新套之前不变，档号逐 token 选。

示例（数值只作说明，gate 先筛门限 τ_g 按档存 0.05 / 0.10 / 0.20，同一个评分 0.12）：

token	档号	用的 τ_g	评分 0.12 的判决
t0	0	0.05	选中
t1	1	0.10	选中
t2	2	0.20	不选
t3	3	—	不参与

5.3 偏置只能收紧门限

门限可以加偏置 b：$\tau' = \tau \cdot 2^b$，**只允许 $b \geq 0$，只收紧**。给出负值时钳为 0，并计数（§8）。偏置是否开启、b 取多大由指令给出，默认关。

偏置与平方根换算的舍入先后【设计者定】，同一套里所有门限（含保留判断的门限）用同一口径，选定后同步算法参考模型。

6 输出形式与结果规则

6.1 输出形式

形式	内容	位宽
判决位	每元素 1 bit 或 2 bit	—
位图	一个选择域一张，每元素 1 bit	attention 录取窗口的位图按 128 bit 参数化（$N_{\mathrm{ct}} \leq 128$）；区块位图 512 bit 定宽
按行计数	选中个数 ≥ 1 的行： 行号与本域选中个数	—
升序序号列表	选中元素的序号按升序排列	个数字段 16 bit；序号 16 bit，0xFFFF 为填充
名次项	序号 + 评分	参考每项 5 B
最大类号	取最大类的结果（$k = 1$ 的流式 TOPK）	—
判决位（交 QNT）	一条向量每元素 1 bit 或 2 bit	Q 一行 head_dim 128 时 16 B

6.2 选择域结束才发布

选择域结束前的暂存结果不交下游。 有效元素不足 k 个时，不补无效项。

6.3 并列取序号小者

评分相等时，取元素序号（key 号、词号或区块号）小者。

6.4 结果只依赖评分与配置

结果只依赖评分、所属（层, 位点, token）、当前门限与档号，与评分到达的先后、所在的核无关。

6.5 与算法参考模型逐位一致

全部选择结果必须与算法参考模型在 NPU 格式下逐位一致（用户 11-02）。某种比较口径硬件实现太难时，交回算法侧修改口径并同步参考模型，**硬件不自行换比较方式**。

6.6 生效时机

- 选择模式与参数在位点边界随指令生效。
- 档号在位点边界由 CCU_CTL 翻转后才被采用，一个位点内不会出现新旧档号混用。

6.7 变长对象按实际长度分配；选择模式只给 token 槽的上限

选择结果决定的变长对象——SEL 自己写出的位图、序号列表、名次项，以及 QNT 按 SEL 判决位压紧写出的紧凑记录——属传输协议篇 §9.2 的第 ③ 档。**这些对象的源空间按实际长度由 CCU bump 分配，不预留上限**（用户 11-05："如果已经知道长度了，上限分区毫无意义"，传输协议篇 §7.3）：顺序产出的对象，下一个对象的基址 = 上一个对象结束时的字号。

只有并发增长的情形才用上限：权重驻留下 T 条 token 记录按 MX 组交错到达、同时在长，CCU 要先给每条一个起点，token 槽按上限留（传输协议篇 §9.7）；编译期的"最坏情况放得下"静态检查也用同一上限。上限来自 SEL 的选择模式：

选择模式	每个选择域的选中个数上限
流式 TOPK	k
阈值后封顶	k
阈值、相对阈值（无封顶）	选择域长度，即稠密长度
关闭	不产生选择结果

强制入选的元素不占 k 个名额（§4.2），所以有封顶时上限 = k + 本域强制入选个数（用户 11-05 认可）；不封顶时按全保留长度计。**在 token 槽里，SEL 保证按所选模式选出的个数不超过槽上限**；超过槽上限是传输协议篇 §10 的致命错误。bump 分配的对象没有上限，也就没有"超上限"。实际长度由本核 CCU 在对象结束时经命令与标量网报 MAE（对象长度报告），SEL 不报。

7 速率与时延

7.1 每拍处理能力匹配上下游模块

SEL 每拍能处理的元素数，须匹配上游各口的产出速率与下游各口的接收要求，由 SEL 设计者与以下模块对接确定（用户 11-04）。下表的参考值只作背景，不是 SEL 的定值：

相关模块	接口	现行参考值
MXU（FBA）	粗分数口	4 个 pod 的 FBA 都直连 SEL，每个 pod 一次交 16 个；同拍是否会 4 个 pod 一起交【待确认】。四 pod 平均约 21.8 个/拍/核（理想粗算节奏），真实掩码回放约 17.2 个/拍/核（旧供数结构下仿真【待标定】）
MXU 出口级	长流评分口	15 万词 × 24 个 token 约 3.6 M 次比较，须在出口级送完这条流的约 10.8 ms 内完成
NLU	NLU 口	每拍 16 个评分
QNT	QNT 口、判决位交 QNT	跟随 QNT 量化的节奏；保留判断每拍至多 16 个通道
本核 CCU	判决口	判决位交出时延见 §7.2
L1 发送侧（先写 L1 再发出）	上行	位图与序号列表的上行负载归 HUB 流量预算；L1 发送侧读 L1 占一个激活类读口时隙，由 CCU 排
VNU 的 RRAM 口	L1 读写	读：经选择器用一个激活类读口（32 B/拍），与 SMP、LOSS、OPT 等分时，时隙由 CCU 排，固定 1 拍，入口缓冲将满时拉 stall_vnu[i]；写：进 A 类写集合器里 SEL 的入口 FIFO，将满时 wr_stall 回 SEL；同一阶段并发写者总需求 ≤ 道数 × 32 B/拍由编译链保证
SMP、LOSS	名次口	选择域结束时一次
CCU_CTL	判决口（最大类号）、档号	档号在位点边界翻转

SEL 不对 FBA 粗分数口施加反压，也不丢失粗分数。 长流评分口在推送链上，SEL 来不及处理时按传输协议篇 §4.3 给出口级一根相邻级 stall（VNU → 出口级）；由 CCU 发读的入口只用 stall_vnu[i] 让 CCU 停发（§2.3）。

7.2 SEL 自身时延

项	要求
粗分数到达到选中位交出（阈值模式）	≤ 2 拍【待标定】
评分到达到判决位交出	≤ 4 拍【待标定】
相对阈值第二遍	不慢于评分的产出节奏；256 项选择域参考 ≤ 12 拍
流式 TOPK 插入	不低于评分到达速率

8 计数与复位

- **计数**：偏置负值钳 0 的次数，供 LIC / MAE 读取。
- **复位**：清当前阈值套、名次缓冲与暂存内容。档号不由 SEL 持有。SEL 没有需要跨次保留的状态。
- **不设运行时错误事件**：§2.4 所列前提由对应模块保证，验收时用断言检查。token 槽不超上限由 SEL 按模式保证（§6.7）；万一超出，属传输协议篇 §10 的致命错误，报 LIC；SEL 在命令与标量网上没有端口，由本核 CCU 转报（用户 11-05 定；槽的 bump 计数在 CCU，通常由 CCU 直接发现）。

9 要求值与验收

9.1 要求值

项	要求值	说明
选择模式	阈值（1 / 2 bit）、相对阈值（最大值 / 均值）、流式 TOPK、阈值后封顶、关闭	模式与参数由指令给出
每拍处理能力	匹配上下游各口（§7.1）	由 SEL 设计者对接确定
NLU 口	每拍 16 个评分	—
时延	选中位 ≤ 2 拍，判决位 ≤ 4 拍	【待标定】

项	要求值	说明
k	指令配置，无硬上限	受名次缓冲地址段长度约束（§3.4）
门限档	每个门限最多 4 档；档号每 token 2 bit	参与按档选门限的 token ≤ 128
位图位宽	录取窗口按 128 bit 参数化；区块位图 512 bit	与 CRU、HUB 一致
相对阈值选择域	≤ 512 项	—
门数	参考 ≤ 28 k 门（NAND2 等效），另加约 2 KB 门限表	不含 L1 内的缓冲
L1 缓冲	建议值 3–10 KB	A 类地址段由编译链分配
入口 stall	每条由 CCU 发读的入口一根 stall_vnu[i]，在"深度 − L"处拉	L【设计者定】
写握手	A 类写集合器里 SEL 的入口 FIFO 将满 → wr_stall 回 SEL	FIFO 深度【设计者定】
变长对象	bump 分配，无上限；权重驻留下的 token 槽按选择模式留上限（§6.7）	超过槽上限为致命错误

9.2 验收

对象	方法	用例
阈值模式（§3.2）	与算法参考模型逐位比对	1 个门限、2 个门限、哨兵门限、评分恰等于门限
相对阈值（§3.3）	逐位比对	最大值与均值两种统计量；8 / 256 / 512 项选择域
流式 TOPK（§3.4）	与整体排序结果逐位比对；断言中途无发布	不同 k、并列评分、同一条流两组 TOPK
阈值后封顶（§3.5）	逐位比对	过门限者少于 k、多于 k
屏蔽与强制入选（§4）	逐位比对	强制不占名额；强制且屏蔽的元素不选中；档号 3 的 token 无输出

对象	方法	用例
按档号选门限（§5.2）	逐位比对	4 档混合的 token 序列
偏置（§5.3）	逐位比对	$b = 0 \ldots 4$ 扫描下选中集合单调变小； 负值钳 0 并计数
结果规则（§6）	断言	域末前无发布；不足 k 不补；乱序注入、 换核运行结果逐位相同
不反压、不丢失（§7.1）	周期仿真	四个 pod 同拍各交 16 个粗分数的峰值注入
RRAM 口与入口 stall（§2.3）	周期仿真；断言	写只给 din 与长度；入口缓冲到"深度 − L "时 stall_vnu 拉起后不溢出； 对象头单独占一个存储字， 每条记录从整字起、尾部补 0
token 槽上限（§6.7）	断言	权重驻留下各模式选中个数 ≤ 槽上限； 强制入选与 k 同时存在
写 FIFO 与 wr_stall（§2.3）	周期仿真	与其他写者同拍撞 bank 时 SEL 的 FIFO 吸收、将满拉 wr_stall 后不丢写
自身时延（§7.2）	周期测量	各模式
关闭（§3.6）	审查	稠密配置下 SEL 无活动
门数（§9.1）	综合	待 RTL

10 为什么

- **对外接口经 VNU 组封装**（用户 11-04）：SEL 是 VNU 组内的单元，访问 L1、向核外上行都经 VNU 的共用口；对外口怎样划分由 VNU 集成篇统一定义，各单元篇只写本单元的接口。
- **按选择模式提供能力，配置由指令完成**（用户 11-04）：attention 录取、区块选择、FFN 判决、LM Head 选词、判别器，都是同几种比较与排序换了参数。模式少且与用途无关，换模型、换算子只换参数与门限，不改硬件。算子融合与放行先后归 CCU 与指令设计。
- **全录取就是关闭**（用户 11-04）：稠密计算不需要先算粗分数再选。
- **屏蔽位与强制入选位由指令给出**（用户 11-04）：因果、树形祖先关系、有效范围都是算子语义，SEL 只按位施加。
- **均值由 NLU 求**（用户 11-04）：NLU 已有求均值的运算（归一化统计），SEL 不做算术。

- **流式 TOPK 作为一个模式**（用户 11-04）：每个域只需存 k 项，域长不限，结果无近似。所以区块名次选择也用它，不再需要直方图近似。
- **选择域结束才发布**：名次要看完整个域才确定，中途发布会让下游用到最终被挤掉的元素（FIG-VNU_SEL-TOPK 的 #1）。
- **粗分数直达、判完即丢**：粗分数每拍几十个，经出口级排队或量化都会成为瓶颈，所以 FBA 直接送 SEL；精确分数由 MXU 用全部数字重算，不以粗分数为初值，所以 SEL 不保存粗分数。
- **比较口径与参考模型逐位一致**（用户 11-02）：FFN 分档阈值定义在平方尺度上，按 $|\tilde{s}| \geq \mathrm{bf16}(\sqrt{\tau})$ 比较是算法侧当前配置采用的口径。有限精度下它与"先平方再比较"在舍入边界可能不同；用户判断影响很可能极小，这个判断尚未实测。
- **按档号选门限、偏置只收紧**（用户 10-14 定 2 bit 档号与四档）：档号由建树方按 token 被接受的路径概率给出，让算力集中到更可能被接受的 token 上。每套阈值装载前已按最松一档核过 H2C 口宽；偏置只收紧，档号只在 0 / 1 / 2 之间改，核过的约束一直成立。
- **结果只依赖评分与配置**：多个核对同一组评分各自判决时必须得到相同结果，训练时也要能重现前向的选择。
- **区块位图 512 bit 定宽**：区块大小为 $64 \cdot 2^e$ 个 key（$e = 0 \ldots 3$），32K 上下文按最细的 64 key 计有 512 个区块。
- **每拍处理能力由设计者对接**（用户 11-04）：四个 pod 是否同拍交出、下游各口的接收节奏，都随相关模块的设计而定，所以本篇列出相关模块与参考值，不写死跨模块的数字。
- **按传输协议篇同步**（用户 11-05，V18-TP-01…16）：核内与 L1 之间只有 RRAM 一种口，地址只在 CCU 一处推理，SEL 只给数据与长度；CCU 不看下游余量，所以每条入口给 CCU 一根 stall；出核数据一律先写 L1、由 L1 发送侧发出；变长对象的上限只能来自选择模式，所以由 SEL 按模式保证。
- **第二轮同步**（用户 11-05）：写侧改为集合器——每个写者一条入口 FIFO，集合器按优先级分 bank 道，写者只看自己的 wr_stall，L1 内仍无仲裁；变长对象已知实际长度，按 bump 分配、不再预留上限，上限只留给并发增长的 token 槽；要做读集合并的位图经 C2H 直送 CRU，不再经 L2；32 B 单位改称存储字，免与矩阵的行混淆。
- **CRU 的该项功能改称读集合并**（用户 11-05："OR，我认为它不应该叫这个命名，它会严重影响名称"；"读集合并是更合理的叫法"，V18-TP-24）：名字说的是功能——把几核各自要读的集合合成一份并集、只读一次再多播，而不是实现它的逻辑运算；SEL 内部"与强制位 OR"一类按位运算不改名。TUSER 用单独 1 bit 目的位标 CRU，不再占类码（协议篇 §5.2）。
- **不在本篇的数字**：阈值套装载拍数是传输时延，位图上行负载是 HUB 流量预算，都不由 SEL 决定。一次通过在线录取（One-Pass Online Admission，OPOA）的在线阈值是扩展项，不实现。